



ΠΑΝΕΠΙΣΤΗΜΙΟ
ΠΑΤΡΩΝ
UNIVERSITY OF PATRAS

Πολυτεχνική Σχολή

Τμήμα Μηχανικών Η/Υ & Πληροφορικής

ΕΞΟΥΥΞΗ ΔΕΔΟΜΕΝΩΝ ΚΑΙ ΜΗΧΑΝΙΚΗ ΜΑΘΗΣΗ

Αναφορά βασισμένη στην ανάλυση Clickstream Δεδομένων

Γεωργία Μυλωνά

A.M. 1104783

Δημήτριος Φιλόπουλος

A.M. 1101130

Πάτρα, 2026

Contents

1	Εισαγωγή	2
2	Προηγούμενες σχετικές μελέτες	2
3	Προηγούμενες σχετικές μελέτες	2
3.1	Clickstream user behavior models [6]	2
3.1.1	Σκοπός της Έρευνας	2
3.1.2	Μεθοδολογία	3
3.1.3	Συμπεράσματα	3
3.2	Real-time clickstream data analytics and visualization [1]	4
3.2.1	Σκοπός της Έρευνας	4
3.2.2	Μεθοδολογία	4
3.2.3	Συμπεράσματα	4
4	Βασική ανάλυση	5
4.1	Model selection for mixture hidden Markov models: an application to click-stream data [5]	5
4.1.1	Σκοπός της Έρευνας	5
4.1.2	Μεθοδολογία	6
4.1.3	Συμπεράσματα	7
4.2	Real-time user clickstream behavior analysis based on apache storm streaming	7
4.2.1	Σκοπός της Έρευνας	7
4.2.2	Μεθοδολογία	7
4.2.3	Συμπεράσματα	8
4.3	Pattern2Vec: Representation of clickstream data sequences for learning user navigational behavior [2]	8
4.3.1	Σκοπός της έρευνας	8
4.3.2	Μεθοδολογία	9
4.3.3	Συμπεράσματα	9
4.4	Exclusive Item Recommendation to the Online Shopping Customers Based on Category Using Clickstream and UID Matrix, 2023 [4]	9
4.4.1	Σκοπός της έρευνας	9
4.4.2	Μεθοδολογία	10
4.4.3	Συμπεράσματα	10
5	Μετέπειτα Εργασίες	10
6	Σύνοψη και συμπεράσματα	11

1 Εισαγωγή

2 Προηγούμενες σχετικές μελέτες

Η μελέτη της βιβλιογραφίας γύρω από τα clickstream δεδομένα δείχνει ότι το συγκεκριμένο πεδίο έχει αναπτυχθεί σε πολλαπλές κατευθύνσεις, οι οποίες περιλαμβάνουν τη μοντελοποίηση της συμπεριφοράς των χρηστών, την ανάλυση ροών δεδομένων σε πραγματικό χρόνο, την αναγνώριση προτύπων πλοήγησης και την αξιοποίηση των ακολουθιών κλικ για τη λήψη αποφάσεων. Οι προηγούμενες σχετικές εργασίες είναι ιδιαίτερα σημαντικές, διότι προσφέρουν το θεωρητικό και μεθοδολογικό υπόβαθρο πάνω στο οποίο στηρίζεται η παρούσα μελέτη. Μέσα από αυτές καθίσταται σαφές ότι τα clickstream δεδομένα δεν αποτελούν απλώς ένα σύνολο διαδοχικών ενεργειών, αλλά μια πλούσια πηγή πληροφορίας για την ερμηνεία της συμπεριφοράς των χρηστών σε ψηφιακά περιβάλλοντα.

Στην παρούσα ενότητα παρουσιάζονται δύο χαρακτηριστικές εργασίες, οι οποίες αντιπροσωπεύουν δύο διαφορετικές αλλά συμπληρωματικές προσεγγίσεις. Η πρώτη επικεντρώνεται στη μοντελοποίηση της συμπεριφοράς των χρηστών και στην ανίχνευση ύποπτων ή μη φυσιολογικών προτύπων μέσω της ανάλυσης ακολουθιών clickstream. Η δεύτερη δίνει έμφαση στην τεχνολογική υποδομή που απαιτείται για τη συλλογή, επεξεργασία και οπτικοποίηση των δεδομένων αυτών σε πραγματικό χρόνο. Η συνδυαστική θεώρηση των δύο αυτών εργασιών επιτρέπει τη σφαιρική κατανόηση τόσο της αναλυτικής όσο και της λειτουργικής διάστασης των clickstream δεδομένων.

2.1 Clickstream user behavior models [6]

2.1.1 Σκοπός της Έρευνας

Ο κύριος σκοπός της εργασίας των Wang et al. [6] είναι η μοντελοποίηση της συμπεριφοράς των χρηστών σε μεγάλες διαδικτυακές πλατφόρμες μέσω της αξιοποίησης clickstream δεδομένων. Η μελέτη αυτή βασίζεται στην παραδοχή ότι οι ακολουθίες πλοήγησης των χρηστών περιέχουν επαρκή πληροφορία ώστε να καταστεί δυνατός ο εντοπισμός διαφορετικών προφίλ συμπεριφοράς, καθώς και η διάκριση μεταξύ φυσιολογικής και μη φυσιολογικής δραστηριότητας. Σε αντίθεση με προσεγγίσεις που επικεντρώνονται αποκλειστικά σε μεμονωμένες ενέργειες ή σε απλά στατιστικά χαρακτηριστικά, η συγκεκριμένη εργασία εξετάζει ολόκληρη τη διαδοχή των ενεργειών του χρήστη, αντιμετωπίζοντας την πλοήγηση ως ακολουθιακό φαινόμενο με ερμηνευτική αξία.

Πιο συγκεκριμένα, οι συγγραφείς επιδιώκουν αφενός την ανίχνευση κακόβουλων ή παραπλανητικών λογαριασμών, όπως οι λογαριασμοί τύπου Sybil, και αφετέρου την κατανόηση των λανθανόντων προτύπων που χαρακτηρίζουν τη συμπεριφορά διαφορετικών ομάδων χρηστών. Με τον τρόπο αυτό, η εργασία δεν περιορίζεται μόνο σε ένα πρόβλημα ταξινόμησης ή ανίχνευσης ανωμαλιών, αλλά επεκτείνεται και στην ευρύτερη ερμηνεία της ανθρώπινης πλοήγησης σε ψηφιακά περιβάλλοντα. Η προσέγγιση αυτή είναι ιδιαίτερα σημαντική, διότι αναδεικνύει ότι τα clickstream δεδομένα μπορούν να χρησιμοποιηθούν όχι μόνο ως μέσο καταγραφής δραστηριότητας, αλλά και ως βάση για την εξαγωγή βαθύτερης γνώσης σχετικά με τα κίνητρα και τις στρατηγικές πλοήγησης των χρηστών.

2.1.2 Μεθοδολογία

Η μεθοδολογία της εργασίας στηρίζεται στην ανάλυση πραγματικών clickstream δεδομένων που προέρχονται από τις πλατφόρμες Renren και Whisper. Οι συγγραφείς εξετάζουν τη συμπεριφορά των χρηστών τόσο σε επίπεδο συνεδρίας όσο και σε επίπεδο συνολικής ακολουθίας ενεργειών, επιδιώκοντας να καταγράψουν όχι μόνο το πλήθος των ενεργειών αλλά και τη δομή με την οποία

αυτές εμφανίζονται μέσα στον χρόνο. Στο αρχικό στάδιο της ανάλυσης, μελετώνται βασικά χαρακτηριστικά, όπως η διάρκεια των συνεδριών, ο αριθμός κλικ ανά συνεδρία και η εναλλαγή μεταξύ διαφορετικών τύπων ενεργειών, ώστε να προκύψει μια πρώτη περιγραφική εικόνα της συμπεριφοράς των χρηστών.

Στη συνέχεια, προτείνονται τρεις διαφορετικές αναπαραστάσεις των clickstream ακολουθιών: η αναπαράσταση click-sequence, η χρονική αναπαράσταση (time-based model) και ένα υβριδικό μοντέλο που συνδυάζει τα προηγούμενα δύο. Στόχος αυτών των αναπαραστάσεων είναι να αποτυπωθεί όχι μόνο η σειρά των ενεργειών αλλά και η χρονική απόσταση μεταξύ τους, καθώς ο χρόνος συχνά αποτελεί κρίσιμο παράγοντα για την κατανόηση της πρόθεσης του χρήστη. Για τη μέτρηση της ομοιότητας μεταξύ ακολουθιών χρησιμοποιούνται μετρικές όπως τα common subsequences, τα subsequences with counts και ο έλεγχος Kolmogorov–Smirnov για τα χρονικά χαρακτηριστικά.

Με βάση τις μετρήσεις ομοιότητας, οι χρήστες τοποθετούνται σε γράφο ομοιότητας και στη συνέχεια εφαρμόζεται ο αλγόριθμος METIS για τον διαχωρισμό τους σε ομάδες. Παράλληλα, η εργασία περιλαμβάνει και μηχανισμό incremental detection, μέσω του οποίου νέα clickstream δεδομένα μπορούν να ταξινομούνται χωρίς να απαιτείται πλήρης επανεκπαίδευση του συστήματος. Η μεθοδολογία αυτή παρουσιάζει ιδιαίτερο ενδιαφέρον, επειδή συνδυάζει τεχνικές αναγνώρισης προτύπων, μεθόδους σύγκρισης ακολουθιών και αλγορίθμους ομαδοποίησης, δημιουργώντας έτσι ένα συνεκτικό πλαίσιο για την ανάλυση σύνθετης συμπεριφοράς χρηστών.

2.1.3 Συμπεράσματα

Τα συμπεράσματα της εργασίας αναδεικνύουν ότι τα clickstream δεδομένα μπορούν να αξιοποιηθούν αποτελεσματικά τόσο για την αναγνώριση κακόβουλων λογαριασμών όσο και για την κατανόηση διαφορετικών προτύπων συμπεριφοράς. Ένα από τα βασικά πλεονεκτήματα της προσέγγισης είναι ότι δεν απαιτείται κατ' ανάγκη μεγάλο όγκο επισημασμένων δεδομένων, καθώς η πληροφορία που ενσωματώνεται στις ίδιες τις ακολουθίες είναι επαρκής για την εξαγωγή ουσιαστικών συμπερασμάτων. Παράλληλα, η μελέτη δείχνει ότι ακόμη και σχετικά απλές αναπαραστάσεις των clickstream ακολουθιών μπορούν να αποδειχθούν ιδιαίτερα αποτελεσματικές, όταν συνδυάζονται με κατάλληλες τεχνικές ομαδοποίησης και ανάλυσης ομοιότητας.

Η συγκεκριμένη εργασία είναι ιδιαίτερα σημαντική για την παρούσα μελέτη, διότι μετατοπίζει το ενδιαφέρον από την απλή καταγραφή ενεργειών προς τη συστηματική μοντελοποίηση της συμπεριφοράς των χρηστών. Επιπλέον, προσφέρει ένα ισχυρό παράδειγμα του τρόπου με τον οποίο οι ακολουθίες clickstream μπορούν να αξιοποιηθούν για την αναγνώριση διαφορετικών προφίλ πλοήγησης και για την κατανόηση των λανθανόντων χαρακτηριστικών που τις διέπουν. Για τον λόγο αυτό, αποτελεί μία από τις βασικές προηγούμενες μελέτες που θεμελιώνουν τη σύγχρονη έρευνα στην ανάλυση clickstream δεδομένων.

2.2 Real-time clickstream data analytics and visualization [1]

2.2.1 Σκοπός της Έρευνας

Ο κύριος σκοπός της εργασίας των Hanamanthrao και Thejaswini [1] είναι η ανάπτυξη μιας αρχιτεκτονικής για την ανάλυση και οπτικοποίηση clickstream δεδομένων σε πραγματικό χρόνο. Σε αντίθεση με μελέτες που δίνουν έμφαση κυρίως στη θεωρητική μοντελοποίηση της συμπεριφοράς των χρηστών, η συγκεκριμένη εργασία επικεντρώνεται στην τεχνολογική υποδομή που απαιτείται προκειμένου τα δεδομένα πλοήγησης να συλλέγονται, να επεξεργάζονται και να αξιοποιούνται άμεσα. Η βασική ιδέα είναι ότι η αξία των clickstream δεδομένων αυξάνεται σημαντικά όταν

αυτά μπορούν να αναλυθούν τη στιγμή που παράγονται, επιτρέποντας έτσι την ταχύτερη λήψη αποφάσεων.

Η μελέτη τοποθετεί το clickstream analysis στο πλαίσιο του business intelligence και αναδεικνύει τη σημασία της real-time επεξεργασίας σε περιβάλλοντα όπου η άμεση απόκριση αποτελεί κρίσιμο παράγοντα. Εφαρμογές όπως οι πλατφόρμες ηλεκτρονικού εμπορίου, τα online learning portals και τα συστήματα παρακολούθησης επισκεψιμότητας μπορούν να επωφεληθούν σημαντικά από την έγκαιρη εξαγωγή πληροφορίας σχετικά με τη συμπεριφορά των χρηστών. Ως εκ τούτου, η έρευνα δεν εξετάζει μόνο μια τεχνική λύση αποθήκευσης ή απεικόνισης, αλλά συνολικά ένα λειτουργικό πλαίσιο διαχείρισης clickstream ροών δεδομένων.

2.2.2 Μεθοδολογία

Η προτεινόμενη μεθοδολογία βασίζεται σε μια αρχιτεκτονική ροής δεδομένων που περιλαμβάνει τα Apache Kafka, Apache Spark Streaming, Elasticsearch και Kibana. Τα clickstream δεδομένα συλλέγονται από μια online learning πλατφόρμα, μεταφέρονται μέσω Kafka, υποβάλλονται σε επεξεργασία σε πραγματικό χρόνο μέσω Spark Streaming και στη συνέχεια αποθηκεύονται ή ευρετηριάζονται στο Elasticsearch. Τέλος, τα αποτελέσματα παρουσιάζονται μέσω του Kibana, το οποίο επιτρέπει τη διαδραστική οπτικοποίηση και την εύκολη παρακολούθηση κρίσιμων δεικτών συμπεριφοράς.

Η αρχιτεκτονική αυτή επιτρέπει την παρακολούθηση ποικίλων χαρακτηριστικών, όπως ο αριθμός των clicks, η γεωγραφική προέλευση των επισκεπτών, ο χρόνος παραμονής, οι συσκευές πρόσβασης και τα συχνότερα μονοπάτια πλοήγησης. Με τον τρόπο αυτό, η εργασία παρουσιάζει μία ολοκληρωμένη data pipeline προσέγγιση, η οποία δεν περιορίζεται στην απλή αποθήκευση δεδομένων, αλλά επεκτείνεται στην άμεση επιχειρησιακή αξιοποίησή τους. Η έμφαση, επομένως, δίνεται περισσότερο στην αποδοτική διαχείριση της ροής των δεδομένων και λιγότερο στην ανάπτυξη πολύπλοκων προβλεπτικών μοντέλων.

2.2.3 Συμπεράσματα

Τα συμπεράσματα της εργασίας καταδεικνύουν ότι η ανάλυση clickstream δεδομένων σε πραγματικό χρόνο μπορεί να προσφέρει ουσιαστικά οφέλη σε περιβάλλοντα όπου η ταχύτητα απόκρισης είναι κρίσιμη. Η ύπαρξη κατάλληλης υποδομής streaming και visualization επιτρέπει την άμεση κατανόηση της συμπεριφοράς των χρηστών και διευκολύνει τη βελτιστοποίηση ιστοσελίδων, υπηρεσιών και ψηφιακών πλατφορμών. Συνεπώς, η συνεισφορά της εργασίας εντοπίζεται κυρίως στην τεχνική και λειτουργική πλευρά της clickstream ανάλυσης.

Για την παρούσα εργασία, η συγκεκριμένη μελέτη είναι σημαντική επειδή αναδεικνύει το υποστηρικτικό τεχνολογικό πλαίσιο που απαιτείται πριν από τη φάση της μοντελοποίησης και της ερμηνείας των δεδομένων. Ενώ άλλες έρευνες εστιάζουν περισσότερο στην εξαγωγή προτύπων και στη συμπεριφορική ανάλυση, η παρούσα εργασία υπενθυμίζει ότι η ποιότητα και η χρηστικότητα των αποτελεσμάτων εξαρτώνται σε μεγάλο βαθμό από την ορθή συλλογή, επεξεργασία και παρουσίαση των δεδομένων. Για τον λόγο αυτό, αποτελεί ουσιαστικό συμπλήρωμα των μελετών που εξετάζουν τα clickstream δεδομένα από καθαρά αναλυτική σκοπιά.

3 Βασική ανάλυση

3.1 Model selection for mixture hidden Markov models: an application to clickstream data [5]

3.1.1 Σκοπός της Έρευνας

Ο κύριος σκοπός αυτού του άρθρου είναι η εις βάθος ανάλυση δεδομένων clickstream μέσω της χρήσης Mixture Hidden Markov Models (MHMMs). Η ανάλυση αυτή αποσκοπεί στο να ξεπεράσει τους περιορισμούς των απλών αλγορίθμων ομαδοποίησης, οι οποίοι συχνά απαιτούν έναν μεγάλο και μη πρακτικό αριθμό συστάδων για να παράγουν ομοιογενείς ομάδες, επειδή εξετάζουν αποκλειστικά τις ορατές αλληλουχίες των σελίδων που επισκέπτονται οι χρήστες.

Τα MHMMs προσφέρουν μια ουσιαστικότερη προσέγγιση στην ομαδοποίηση των ακολουθιών πλοήγησης, καθώς δεν αντιμετωπίζουν τη συμπεριφορά των χρηστών ως μια απλή, τυχαία σειρά από κλικ. Αντιθέτως, βασίζονται στην υπόθεση ότι η πλοήγηση καθοδηγείται από μια μίξη λανθανουσών μαρκοβιανών διαδικασιών, καθεμία από τις οποίες αντιστοιχεί σε έναν διαφορετικό, άγνωστο υποπληθυσμό χρηστών. Αυτές οι διαδικασίες αποτυπώνουν τα λανθάνοντα κίνητρα των χρηστών, τα οποία αναφέρονται στη μελέτη ως «νοητικές» ή «κρυφές καταστάσεις» (mental / hidden states). Οι καταστάσεις αυτές υπαγορεύουν την πορεία του χρήστη μέσα στον ιστότοπο, προσαρμόζοντας τις επιλογές του ανάλογα με τον εκάστοτε στόχο του. Με αυτόν τον τρόπο, το μοντέλο καταφέρνει να αποκαλύψει υποκείμενα προφίλ συμπεριφοράς που δεν θα μπορούσαν να εντοπιστούν αποκλειστικά από την επιφανειακή καταγραφή των σελίδων.

Ωστόσο, η πρακτική εφαρμογή των MHMMs περιπλέκεται σημαντικά από την ανάγκη προσδιορισμού ενός άγνωστου, εκ των προτέρων, αριθμού τόσο των συστάδων όσο και αυτών των κρυφών καταστάσεων. Όταν τα δεδομένα αποτελούνται από σύντομες ακολουθίες, τα παραδοσιακά κριτήρια πληροφοριών αποτυγχάνουν να υποδείξουν τον σωστό αριθμό ομάδων, καθώς αγνοούν τον βαθμό διαχωρισμού μεταξύ των προφίλ των χρηστών.

Για να αντιμετωπίσουν αυτή την πρόκληση και να εντοπίσουν τον βέλτιστο διαχωρισμό των χρηστών, οι συγγραφείς ανέπτυξαν και πρότειναν ένα νέο κριτήριο επιλογής μοντέλου, το BIC_H . Το κριτήριο αυτό σχεδιάστηκε ειδικά για να επιλέγει μοντέλα που δεν προσαρμόζονται απλώς καλά στα παρατηρούμενα δεδομένα, αλλά ταυτόχρονα αξιολογούν την αβεβαιότητα της ταξινόμησης, προσφέροντας τελικά διακριτές και εύκολα ερμηνεύσιμες ομάδες χρηστών.

Όσον αφορά τα **αποτελέσματα**, η αξιολόγηση του προτεινόμενου κριτηρίου χωρίζεται σε δύο σκέλη:

- **Αξιολόγηση μέσω Monte Carlo προσομοιώσεων:** Οι συγγραφείς εξέτασαν την απόδοση του BIC_H έναντι των κλασικών κριτηρίων πληροφοριών (AIC , BIC και $ssBIC$) σε διάφορα σενάρια, μεταβάλλοντας το μήκος των ακολουθιών και τον αριθμό των δεδομένων. Αποδείχθηκε ότι σε ακολουθίες μικρού μήκους, γεγονός που αποτελεί τον κανόνα στα δεδομένα clickstream, το BIC_H έχει σημαντικά καλύτερη απόδοση στην ταυτόχρονη αναγνώριση του σωστού αριθμού συστάδων και καταστάσεων. Αντίθετα, τα κλασικά κριτήρια δυσκολεύονται έντονα και υποτιμούν συστηματικά τον αριθμό των συστάδων.
- **Εφαρμογή σε πραγματικά δεδομένα:** Κατά την ανάλυση των πραγματικών δεδομένων clickstream από τον ιστότοπο της εταιρείας φιλοξενίας "LovePanormus", το κριτήριο BIC_H επέλεξε ένα μοντέλο με 3 συστάδες (clusters) και (3, 2, 4) κρυφές καταστάσεις αντίστοιχα. Η επιλογή αυτή αποκάλυψε τρία διακριτά προφίλ χρηστών:

1. «Απλός επισκέπτης / πιθανός συνεργάτης» (Casual explorer / Potential partner): Αποτελεί το 22% των χρηστών. Το μοντέλο εντόπισε 3 κρυφές καταστάσεις

σε αυτό το προφίλ, οι οποίες αντιστοιχούν σε πλοήγηση στην αρχική σελίδα, σε γενική εξερεύνηση, και στην αναζήτηση πληροφοριών για την ίδια την εταιρεία.

2. **«Αναζητητής πληροφοριών» (Information seeker):** Αποτελεί το 19% των χρηστών. Εδώ εντοπίστηκαν 2 κρυφές καταστάσεις, όπου οι χρήστες εστιάζουν αποκλειστικά σε τουριστικές πληροφορίες (αξιοθέατα) ή ακολουθούν μια μικτή πορεία προς τις τοπικές εκδηλώσεις, χωρίς να δείχνουν άμεση πρόθεση αγοράς υπηρεσιών.
3. **«Πιθανός τουρίστας» (Potential tourist):** Είναι η μεγαλύτερη ομάδα (59% των χρηστών). Το μοντέλο αποκάλυψε 4 κρυφές καταστάσεις που χαρτογραφούν την πορεία του χρήστη από την αρχική σελίδα προς τα αξιοθέατα, και τελικά προς αγοραστικές ενέργειες, όπως η εύρεση διαμονής (Accommodation) ή τοπικών εμπειριών (Experiences).

3.1.2 Μεθοδολογία

Η μεθοδολογία του άρθρου επικεντρώνεται στο πώς θα επιλεγεί το βέλτιστο MHMM. Όταν δεν υπάρχει εκ των προτέρων γνώση για τα δεδομένα, η επιλογή βασίζεται συνήθως σε παραδοσιακά κριτήρια, όπως το BIC. Ωστόσο, τέτοιου είδους κριτήρια δεν λαμβάνουν υπόψη τον βαθμό διαχωρισμού μεταξύ των λανθανουσών κλάσεων (δηλαδή των διαφορετικών προφίλ που προκύπτουν).

Για την αντιμετώπιση αυτού του προβλήματος, οι συγγραφείς βασίστηκαν στην προσέγγιση της Ολοκληρωμένης Συμπληρωμένης Πιθανοφάνειας (Integrated Completed Likelihood - ICL). Το νέο κριτήριο, BIC_H , λειτουργεί ως μια προσέγγιση του ICL, χρησιμοποιώντας τη βάση του BIC αλλά «ποινικοποιώντας» το μοντέλο με γνώμονα την **εντροπία**.

Ο τύπος του BIC_H συνδυάζει μαθηματικά τρία στοιχεία:

1. **Την παρατηρούμενη λογαριθμική πιθανοφάνεια (log-likelihood):** Αξιολογεί τον βαθμό προσαρμογής του μοντέλου, δηλαδή το πόσο καλά το μοντέλο εξηγεί τα παρατηρούμενα δεδομένα.
2. **Μια συνολική ποινή εντροπίας:** Προστίθεται για να «τιμωρήσει» την αβεβαιότητα στην ταξινόμηση των χρηστών, εξασφαλίζοντας τον βέλτιστο διαχωρισμό τους. Η ποινή αυτή αποτελείται από δύο επίπεδα: την εντροπία που σχετίζεται με τον αριθμό των συστάδων (δηλαδή πόσο αβέβαιο είναι το μοντέλο για το σε ποιο cluster ανήκει ο χρήστης) και την εντροπία που σχετίζεται με τις κρυφές καταστάσεις (αβεβαιότητα για την ακριβή αλληλουχία των προθέσεων του).
3. **Τους βαθμούς ελευθερίας:** Λειτουργεί ως ποινή για την πολυπλοκότητα του μοντέλου, λαμβάνοντας υπόψη τον αριθμό των παρατηρήσεων, τις υπολογιζόμενες παραμέτρους, και τυχόν σταθερές στον χρόνο συμμεταβλητές που επηρεάζουν την πιθανότητα ένταξης σε μια ομάδα, όπως για παράδειγμα η γεωγραφική περιοχή ή η συσκευή πρόσβασης του χρήστη.

Τέλος, η εκτίμηση των παραμέτρων (εκπαίδευση) του μοντέλου πραγματοποιήθηκε μέσω του γνωστού αλγορίθμου Expectation-Maximization (EM).

3.1.3 Συμπεράσματα

Το άρθρο συμπεραίνει ότι η χρήση κριτηρίων που βασίζονται στην εντροπία, όπως το BIC_H , είναι πολύ πιο αποτελεσματική από τα παραδοσιακά κριτήρια όταν αναλύονται σύντομες ακολουθίες, οι οποίες αποτελούν τον κανόνα στα δεδομένα clickstream.

Η ενσωμάτωση της εντροπίας επιτρέπει στο μοντέλο να επιλέγει διαμορφώσεις με τον καλύτερο δυνατό διαχωρισμό τόσο μεταξύ των διαφορετικών προφίλ χρηστών όσο και μεταξύ των κρυφών προθέσεων κάθε χρήστη. Πρακτικά, η εφαρμογή αυτών των μοντέλων μπορεί να προσφέρει σε επιχειρήσεις ηλεκτρονικού εμπορίου πολύτιμες γνώσεις για τη στρατηγική τους. Αυτό συμβαίνει διότι τα MHMMs αποκαλύπτουν όχι μόνο το τι κάνουν οι χρήστες (δηλαδή τις παρατηρούμενες καταστάσεις), αλλά και τους πιθανούς λόγους για τους οποίους πλοηγούνται με έναν συγκεκριμένο τρόπο (δηλαδή τις κρυφές καταστάσεις).

3.2 Real-time user clickstream behavior analysis based on apache storm streaming

[3]

3.2.1 Σκοπός της Έρευνας

Ο κύριος σκοπός αυτού του άρθρου είναι η ανάπτυξη ενός ολοκληρωμένου συστήματος για την ανάλυση της συμπεριφοράς και των προθέσεων των καταναλωτών σε πλατφόρμες ηλεκτρονικού εμπορίου σε πραγματικό χρόνο. Η έρευνα αυτή υποκινείται από τους περιορισμούς των παραδοσιακών συστημάτων προτάσεων, τα οποία βασίζονται κυρίως σε στατική, εκτός-σύνδεσης ανάλυση ιστορικών δεδομένων, αποτυγχάνοντας έτσι να προσαρμοστούν στις άμεσες μεταβολές του ενδιαφέροντος του χρήστη κατά τη διάρκεια μιας ενεργής συνεδρίας.

Εστιάζοντας στα δεδομένα clickstream που δημιουργούνται κατά τη πλοήγηση, οι συγγραφείς επιδιώκουν να χαρτογραφήσουν τα μοτίβα συμπεριφοράς και την τρέχουσα πρόθεση αναζήτησης του καταναλωτή. Απώτερος στόχος είναι η άμεση πρόβλεψη των επόμενων κινήσεων του χρήστη, η εξατομίκευση των προτάσεων προϊόντων την ακριβή στιγμή της περιήγησης και η δυναμική συσταδοποίηση των πελατών, επιτυγχάνοντας τη βέλτιστη δυνατή απόδοση της υποδομής με ελάχιστη καθυστέρηση κατά την επεξεργασία.

3.2.2 Μεθοδολογία

Η μεθοδολογία αξιοποιεί την αρχιτεκτονική Lambda (Lambda Architecture) για να γεφυρώσει την ανάλυση ιστορικών παρτίδων δεδομένων (batch processing μέσω Apache Hadoop) με τη ζωντανή επεξεργασία ροών. Για την επίτευξη χαμηλής καθυστέρησης, τα δεδομένα clickstream συλλέγονται απευθείας από τον browser του χρήστη και περνούν από μια αλυσίδα εργαλείων Big Data που περιλαμβάνει την υποδοχή τους από το Apache Kafka, την επεξεργασία τους από το Apache Storm, και τελικά την αποθήκευσή τους στη βάση δεδομένων Cassandra, επιτρέποντας την άμεση ανταπόκριση του συστήματος.

Η αναλυτική διαδικασία βασίζεται σε τρεις κεντρικούς άξονες:

1. **Εξόρυξη Μοτίβων (Pattern Mining):** Αρχικά, εξάγονται αλληλουχίες N-grams (μήκους 2 έως 7 κλικ) για να ανακαλυφθούν τα πιο συχνά μονοπάτια πλοήγησης μέσα στο site. Στη συνέχεια, εφαρμόζεται η μέθοδος Collocation μέσω του στατιστικού ελέγχου T-Test. Αυτό επιτρέπει στο σύστημα να συγκρίνει διαφορετικούς πληθυσμούς (π.χ. χρήστες που εξετάζουν ακριβά έναντι φθηνών προϊόντων) και να διαπιστώσει εάν οι διαδρομές που ακολουθούν διαφέρουν στατιστικά σημαντικά.
2. **Συσταδοποίηση:** Η τμηματοποίηση των χρηστών πραγματοποιείται με τη βοήθεια του αλγορίθμου EM σε συνδυασμό με Gaussian Mixture Models (GMM). Μέσω αυτής της προσέγγισης, ο κάθε χρήστης κατατάσσεται στοχαστικά σε συστάδες, αναγνωρίζοντας

ότι δεν ανήκει απόλυτα σε μία μόνο κατηγορία, αλλά μπορεί να εμπίπτει σε πολλαπλά αγοραστικά προφίλ ταυτόχρονα, με διαφορετικό βαθμό πιθανότητας στο καθένα.

3. **Πρόβλεψη επόμενου κλικ:** Χρησιμοποιούνται Μαρκοβιανές Αλυσίδες υψηλότερης τάξης (higher-order Markov Chains). Το σύστημα δημιουργεί πίνακες πιθανοτήτων μετάβασης που εξετάζουν το δυναμικό ιστορικό των k πιο πρόσφατων καταστάσεων του χρήστη (π.χ. «Προβολή Προϊόντος» → «Προσθήκη στο Καλάθι»), ώστε να υπολογίσουν μαθηματικά ποια θα είναι η πιο πιθανή επόμενη κίνησή του.

3.2.3 Συμπεράσματα

Συνοψίζοντας, η συγκεκριμένη μελέτη καταδεικνύει ότι η ανάλυση του ψηφιακού αποτυπώματος (clickstream) των πελατών σε σχεδόν πραγματικό χρόνο (near real-time) μπορεί να προσφέρει σημαντικό ανταγωνιστικό πλεονέκτημα, εφόσον υποστηρίζεται από την κατάλληλη υποδομή Big Data. Οι συγγραφείς απέδειξαν ότι η εφαρμογή της αρχιτεκτονικής Λάμδα, η οποία συνδυάζει το Apache Kafka για τη σύλληψη δεδομένων και το Apache Storm για την επεξεργασία τους, επιτρέπει την αποτελεσματική εξαγωγή πληροφορίας, όπως συχνά μοτίβα πλοήγησης (n-grams) και πίνακες συν-εμφάνισης.

Επιπροσθέτως, η έρευνα ανέδειξε την πρακτική αξία του συνδυασμού προηγμένων αλγορίθμων μηχανικής μάθησης. Συγκεκριμένα, η δυναμική τμηματοποίηση των χρηστών (μέσω K-Means και Expectation-Maximization) και η πρόβλεψη των μελλοντικών τους κινήσεων (αξιοποιώντας Μαρκοβιανές Αλυσίδες Υψηλής Τάξης) καθιστούν εφικτή την παροχή εξαιρετικά στοχευμένων προτάσεων. Όσον αφορά την αποδοτικότητα της υποδομής, η χρήση της βάσης δεδομένων Cassandra, σε συνδυασμό με τεχνικές βελτιστοποίησης για εγκαταστάσεις σε πολλαπλά κέντρα δεδομένων, εξασφάλισε απαντήσεις με ελάχιστη καθυστέρηση. Η απόδοση αυτή επιβεβαιώθηκε πειραματικά μέσω μετρικών στο Microsoft Azure HDInsight cluster.

3.3 Pattern2Vec: Representation of clickstream data sequences for learning user navigational behavior [2]

3.3.1 Σκοπός της έρευνας

Σκοπός της εργασίας ήταν η ανάπτυξη μιας νέας μεθόδου αναπαράστασης δεδομένων πλοήγησης χρηστών (clickstream), με την ονομασία Pattern2Vec, με στόχο την αποτελεσματικότερη κατανόηση της συμπεριφοράς των χρηστών κατά την πλοήγησή τους σε ιστοσελίδες. Το βασικό πρόβλημα που αντιμετωπίζεται είναι ότι οι ακολουθίες URLs αποτελούν μη αριθμητικά και μη δομημένα δεδομένα, τα οποία δεν μπορούν να αξιοποιηθούν άμεσα από αλγορίθμους μηχανικής μάθησης. Για τον λόγο αυτό, προτείνεται η μετατροπή των ακολουθιών πλοήγησης σε διανυσματικές αναπαραστάσεις (embeddings), οι οποίες αποτυπώνουν το σημασιολογικό περιεχόμενο και το πλαίσιο εμφάνισης των URLs. Με τον τρόπο αυτό καθίσταται δυνατή η εφαρμογή τεχνικών μη επιβλεπόμενης μάθησης, όπως η ομαδοποίηση (clustering), για την αναγνώριση προτύπων συμπεριφοράς. Τα αποτελέσματα έδειξαν ότι η προτεινόμενη μέθοδος υπερτερεί έναντι υπαρχουσών προσεγγίσεων, όπως οι Word2Vec, DeepWalk και Node2Vec. Συγκεκριμένα, παρουσίασε υψηλότερες επιδόσεις σε μετρικές αξιολόγησης ομαδοποίησης, όπως το v-score, η ομοιογένεια (homogeneity) και η πληρότητα (completeness), επιτυγχάνοντας ποσοστά που προσεγγίζουν το 95 τοις εκατό. Επιπλέον, τα παραγόμενα clusters εμφανίζουν μεγαλύτερη συνοχή και καλύτερο διαχωρισμό.

3.3.2 Μεθοδολογία

Αρχικά, συλλέχθηκαν δεδομένα clickstream από πραγματική ιστοσελίδα του ηλεκτρονικού εμπορίου. Στη συνέχεια πραγματοποιήθηκε η προεπεξεργασία δεδομένων, η οποία περιλάμβανε καθαρισμό (data cleansing), απομάκρυνση ελλιπών εγγράφων, καθώς και κανονικοποίηση των URLs μέσω κανονικών εκφράσεων, ώστε να αντιστοιχιστούν σε γενικότερες κατηγορίες. Έπειτα, τα δεδομένα οργανώθηκαν σε συνεδρίες πλοήγησης (sessions), λαμβάνοντας υπόψη χρονικούς περιορισμούς, όπως το μέγιστο χρονικό διάστημα μεταξύ διαδοχικών ενεργειών. Με αυτόν τον τρόπο εξασφαλίστηκε ότι οι ακολουθίες αντανακλούν την ρεαλιστική συμπεριφορά χρηστών. Στη συνέχεια, εφαρμόστηκε η εξόρυξη προτύπων (pattern mining) με αλγορίθμους όπως ο PrefixSpan και ο FPGrowth, με στόχο την αναγνώριση συχνών και λανθανόντων (hidden) προτύπων πλοήγησης. Παράλληλα, πραγματοποιήθηκε φιλτράρισμα για την απομάκρυνση πλεοναζόντων ή επικαλυπτόμενων προτύπων. Το κύριο στάδιο της μεθοδολογίας είναι η εφαρμογή της Pattern2Vec. Η μέθοδος βασίζεται σε διανυσματικές αναπαραστάσεις τύπου Word2Vec, αλλά διαφοροποιείται στο ότι εισάγει μηχανισμό στάθμισης των χαρακτηριστικών. Συγκεκριμένα, αξιοποιεί τον νόμο του Zipf, ώστε κάθε URL να συνεισφέρει διαφορετικά στο τελικό διάνυσμα, ανάλογα με τη συχνότητα εμφάνισης και τη θέση του μέσα στο πρότυπο. Με αυτόν τον τρόπο αποδίδεται μεγαλύτερη σημασία στα πιο αντιπροσωπευτικά στοιχεία της ακολουθίας. Τέλος, εφαρμόστηκαν τεχνικές μη επιβλεπόμενης μάθησης, όπως ο αλγόριθμος K-Means και η ιεραρχική ομαδοποίηση (Agglomerative Clustering), για την αξιολόγηση της ποιότητας των παραγόμενων αναπαραστάσεων. Η αξιολόγηση βασίστηκε σε μετρικές ομαδοποίησης, καθώς και σε τεχνικές οπτικοποίησης, όπως το t-SNE.

3.3.3 Συμπεράσματα

Συνοψίζοντας, η εργασία καταδεικνύει ότι η Pattern2Vec αποτελεί μια πιο αποδοτική μέθοδο αναπαράστασης δεδομένων clickstream σε σύγκριση με τις υπάρχουσες προσεγγίσεις. Η βασική καινοτομία της έγκειται στην ενσωμάτωση της σχετικής σημασίας και της θέσης των URLs στη διαδικασία δημιουργίας των embeddings. Η προσέγγιση αυτή οδηγεί σε μία βελτιωμένη ποιότητα ομαδοποίησης, με πιο διακριτά και ερμηνεύσιμα σύνολα δεδομένων. Επιπλέον, η μέθοδος μπορεί να εφαρμοστεί σε πρακτικά σενάρια, όπως η ανάλυση διοχέτευσης χρηστών (funnel analysis) και η αυτοματοποίηση δοκιμής διεπαφής λογισμικού. Τέλος, προτείνονται κατευθύνσεις για μελλοντική έρευνα, όπως η ανάπτυξη μηχανισμών κατάταξης προτύπων και η εφαρμογή της μεθόδου σε άλλα είδη ακολουθιακών δεδομένων, γεγονός που υποδεικνύει τη δυναμική επέκτασης αυτής της προσέγγισης.

3.4 Exclusive Item Recommendation to the Online Shopping Customers Based on Category Using Clickstream and UID Matrix, 2023 [4]

3.4.1 Σκοπός της έρευνας

Ο βασικός στόχος της συγκεκριμένης έρευνας είναι η ανάπτυξη ενός πιο ακριβούς και εξατομικευμένου συστήματος συστάσεων προϊόντων για online αγορές, αξιοποιώντας clickstream δεδομένα και το ιστορικό αγορών των χρηστών. Σε αντίθεση με πολλές υπάρχουσες προσεγγίσεις που βασίζονται κυρίως σε ratings ή απλά clicks, η συγκεκριμένη εργασία δίνει έμφαση στη πραγματική αγοραστική συμπεριφορά του χρήστη. Οι βασικοί σκοποί της μελέτης είναι η εξής: η ανάλυση της συμπεριφοράς των χρηστών μέσα από clickstream δεδομένα, η ταξινόμηση των χρηστών σε τρεις διαφορετικές κατηγορίες που είναι Regular, Special και Exceptional, η δημιουργία ενός πιο πλούσιου User-Item-Detail matrix που ενσωματώνει πολλαπλά χαρακτηριστικά συμπεριφοράς και η παροχή

εξατομικευμένων και αποκλειστικών προτάσεων προϊόντων για κάθε κατηγορία χρηστών με στόχο τη βελτίωση της εμπειρίας αγορών και την αύξηση των πωλήσεων.

3.4.2 Μεθοδολογία

Η προτεινόμενη μεθοδολογία UID-KNN αποτελείται από τέσσερα βασικά στάδια που συνδυάζουν τεχνικές επεξεργασίας δεδομένων, μηχανικής μάθησης και συστημάτων συστάσεων. Αρχικά πραγματοποιείται η προεπεξεργασία των clickstream δεδομένων. Σε αυτό το στάδιο γίνεται καθαρισμός των δεδομένων, η αναγνώριση μοναδικών χρηστών μέσω user ID ή IP διεύθυνσης, καθώς και ο διαχωρισμός των sessions με βάση τη χρονική δραστηριότητα του χρήστη. Επιπλέον γίνεται path completion ώστε να ανακατασκευαστούν ελλιπείς διαδρομές πλοήγησης και να αποτυπωθεί πιο σωστά η συμπεριφορά του χρήστη. Στη συνέχεια εφαρμόζεται ο αλγόριθμος K-Nearest Neighbors για την ταξινόμηση των χρηστών. Η ταξινόμηση δεν βασίζεται απλά στο browsing behavior αλλά κυρίως στο ιστορικό αγορών. Οι χρήστες χωρίζονται σε τρεις κατηγορίες που είναι Regular, Special και Exceptional, με βάση χαρακτηριστικά όπως χρόνος παραμονής σε προϊόντα, αριθμός clicks, προσθήκη στο καλάθι, wishlist και ολοκλήρωση αγοράς. Η ομοιότητα μεταξύ χρηστών υπολογίζεται με Ευκλείδεια απόσταση. Έπειτα κατασκευάζεται το User-Item-Detail matrix, το οποίο αποτελεί μια πιο αναλυτική μορφή αναπαράστασης δεδομένων σε σχέση με το κλασικό user-item matrix. Ο πίνακας αυτός περιλαμβάνει χαρακτηριστικά όπως την βαθμολογία προϊόντος, τον χρόνο θέασης, τον αριθμό επισκέψεων στη σελίδα προϊόντος, την προσθήκη στο καλάθι, την προσθήκη στη wishlist και την τελική αγορά. Με βάση αυτά τα δεδομένα δημιουργούνται τρεις ξεχωριστοί πίνακες UID για κάθε κατηγορία χρηστών, ώστε να υπάρχει πιο στοχευμένη ανάλυση και καλύτερη εξατομίκευση. Τέλος εφαρμόζεται ο μηχανισμός συστάσεων που προτείνει τα top-N προϊόντα σε κάθε κατηγορία χρηστών. Οι προτάσεις βασίζονται τόσο στη συμπεριφορά του χρήστη όσο και στη συσχέτιση μεταξύ χρηστών και προϊόντων μέσα από το collaborative filtering approach. Για την αξιολόγηση της μεθόδου χρησιμοποιούνται τα metrics MAE και RMSE για την ακρίβεια των προβλέψεων, καθώς και το Precision, Recall και F-measure για την ποιότητα των προτάσεων.

3.4.3 Συμπεράσματα

Τα αποτελέσματα της έρευνας δείχνουν ότι η προτεινόμενη μέθοδος UID-KNN παρουσιάζει καλύτερη απόδοση σε σχέση με υπάρχουσες προσεγγίσεις που βασίζονται μόνο σε item ratings ή απλό user-item matrix. Συγκεκριμένα, επιτυγχάνει χαμηλότερες τιμές MAE και RMSE, κάτι που δείχνει πιο ακριβείς προβλέψεις και μικρότερο σφάλμα στο σύστημα συστάσεων. Επιπλέον, η ταξινόμηση των χρηστών σε τρεις διαφορετικές κατηγορίες συμβάλλει σημαντικά στη βελτίωση της ποιότητας των προτάσεων, καθώς επιτρέπει την πιο στοχευμένη και εξατομικευμένη παροχή προϊόντων. Το σύστημα καταφέρνει να προσαρμόζει τις προτάσεις με βάση το προφίλ και τη συμπεριφορά κάθε χρήστη, κάτι που βελτιώνει συνολικά την εμπειρία του online shopping. Συνολικά, η μελέτη αποδεικνύει ότι η χρήση clickstream δεδομένων σε συνδυασμό με την ταξινόμηση των χρηστών και το εμπλουτισμένο UID matrix μπορεί να βελτιώσει σημαντικά την απόδοση των recommender systems. Ως μελλοντική εργασία προτείνεται η ενσωμάτωση τεχνικών deep learning για ακόμη πιο ακριβή και δυναμικά συστήματα προτάσεων.

4 Μετέπειτα Εργασίες

5 Σύνοψη και συμπεράσματα

References

- [1] Ramanna Hanamanthrao and Thejaswini S. Real-time clickstream data analytics and visualization. In *2017 2nd IEEE International Conference on Recent Trends in Electronics Information & Communication Technology (RTEICT)*, pages 2139–2144, May 2017.
- [2] Erdi Olmezogullari and Mehmet S. Aktas. Pattern2vec: Representation of clickstream data sequences for learning user navigational behavior. 2022.
- [3] Gautam Pal, Katie Atkinson, and Gangmin Li. Real-time user clickstream behavior analysis based on apache storm streaming. 2023.
- [4] R. Suguna, P. Sathishkumar, and S. Deepa. Exclusive item recommendation to the online shopping customers based on category using clickstream and uid matrix. In *Computer Networks and Inventive Communication Technologies*, pages 177–190. Springer, 2023.
- [5] Furio Urso, Antonino Abbruzzo, Marcello Chiodi, and Maria Francesca Cracolici. Model selection for mixture hidden markov models: an application to clickstream data. 2024.
- [6] Gang Wang, Xinyi Zhang, Shiliang Tang, Christo Wilson, Haitao Zheng, and Ben Y. Zhao. Clickstream user behavior models. *ACM Transactions on the Web*, 11(4):21:1–21:37, 2017.