



ΠΑΝΕΠΙΣΤΗΜΙΟ
ΠΑΤΡΩΝ
UNIVERSITY OF PATRAS

Πολυτεχνική Σχολή

Τμήμα Μηχανικών Η/Υ & Πληροφορικής

ΕΞΟΥΥΞΗ ΔΕΔΟΜΕΝΩΝ ΚΑΙ ΜΗΧΑΝΙΚΗ ΜΑΘΗΣΗ

Αναφορά βασισμένη στην ανάλυση Clickstream Δεδομένων

Γεωργία Μυλωνά

A.M. 1104783

Δημήτριος Φιλόπουλος

A.M. 1101130

Πάτρα, 2026

Contents

1	Εισαγωγή	3
1.1	Πλαίσιο και Κίνητρο της Έρευνας	3
1.2	Προκλήσεις και Μεθοδολογική Εξέλιξη στη Βιβλιογραφία	3
1.3	Σκοπός και Δομή της Αναφοράς	3
2	Προηγούμενες σχετικές μελέτες	4
2.1	Mixture Hidden Markov Models για Clickstream Δεδομένα	4
2.2	Real-time ανάλυση clickstream δεδομένων	4
3	Βασική ανάλυση	5
3.1	Model selection for mixture hidden Markov models: an application to click-stream data	5
3.1.1	Σκοπός της Έρευνας	5
3.1.2	Μεθοδολογία	6
3.1.3	Συμπεράσματα	7
3.2	Real-time user clickstream behavior analysis based on apache storm streaming	7
3.2.1	Σκοπός της Έρευνας	7
3.2.2	Μεθοδολογία	7
3.2.3	Συμπεράσματα	8
3.3	Pattern2Vec: Representation of clickstream data sequences for learning user navigational behavior	8
3.3.1	Σκοπός της έρευνας	8
3.3.2	Μεθοδολογία	9
3.3.3	Συμπεράσματα	9
3.4	Exclusive Item Recommendation to the Online Shopping Customers Based on Category Using Clickstream and UID Matrix, 2023	10
3.4.1	Σκοπός της έρευνας	10
3.4.2	Μεθοδολογία	10
3.4.3	Συμπεράσματα	10
4	Μετέπειτα Εργασίες	11
4.1	Mining and Predicting Users Clickstream Patterns from Noisy Interleaving Clicks	11
4.2	Clickstream user behavior models	11
4.3	Real-time clickstream data analytics and visualization	12
4.4	Intent-Aware Clickstream Analytics with Explainable AI: A Scalable Data Engineering Framework	13
4.5	Predicting online shopping behaviour from clickstream data using deep learning	13
4.6	Efficient Long Sequential User Data Modeling for Click-Through Rate Prediction	14
4.7	ClickstreamGPT: a transformer-based generative AI approach to clickstream prediction for E-commerce platforms	14
4.8	Clickstream user behavior clustering using graph time series	15
4.9	Understanding consumers' online browsing patterns and influence of marketing stimuli: A two-layer sequence analysis approach	15

5	Σύνοψη και συμπεράσματα	16
5.1	Deep learning & sequential prediction	16
5.2	MHMM & Sequence modeling	17
5.3	Real-Time Streaming & ETL Υποδομές	17

1 Εισαγωγή

1.1 Πλαίσιο και Κίνητρο της Έρευνας

Η ραγδαία ανάπτυξη του ηλεκτρονικού εμπορίου και των ψηφιακών πλατφορμών έχει οδηγήσει στην παραγωγή τεράστιου όγκου δεδομένων που αφορούν την αλληλεπίδραση των χρηστών με το διαδικτυακό περιβάλλον. Κεντρική πηγή αυτής της πληροφορίας αποτελούν τα δεδομένα clickstream, τα οποία καταγράφουν με ακρίβεια τις αλληλουχίες των ενεργειών (κλικ, προβολές σελίδων, χρονικές σημάνσεις) ενός επισκέπτη κατά τη διάρκεια μιας συνεδρίας (session).

Η επιχειρησιακή και ερευνητική αξία της ανάλυσης clickstream είναι θεμελιώδης, καθώς επιτρέπει την κατανόηση της αγοραστικής πρόθεσης των καταναλωτών, την παροχή προσωποποιημένων συστάσεων προϊόντων σε πραγματικό χρόνο, τη βελτιστοποίηση της αρχιτεκτονικής των ιστοτόπων, καθώς και την έγκαιρη ανίχνευση κακόβουλων συμπεριφορών. Για τον λόγο αυτό, η επιστημονική κοινότητα έχει αναπτύξει πληθώρα προσεγγίσεων, επιστρατεύοντας εργαλεία από τα πεδία της Εξόρυξης Δεδομένων και της Μηχανικής Μάθησης.

1.2 Προκλήσεις και Μεθοδολογική Εξέλιξη στη Βιβλιογραφία

Η ανάλυση των δεδομένων πλοήγησης παρουσιάζει σημαντικές ερευνητικές προκλήσεις που καθιστούν αναγκαία τη συνεχή εξέλιξη των προτεινόμενων μοντέλων. Τα δεδομένα αυτά είναι εγγενώς μη δομημένα και μη αριθμητικά, ενώ επιβαρύνονται συχνά από σημαντικό θόρυβο, τυχαίες ενέργειες και ασυνέχειες. Επιπλέον, οι αναλυτές καλούνται να εξάγουν συμπεράσματα για λανθάνουσες ψυχολογικές καταστάσεις και κίνητρα των χρηστών, βασιζόμενοι αποκλειστικά σε επιφανειακές καταγραφές κλικ. Παράλληλα, οι σύγχρονες βιομηχανικές απαιτήσεις επιβάλλουν τη μετατόπιση από τη στατική ανάλυση ιστορικού στην επεξεργασία ροών σε πραγματικό χρόνο με ελάχιστη υπολογιστική καθυστέρηση.

Για την αντιμετώπιση αυτών των προκλήσεων, η βιβλιογραφία έχει παρουσιάσει μια αξιοσημείωτη μεθοδολογική εξέλιξη, η οποία εκτείνεται σε τέσσερις κύριους άξονες:

- **Στατιστικά και Πιθανοτικά Μοντέλα:** Χρήση Μαρκοβιανών αλυσίδων και Mixture Hidden Markov Models (MHMMs) για την αποτύπωση των κρυφών καταστάσεων πλοήγησης.
- **Embeddings:** Εφαρμογή τεχνικών όπως το Pattern2Vec για τη μετατροπή των αλληλουχιών URL σε δομημένα διανύσματα με σημασιολογικό περιεχόμενο.
- **Big Data Streaming:** Αξιοποίηση συστημάτων όπως το Apache Storm και το Apache Spark Streaming για τη δυναμική συσταδοποίηση και πρόβλεψη σε πραγματικό χρόνο.
- **Μοντέλα Βαθιάς Μάθησης και Generative AI:** Σύγχρονη στροφή σε Recurrent Neural Networks (RNNs) και αρχιτεκτονικές Transformers (ClickstreamGPT) για τη μοντελοποίηση της συμπεριφοράς ως μορφή γλώσσας.

1.3 Σκοπός και Δομή της Αναφοράς

Σκοπός της παρούσας αναφοράς είναι η διεξαγωγή μιας εις βάθος βιβλιογραφικής επισκόπησης, εστιάζοντας στην ανάλυση, τη σύγκριση και τη σύνθεση αντιπροσωπευτικών επιστημονικών άρθρων.

Η αναφορά είναι οργανωμένη ως εξής:

- Στην Ενότητα 2 παρουσιάζεται το γενικότερο θεωρητικό υπόβαθρο της σχετικής βιβλιογραφίας.

- Στην Ενότητα 3 πραγματοποιείται η βασική ανάλυση τεσσάρων θεμελιωδών ερευνητικών εργασιών, εξετάζοντας τον σκοπό, τη μεθοδολογία και τα συμπεράσματά τους.
- Στην Ενότητα 4 επεκτείνεται η μελέτη μέσω της εξέτασης μεταγενέστερων, σύγχρονων εργασιών και εξελίξεων (state-of-the-art).
- Τέλος, στην Ενότητα 5 πραγματοποιείται η συγκριτική αξιολόγηση και η σύνθεση των μοντέλων, αναδεικνύοντας τα κυριότερα συμπεράσματα και τις μελλοντικές ερευνητικές κατευθύνσεις.

2 Προηγούμενες σχετικές μελέτες

Η μελέτη της βιβλιογραφίας γύρω από τα clickstream δεδομένα δείχνει ότι το συγκεκριμένο πεδίο έχει αναπτυχθεί σε πολλαπλές κατευθύνσεις, οι οποίες περιλαμβάνουν τη μοντελοποίηση της συμπεριφοράς των χρηστών, την ανάλυση ροών δεδομένων σε πραγματικό χρόνο, την αναγνώριση προτύπων πλοήγησης και την αξιοποίηση των ακολουθιών κλικ για τη λήψη αποφάσεων. Οι προηγούμενες σχετικές εργασίες είναι ιδιαίτερα σημαντικές, διότι προσφέρουν το θεωρητικό και μεθοδολογικό υπόβαθρο πάνω στο οποίο στηρίζεται η παρούσα μελέτη. Μέσα από αυτές καθίσταται σαφές ότι τα clickstream δεδομένα δεν αποτελούν απλώς ένα σύνολο διαδοχικών ενεργειών, αλλά μια πλούσια πηγή πληροφορίας για την ερμηνεία της συμπεριφοράς των χρηστών σε ψηφιακά περιβάλλοντα.

2.1 Mixture Hidden Markov Models για Clickstream Δεδομένα

Η έννοια των sequence data είναι κεντρική στη μελέτη διακριτών διαχρονικών ακολουθιών, όπου κάθε παρατήρηση αντιστοιχεί σε μία κατάσταση από πεπερασμένο σύνολο δυνατών τιμών. Στο πλαίσιο αυτό, τα Hidden Markov Models (HMMs) χρησιμοποιούνται για να περιγράψουν τις παρατηρούμενες ακολουθίες ως στοχαστικές συναρτήσεις λανθανουσών καταστάσεων, οι οποίες δεν παρατηρούνται άμεσα αλλά επηρεάζουν την εξέλιξη των δεδομένων [6]. Ένα βασικό πλεονέκτημα των HMMs είναι ότι επιτρέπουν τη συμπύκνωση πληροφορίας σε ένα ερμηνεύσιμο probabilistic framework, ενώ παραμένουν κατάλληλα για την ανάλυση πολλαπλών ακολουθιών με κοινή λανθάνουσα δομή. Στην περίπτωση multichannel δεδομένων, η ίδια hidden process μπορεί να συνδέεται με περισσότερες από μία παρατηρούμενες ακολουθίες ανά υποκείμενο, κάτι που καθιστά το μοντέλο ιδιαίτερα χρήσιμο σε σύνθετα longitudinal settings [6].

Η επέκταση σε MHMMs επιτρέπει επιπλέον τη δημιουργία latent clusters, έτσι ώστε οι ακολουθίες να ομαδοποιούνται σε πιο ομοιογενείς υποομάδες κατά τη διάρκεια της εκτίμησης, αντί να προεπιλέγονται εκ των προτέρων [6]. Με αυτόν τον τρόπο, τα MHMMs συνδυάζουν τη δυναμική των HMMs με τη λογική της model-based clustering, προσφέροντας ένα ενιαίο πλαίσιο για ανάλυση, ταξινόμηση και ερμηνεία sequence data. Η επιλογή του κατάλληλου αριθμού hidden states και clusters παραμένει κρίσιμο ζήτημα, και συνήθως εξετάζεται με κριτήρια όπως το BIC ή το ICL, σε συνδυασμό με την ποιότητα της ταξινόμησης και τη σταθερότητα του μοντέλου [6, ?]. Για αυτόν τον λόγο, τα MHMMs αποτελούν μια φυσική προέκταση των κλασικών HMMs όταν ο στόχος δεν είναι μόνο η περιγραφή της ακολουθιακής δομής, αλλά και η ανάδειξη ετερογένειας μεταξύ των παρατηρούμενων μονάδων.

2.2 Real-time ανάλυση clickstream δεδομένων

Οι πρώτες προσεγγίσεις στην ανάλυση clickstream δεδομένων επικεντρώθηκαν κυρίως στην κατανόηση των διαδρομών πλοήγησης των χρηστών και στην ανάδειξη κοινών visitor paths

μέσα από ακολουθιακή ανάλυση. Σε αυτή την κατεύθυνση, οι Liu et al. [8] παρουσίασαν ένα διαδραστικό πλαίσιο για την εξερεύνηση clickstreams, με στόχο την καλύτερη ερμηνεία της συμπεριφοράς των χρηστών σε επίπεδο ακολουθιών. Η εργασία αυτή είναι σημαντική γιατί μετατρέπει τα raw click sequences σε πιο αναγνώσιμη και αναλύσιμη μορφή, θέτοντας τη βάση για μεταγενέστερες προσεγγίσεις που δεν περιορίζονται μόνο στην περιγραφή των δεδομένων, αλλά προχωρούν και σε πρόβλεψη ή online επεξεργασία.

Σε πιο εφαρμοσμένο επίπεδο, οι Pal et al. [11] επεκτείνουν αυτή τη λογική προς μια real-time αρχιτεκτονική επεξεργασίας clickstream δεδομένων, αξιοποιώντας Apache Storm, Kafka και Cassandra για streaming analytics. Σε αντίθεση με τις προηγούμενες προσεγγίσεις που δίνουν έμφαση κυρίως στην οπτικοποίηση ή στη batch ανάλυση, το συγκεκριμένο έργο στοχεύει στη near real-time εξαγωγή συμπερασμάτων από τη συμπεριφορά των χρηστών, όπως browsing motifs, recently viewed products και customer segmentation. Έτσι, η συμβολή του εντάσσεται φυσικά πάνω σε προηγούμενες εργασίες για clickstream exploration και sequence mining, αλλά προσθέτει το κρίσιμο στοιχείο της χαμηλής καθυστέρησης και της συνεχούς ροής δεδομένων [8, 11].

3 Βασική ανάλυση

3.1 Model selection for mixture hidden Markov models: an application to clickstream data

3.1.1 Σκοπός της Έρευνας

Ο κύριος σκοπός αυτού του άρθρου [13] είναι η εις βάθος ανάλυση δεδομένων clickstream μέσω της χρήσης Mixture Hidden Markov Models (MHMMs). Η ανάλυση αυτή αποσκοπεί στο να ξεπεράσει τους περιορισμούς των απλών αλγορίθμων ομαδοποίησης, οι οποίοι συχνά απαιτούν έναν μεγάλο και μη πρακτικό αριθμό συστάδων για να παράγουν ομοιογενείς ομάδες, επειδή εξετάζουν αποκλειστικά τις ορατές αλληλουχίες των σελίδων που επισκέπτονται οι χρήστες.

Τα MHMMs προσφέρουν μια ουσιαστικότερη προσέγγιση στην ομαδοποίηση των ακολουθιών πλοήγησης, καθώς δεν αντιμετωπίζουν τη συμπεριφορά των χρηστών ως μια απλή, τυχαία σειρά από κλικ. Αντιθέτως, βασίζονται στην υπόθεση ότι η πλοήγηση καθοδηγείται από μια μίξη λανθανουσών μαρκοβιανών διαδικασιών, καθεμία από τις οποίες αντιστοιχεί σε έναν διαφορετικό, άγνωστο υποπληθυσμό χρηστών. Αυτές οι διαδικασίες αποτυπώνουν τα λανθάνοντα κίνητρα των χρηστών, τα οποία αναφέρονται στη μελέτη ως «νοητικές» ή «κρυφές καταστάσεις» (mental / hidden states). Οι καταστάσεις αυτές υπαγορεύουν την πορεία του χρήστη μέσα στον ιστότοπο, προσαρμόζοντας τις επιλογές του ανάλογα με τον εκάστοτε στόχο του. Με αυτόν τον τρόπο, το μοντέλο καταφέρνει να αποκαλύψει υποκείμενα προφίλ συμπεριφοράς που δεν θα μπορούσαν να εντοπιστούν αποκλειστικά από την επιφανειακή καταγραφή των σελίδων.

Ωστόσο, η πρακτική εφαρμογή των MHMMs περιπλέκεται σημαντικά από την ανάγκη προσδιορισμού ενός άγνωστου, εκ των προτέρων, αριθμού τόσο των συστάδων όσο και αυτών των κρυφών καταστάσεων. Όταν τα δεδομένα αποτελούνται από σύντομες ακολουθίες, τα παραδοσιακά κριτήρια πληροφοριών αποτυγχάνουν να υποδείξουν τον σωστό αριθμό ομάδων, καθώς αγνοούν τον βαθμό διαχωρισμού μεταξύ των προφίλ των χρηστών.

Για να αντιμετωπίσουν αυτή την πρόκληση και να εντοπίσουν τον βέλτιστο διαχωρισμό των χρηστών, οι συγγραφείς ανέπτυξαν και πρότειναν ένα νέο κριτήριο επιλογής μοντέλου, το BIC_H . Το κριτήριο αυτό σχεδιάστηκε ειδικά για να επιλέγει μοντέλα που δεν προσαρμόζονται απλώς καλά στα παρατηρούμενα δεδομένα, αλλά ταυτόχρονα αξιολογούν την αβεβαιότητα της ταξινόμησης, προσφέροντας τελικά διακριτές και εύκολα ερμηνεύσιμες ομάδες χρηστών.

Όσον αφορά τα **αποτελέσματα**, η αξιολόγηση του προτεινόμενου κριτηρίου χωρίζεται σε δύο σκέλη:

- **Αξιολόγηση μέσω Monte Carlo προσομοιώσεων:** Οι συγγραφείς εξέτασαν την απόδοση του BIC_H έναντι των κλασικών κριτηρίων πληροφοριών (AIC , BIC και $ssBIC$) σε διάφορα σενάρια, μεταβάλλοντας το μήκος των ακολουθιών και τον αριθμό των δεδομένων. Αποδείχθηκε ότι σε ακολουθίες μικρού μήκους, γεγονός που αποτελεί τον κανόνα στα δεδομένα clickstream, το BIC_H έχει σημαντικά καλύτερη απόδοση στην ταυτόχρονη αναγνώριση του σωστού αριθμού συστάδων και καταστάσεων. Αντίθετα, τα κλασικά κριτήρια δυσκολεύονται έντονα και υποτιμούν συστηματικά τον αριθμό των συστάδων.
- **Εφαρμογή σε πραγματικά δεδομένα:** Κατά την ανάλυση των πραγματικών δεδομένων clickstream από τον ιστότοπο της εταιρείας φιλοξενίας "LovePanormus", το κριτήριο BIC_H επέλεξε ένα μοντέλο με 3 συστάδες (clusters) και (3, 2, 4) κρυφές καταστάσεις αντίστοιχα. Η επιλογή αυτή αποκάλυψε τρία διακριτά προφίλ χρηστών:
 1. **«Απλός επισκέπτης / πιθανός συνεργάτης» (Casual explorer / Potential partner):** Αποτελεί το 22% των χρηστών. Το μοντέλο εντόπισε 3 κρυφές καταστάσεις σε αυτό το προφίλ, οι οποίες αντιστοιχούν σε πλοήγηση στην αρχική σελίδα, σε γενική εξερεύνηση, και στην αναζήτηση πληροφοριών για την ίδια την εταιρεία.
 2. **«Αναζητητής πληροφοριών» (Information seeker):** Αποτελεί το 19% των χρηστών. Εδώ εντοπίστηκαν 2 κρυφές καταστάσεις, όπου οι χρήστες εστιάζουν αποκλειστικά σε τουριστικές πληροφορίες (αξιοθέατα) ή ακολουθούν μια μικτή πορεία προς τις τοπικές εκδηλώσεις, χωρίς να δείχνουν άμεση πρόθεση αγοράς υπηρεσιών.
 3. **«Πιθανός τουρίστας» (Potential tourist):** Είναι η μεγαλύτερη ομάδα (59% των χρηστών). Το μοντέλο αποκάλυψε 4 κρυφές καταστάσεις που χαρτογραφούν την πορεία του χρήστη από την αρχική σελίδα προς τα αξιοθέατα, και τελικά προς αγοραστικές ενέργειες, όπως η εύρεση διαμονής (Accommodation) ή τοπικών εμπειριών (Experiences).

3.1.2 Μεθοδολογία

Η μεθοδολογία του άρθρου επικεντρώνεται στο πώς θα επιλεγεί το βέλτιστο MHMM. Όταν δεν υπάρχει εκ των προτέρων γνώση για τα δεδομένα, η επιλογή βασίζεται συνήθως σε παραδοσιακά κριτήρια, όπως το BIC. Ωστόσο, τέτοιου είδους κριτήρια δεν λαμβάνουν υπόψη τον βαθμό διαχωρισμού μεταξύ των λανθανουσών κλάσεων (δηλαδή των διαφορετικών προφίλ που προκύπτουν).

Για την αντιμετώπιση αυτού του προβλήματος, οι συγγραφείς βασίστηκαν στην προσέγγιση της Integrated Completed Likelihood (ICL). Το νέο κριτήριο, BIC_H , λειτουργεί ως μια προσέγγιση του ICL, χρησιμοποιώντας τη βάση του BIC αλλά «ποινοικοποιώντας» το μοντέλο με γνώμονα την εντροπία.

Ο τύπος του BIC_H συνδυάζει μαθηματικά τρία στοιχεία:

1. **Την παρατηρούμενη λογαριθμική πιθανοφάνεια (log-likelihood):** Αξιολογεί τον βαθμό προσαρμογής του μοντέλου, δηλαδή το πόσο καλά το μοντέλο εξηγεί τα παρατηρούμενα δεδομένα.
2. **Μια συνολική ποινή εντροπίας:** Προστίθεται για να «τιμωρήσει» την αβεβαιότητα στην ταξινόμηση των χρηστών, εξασφαλίζοντας τον βέλτιστο διαχωρισμό τους. Η ποινή αυτή αποτελείται από δύο επίπεδα: την εντροπία που σχετίζεται με τον αριθμό των συστάδων

(δηλαδή πόσο αβέβαιο είναι το μοντέλο για το σε ποιο cluster ανήκει ο χρήστης) και την εντροπία που σχετίζεται με τις κρυφές καταστάσεις (αβεβαιότητα για την ακριβή αλληλουχία των προθέσεων του).

3. **Τους βαθμούς ελευθερίας:** Λειτουργεί ως ποινή για την πολυπλοκότητα του μοντέλου, λαμβάνοντας υπόψη τον αριθμό των παρατηρήσεων, τις υπολογιζόμενες παραμέτρους, και τυχόν σταθερές στον χρόνο συμμεταβλητές που επηρεάζουν την πιθανότητα ένταξης σε μια ομάδα, όπως για παράδειγμα η γεωγραφική περιοχή ή η συσκευή πρόσβασης του χρήστη.

Τέλος, η εκτίμηση των παραμέτρων (εκπαίδευση) του μοντέλου πραγματοποιήθηκε μέσω του γνωστού αλγορίθμου Expectation-Maximization (EM).

3.1.3 Συμπεράσματα

Το άρθρο συμπεραίνει ότι η χρήση κριτηρίων που βασίζονται στην εντροπία, όπως το BIC_H , είναι πολύ πιο αποτελεσματική από τα παραδοσιακά κριτήρια όταν αναλύονται σύντομες ακολουθίες, οι οποίες αποτελούν τον κανόνα στα δεδομένα clickstream.

Η ενσωμάτωση της εντροπίας επιτρέπει στο μοντέλο να επιλέγει διαμορφώσεις με τον καλύτερο δυνατό διαχωρισμό τόσο μεταξύ των διαφορετικών προφίλ χρηστών όσο και μεταξύ των κρυφών προθέσεων κάθε χρήστη. Πρακτικά, η εφαρμογή αυτών των μοντέλων μπορεί να προσφέρει σε επιχειρήσεις ηλεκτρονικού εμπορίου πολύτιμες γνώσεις για τη στρατηγική τους. Αυτό συμβαίνει διότι τα MHMMs αποκαλύπτουν όχι μόνο το τι κάνουν οι χρήστες (δηλαδή τις παρατηρούμενες καταστάσεις), αλλά και τους πιθανούς λόγους για τους οποίους πλοηγούνται με έναν συγκεκριμένο τρόπο (δηλαδή τις κρυφές καταστάσεις).

3.2 Real-time user clickstream behavior analysis based on apache storm streaming

3.2.1 Σκοπός της Έρευνας

Ο κύριος σκοπός αυτού του άρθρου [11], είναι η ανάπτυξη ενός ολοκληρωμένου συστήματος για την ανάλυση της συμπεριφοράς και των προθέσεων των καταναλωτών σε πλατφόρμες ηλεκτρονικού εμπορίου σε πραγματικό χρόνο. Η έρευνα αυτή υποκινείται από τους περιορισμούς των παραδοσιακών συστημάτων προτάσεων, τα οποία βασίζονται κυρίως σε στατική, εκτός-σύνδεσης ανάλυση ιστορικών δεδομένων, αποτυγχάνοντας έτσι να προσαρμοστούν στις άμεσες μεταβολές του ενδιαφέροντος του χρήστη κατά τη διάρκεια μιας ενεργής συνεδρίας.

Εστιάζοντας στα δεδομένα clickstream που δημιουργούνται κατά τη πλοήγηση, οι συγγραφείς επιδιώκουν να χαρτογραφήσουν τα μοτίβα συμπεριφοράς και την τρέχουσα πρόθεση αναζήτησης του καταναλωτή. Απώτερος στόχος είναι η άμεση πρόβλεψη των επόμενων κινήσεων του χρήστη, η εξατομίκευση των προτάσεων προϊόντων την ακριβή στιγμή της περιήγησης και η δυναμική συσταδοποίηση των πελατών, επιτυγχάνοντας τη βέλτιστη δυνατή απόδοση της υποδομής με ελάχιστη καθυστέρηση κατά την επεξεργασία.

3.2.2 Μεθοδολογία

Η μεθοδολογία αξιοποιεί την αρχιτεκτονική Lambda για να γεφυρώσει την ανάλυση ιστορικών παρτίδων δεδομένων (batch processing μέσω Apache Hadoop) με τη ζωντανή επεξεργασία ροών. Για την επίτευξη χαμηλής καθυστέρησης, τα δεδομένα συλλέγονται από το Apache

Kafka, την επεξεργασία τους από το Apache Storm, και τελικά την αποθήκευσή τους στη βάση δεδομένων Cassandra, επιτρέποντας την άμεση ανταπόκριση του συστήματος.

Η αναλυτική διαδικασία βασίζεται σε τρεις κεντρικούς άξονες:

1. **Εξόρυξη Μοτίφων:** Αρχικά, εξάγονται αλληλουχίες N-grams (μήκους 2 έως 7 κλικ) για να ανακαλυφθούν τα πιο συχνά μονοπάτια πλοήγησης μέσα στο site. Στη συνέχεια, εφαρμόζεται η μέθοδος Collocation μέσω του στατιστικού ελέγχου T-Test. Αυτό επιτρέπει στο σύστημα να συγκρίνει διαφορετικούς πληθυσμούς (π.χ. χρήστες που εξετάζουν ακριβά έναντι φθηνών προϊόντων) και να διαπιστώσει εάν οι διαδρομές που ακολουθούν διαφέρουν στατιστικά σημαντικά.
2. **Συσταδοποίηση:** Η τμηματοποίηση των χρηστών πραγματοποιείται με τη βοήθεια του αλγορίθμου EM σε συνδυασμό με Gaussian Mixture Models (GMM). Μέσω αυτής της προσέγγισης, ο κάθε χρήστης κατατάσσεται στοχαστικά σε συστάδες, αναγνωρίζοντας ότι δεν ανήκει απόλυτα σε μία μόνο κατηγορία, αλλά μπορεί να εμπίπτει σε πολλαπλά αγοραστικά προφίλ ταυτόχρονα, με διαφορετικό βαθμό πιθανότητας στο καθένα.
3. **Πρόβλεψη επόμενου κλικ:** Χρησιμοποιούνται Μαρκοβιανές Αλυσίδες υψηλότερης τάξης (higher-order Markov Chains). Το σύστημα δημιουργεί πίνακες πιθανοτήτων μετάβασης που εξετάζουν το δυναμικό ιστορικό των k πιο πρόσφατων καταστάσεων του χρήστη (π.χ. «Προβολή Προϊόντος» → «Προσθήκη στο Καλάθι»), ώστε να υπολογίσουν μαθηματικά ποια θα είναι η πιο πιθανή επόμενη κίνησή του.

3.2.3 Συμπεράσματα

Συνοψίζοντας, η συγκεκριμένη μελέτη καταδεικνύει ότι η ανάλυση του clickstream των πελατών σε σχεδόν πραγματικό χρόνο μπορεί να προσφέρει σημαντικό ανταγωνιστικό πλεονέκτημα, εφόσον υποστηρίζεται από την κατάλληλη υποδομή Big Data. Οι συγγραφείς απέδειξαν ότι η εφαρμογή της αρχιτεκτονικής Λάμδα, η οποία συνδυάζει το Apache Kafka για τη σύλληψη δεδομένων και το Apache Storm για την επεξεργασία τους, επιτρέπει την αποτελεσματική εξαγωγή πληροφορίας, όπως συχνά μοτίβα πλοήγησης (n-grams) και πίνακες συν-εμφάνισης.

Επιπροσθέτως, η έρευνα ανέδειξε την πρακτική αξία του συνδυασμού προηγμένων αλγορίθμων μηχανικής μάθησης. Συγκεκριμένα, η δυναμική τμηματοποίηση των χρηστών (μέσω K-Means και Expectation-Maximization) και η πρόβλεψη των μελλοντικών τους κινήσεων (αξιοποιώντας Μαρκοβιανές Αλυσίδες Υψηλής Τάξης) καθιστούν εφικτή την παροχή εξαιρετικά στοχευμένων προτάσεων. Όσον αφορά την αποδοτικότητα της υποδομής, η χρήση της βάσης δεδομένων Cassandra, σε συνδυασμό με τεχνικές βελτιστοποίησης για εγκαταστάσεις σε πολλαπλά κέντρα δεδομένων, εξασφάλισε απαντήσεις με ελάχιστη καθυστέρηση. Η απόδοση αυτή επιβεβαιώθηκε πειραματικά μέσω μετρικών στο Microsoft Azure HDInsight cluster.

3.3 Pattern2Vec: Representation of clickstream data sequences for learning user navigational behavior

3.3.1 Σκοπός της έρευνας

Σκοπός της εργασίας [10] ήταν η ανάπτυξη μιας νέας μεθόδου αναπαράστασης δεδομένων πλοήγησης χρηστών (clickstream), με την ονομασία Pattern2Vec, με στόχο την αποτελεσματικότερη κατανόηση της συμπεριφοράς των χρηστών κατά την πλοήγησή τους σε ιστοσελίδες. Το βασικό πρόβλημα που αντιμετωπίζεται είναι ότι οι ακολουθίες URLs αποτελούν μη αριθμητικά και μη δομημένα δεδομένα, τα οποία δεν μπορούν να αξιοποιηθούν άμεσα από αλγορίθμους μηχανικής

μάθησης. Για τον λόγο αυτό, προτείνεται η μετατροπή των ακολουθιών πλοήγησης σε διανυσματικές αναπαραστάσεις (embeddings), οι οποίες αποτυπώνουν το σημασιολογικό περιεχόμενο και το πλαίσιο εμφάνισης των URLs. Με τον τρόπο αυτό καθίσταται δυνατή η εφαρμογή τεχνικών μη επιβλεπόμενης μάθησης, όπως η ομαδοποίηση (clustering), για την αναγνώριση προτύπων συμπεριφοράς. Τα αποτελέσματα έδειξαν ότι η προτεινόμενη μέθοδος υπερτερεί έναντι υπάρχουσών προσεγγίσεων, όπως οι Word2Vec, DeepWalk και Node2Vec. Συγκεκριμένα, παρουσίασε υψηλότερες επιδόσεις σε μετρικές αξιολόγησης ομαδοποίησης, όπως το v-score, η ομοιογένεια (homogeneity) και η πληρότητα (completeness), επιτυγχάνοντας ποσοστά που προσεγγίζουν το 95 τοις εκατό. Επιπλέον, τα παραγόμενα clusters εμφανίζουν μεγαλύτερη συνοχή και καλύτερο διαχωρισμό.

3.3.2 Μεθοδολογία

Αρχικά, συλλέχθηκαν δεδομένα clickstream από πραγματική ιστοσελίδα του ηλεκτρονικού εμπορίου. Στη συνέχεια πραγματοποιήθηκε η προεπεξεργασία δεδομένων, η οποία περιλάμβανε καθαρισμό (data cleansing), απομάκρυνση ελλιπών εγγράφων, καθώς και κανονικοποίηση των URLs μέσω κανονικών εκφράσεων, ώστε να αντιστοιχιστούν σε γενικότερες κατηγορίες. Έπειτα, τα δεδομένα οργανώθηκαν σε συνεδρίες πλοήγησης (sessions), λαμβάνοντας υπόψη χρονικούς περιορισμούς, όπως το μέγιστο χρονικό διάστημα μεταξύ διαδοχικών ενεργειών. Με αυτόν τον τρόπο εξασφαλίστηκε ότι οι ακολουθίες αντανakλούν την ρεαλιστική συμπεριφορά χρηστών. Στη συνέχεια, εφαρμόστηκε η εξόρυξη προτύπων (pattern mining) με αλγορίθμους όπως ο PrefixSpan και ο FPGrowth, με στόχο την αναγνώριση συχνών και λανθανόντων (hidden) προτύπων πλοήγησης. Παράλληλα, πραγματοποιήθηκε φιλτράρισμα για την απομάκρυνση πλεοναζόντων ή επικαλυπτόμενων προτύπων. Το κύριο στάδιο της μεθοδολογίας είναι η εφαρμογή της Pattern2Vec. Η μέθοδος βασίζεται σε διανυσματικές αναπαραστάσεις τύπου Word2Vec, αλλά διαφοροποιείται στο ότι εισάγει μηχανισμό στάθμισης των χαρακτηριστικών. Συγκεκριμένα, αξιοποιεί τον νόμο του Zipf, ώστε κάθε URL να συνεισφέρει διαφορετικά στο τελικό διάνυσμα, ανάλογα με τη συχνότητα εμφάνισης και τη θέση του μέσα στο πρότυπο. Με αυτόν τον τρόπο αποδίδεται μεγαλύτερη σημασία στα πιο αντιπροσωπευτικά στοιχεία της ακολουθίας. Τέλος, εφαρμόστηκαν τεχνικές μη επιβλεπόμενης μάθησης, όπως ο αλγόριθμος K-Means και η ιεραρχική ομαδοποίηση (Agglomerative Clustering), για την αξιολόγηση της ποιότητας των παραγόμενων αναπαραστάσεων. Η αξιολόγηση βασίστηκε σε μετρικές ομαδοποίησης, καθώς και σε τεχνικές οπτικοποίησης, όπως το t-SNE.

3.3.3 Συμπεράσματα

Συνοψίζοντας, η εργασία καταδεικνύει ότι η Pattern2Vec αποτελεί μια πιο αποδοτική μέθοδο αναπαράστασης δεδομένων clickstream σε σύγκριση με τις υπάρχουσες προσεγγίσεις. Η βασική καινοτομία της έγκειται στην ενσωμάτωση της σχετικής σημασίας και της θέσης των URLs στη διαδικασία δημιουργίας των embeddings. Η προσέγγιση αυτή οδηγεί σε μία βελτιωμένη ποιότητα ομαδοποίησης, με πιο διακριτά και ερμηνεύσιμα σύνολα δεδομένων. Επιπλέον, η μέθοδος μπορεί να εφαρμοστεί σε πρακτικά σενάρια, όπως η ανάλυση διοχέτευσης χρηστών (funnel analysis) και η αυτοματοποίηση δοκιμής διεπαφής λογισμικού. Τέλος, προτείνονται κατευθύνσεις για μελλοντική έρευνα, όπως η ανάπτυξη μηχανισμών κατάταξης προτύπων και η εφαρμογή της μεθόδου σε άλλα είδη ακολουθιακών δεδομένων, γεγονός που υποδεικνύει τη δυναμική επέκτασης αυτής της προσέγγισης.

3.4 Exclusive Item Recommendation to the Online Shopping Customers Based on Category Using Clickstream and UID Matrix, 2023

3.4.1 Σκοπός της έρευνας

Ο βασικός στόχος της συγκεκριμένης έρευνας [12] είναι η ανάπτυξη ενός πιο ακριβούς και εξατομικευμένου συστήματος συστάσεων προϊόντων για online αγορές, αξιοποιώντας clickstream δεδομένα και το ιστορικό αγορών των χρηστών. Σε αντίθεση με πολλές υπάρχουσες προσεγγίσεις που βασίζονται κυρίως σε ratings ή απλά clicks, η συγκεκριμένη εργασία δίνει έμφαση στη πραγματική αγοραστική συμπεριφορά του χρήστη. Οι βασικοί σκοποί της μελέτης είναι η εξής: η ανάλυση της συμπεριφοράς των χρηστών μέσα από clickstream δεδομένα, η ταξινόμηση των χρηστών σε τρεις διαφορετικές κατηγορίες που είναι Regular, Special και Exceptional, η δημιουργία ενός πιο πλούσιου User-Item-Detail matrix που ενσωματώνει πολλαπλά χαρακτηριστικά συμπεριφοράς και η παροχή εξατομικευμένων και αποκλειστικών προτάσεων προϊόντων για κάθε κατηγορία χρηστών με στόχο τη βελτίωση της εμπειρίας αγορών και την αύξηση των πωλήσεων.

3.4.2 Μεθοδολογία

Η προτεινόμενη μεθοδολογία UID-KNN αποτελείται από τέσσερα βασικά στάδια που συνδυάζουν τεχνικές επεξεργασίας δεδομένων, μηχανικής μάθησης και συστημάτων συστάσεων. Αρχικά πραγματοποιείται η προεπεξεργασία των clickstream δεδομένων. Σε αυτό το στάδιο γίνεται καθαρισμός των δεδομένων, η αναγνώριση μοναδικών χρηστών μέσω user ID ή IP διεύθυνσης, καθώς και ο διαχωρισμός των sessions με βάση τη χρονική δραστηριότητα του χρήστη. Επιπλέον γίνεται path completion ώστε να ανακατασκευαστούν ελλιπείς διαδρομές πλοήγησης και να αποτυπωθεί πιο σωστά η συμπεριφορά του χρήστη. Στη συνέχεια εφαρμόζεται ο αλγόριθμος K-Nearest Neighbors για την ταξινόμηση των χρηστών. Η ταξινόμηση δεν βασίζεται απλά στο browsing behavior αλλά κυρίως στο ιστορικό αγορών. Οι χρήστες χωρίζονται σε τρεις κατηγορίες που είναι Regular, Special και Exceptional, με βάση χαρακτηριστικά όπως χρόνος παραμονής σε προϊόντα, αριθμός clicks, προσθήκη στο καλάθι, wishlist και ολοκλήρωση αγοράς. Η ομοιότητα μεταξύ χρηστών υπολογίζεται με Ευκλείδεια απόσταση. Έπειτα κατασκευάζεται το User-Item-Detail matrix, το οποίο αποτελεί μια πιο αναλυτική μορφή αναπαράστασης δεδομένων σε σχέση με το κλασικό user-item matrix. Ο πίνακας αυτός περιλαμβάνει χαρακτηριστικά όπως την βαθμολογία προϊόντος, τον χρόνο θέασης, τον αριθμό επισκέψεων στη σελίδα προϊόντος, την προσθήκη στο καλάθι, την προσθήκη στη wishlist και την τελική αγορά. Με βάση αυτά τα δεδομένα δημιουργούνται τρεις ξεχωριστοί πίνακες UID για κάθε κατηγορία χρηστών, ώστε να υπάρχει πιο στοχευμένη ανάλυση και καλύτερη εξατομίκευση. Τέλος εφαρμόζεται ο μηχανισμός συστάσεων που προτείνει τα top-N προϊόντα σε κάθε κατηγορία χρηστών. Οι προτάσεις βασίζονται τόσο στη συμπεριφορά του χρήστη όσο και στη συσχέτιση μεταξύ χρηστών και προϊόντων μέσα από το collaborative filtering approach. Για την αξιολόγηση της μεθόδου χρησιμοποιούνται τα metrics MAE και RMSE για την ακρίβεια των προβλέψεων, καθώς και το Precision, Recall και F-measure για την ποιότητα των προτάσεων.

3.4.3 Συμπεράσματα

Τα αποτελέσματα της έρευνας δείχνουν ότι η προτεινόμενη μέθοδος UID-KNN παρουσιάζει καλύτερη απόδοση σε σχέση με υπάρχουσες προσεγγίσεις που βασίζονται μόνο σε item ratings ή απλό user-item matrix. Συγκεκριμένα, επιτυγχάνει χαμηλότερες τιμές MAE και RMSE, κάτι που δείχνει πιο ακριβείς προβλέψεις και μικρότερο σφάλμα στο σύστημα συστάσεων. Επιπλέον,

η ταξινόμηση των χρηστών σε τρεις διαφορετικές κατηγορίες συμβάλλει σημαντικά στη βελτίωση της ποιότητας των προτάσεων, καθώς επιτρέπει την πιο στοχευμένη και εξατομικευμένη παροχή προϊόντων. Το σύστημα καταφέρνει να προσαρμόζει τις προτάσεις με βάση το προφίλ και τη συμπεριφορά κάθε χρήστη, κάτι που βελτιώνει συνολικά την εμπειρία του online shopping. Συνολικά, η μελέτη αποδεικνύει ότι η χρήση clickstream δεδομένων σε συνδυασμό με την ταξινόμηση των χρηστών και το εμπλουτισμένο UID matrix μπορεί να βελτιώσει σημαντικά την απόδοση των recommender systems. Ως μελλοντική εργασία προτείνεται η ενσωμάτωση τεχνικών deep learning για ακόμη πιο ακριβή και δυναμικά συστήματα προτάσεων.

4 Μετέπειτα Εργασίες

4.1 Mining and Predicting Users Clickstream Patterns from Noisy Interleaving Clicks

Η εργασία των Alamoudi et al. [1] επικεντρώνεται στην εξόρυξη και την πρόβλεψη clickstream patterns σε ρεαλιστικά ψηφιακά περιβάλλοντα, όπου οι ακολουθίες των χρηστών επιβαρύνονται από θόρυβο και παρεμβαλλόμενες, άσχετες ενέργειες. Με δεδομένο ότι η ανθρώπινη συμπεριφορά στον ιστό σπάνια ακολουθεί γραμμικές ή ιδανικές διαδρομές, οι συγγραφείς προσεγγίζουν το clickstream ως ένα στοχαστικό ακολουθιακό πρόβλημα και εισάγουν μια μεθοδολογία βασισμένη σε ένα τροποποιημένο suffix tree σε συνδυασμό με κινούμενο χρονικό παράθυρο. Η προσέγγιση αυτή επιτρέπει την απομόνωση και την εξόρυξη συχνών, μη επικαλυπτόμενων προτύπων συμπεριφοράς, διασφαλίζοντας παράλληλα την υπολογιστική αποδοτικότητα της αναζήτησης μέσω της ιδιότητας της αντι-μονοτονικότητας, ακόμη και όταν η κύρια δραστηριότητα διακόπτεται προσωρινά.

Για το στάδιο της μοντελοποίησης και της πρόβλεψης των μελλοντικών κινήσεων του χρήστη, η έρευνα αξιοποιεί ένα τροποποιημένο Hidden Markov Model. Η επιλογή αυτή βασίζεται στην ικανότητα των Μαρκοβιανών δομών να αποτυπώνουν τις χρονικές και στατιστικές εξαρτήσεις μεταξύ διαδοχικών ενεργειών, συνδέοντας τα παρατηρούμενα, θορυβώδη μοτίβα με τις λανθάνουσες καταστάσεις και τις υποκείμενες προθέσεις πλοήγησης. Η εκτίμηση των παραμέτρων και η βελτιστοποίηση των πιθανοτήτων μετάβασης πραγματοποιούνται μέσω του αλγορίθμου EM, με τα πειραματικά αποτελέσματα να επιβεβαιώνουν την υψηλή ακρίβεια πρόβλεψης του μοντέλου ακόμη και σε συνθήκες υψηλού θορύβου.

Συνολικά, η συγκεκριμένη μελέτη προσφέρει ένα συνεκτικό πλαίσιο που γεφυρώνει με επιτυχία τις sequential mining τεχνικές με την πιθανοτική στατιστική μοντελοποίηση. Η ικανότητά της να απομονώνει την ουσιαστική πληροφορία από τις τυχαίες ενέργειες αναδεικνύει την εξελιγμένη χρήση των Μαρκοβιανών αλυσίδων και των κρυφών καταστάσεων, καθιστώντας την προσέγγιση αυτή εξαιρετικά ανθεκτική και πολύτιμη για την κατανόηση της σύνθετης ανθρώπινης συμπεριφοράς σε μη ιδανικά ψηφιακά περιβάλλοντα.

4.2 Clickstream user behavior models

Η εργασία των Wang et al. [15] εστιάζει στη συστηματική μοντελοποίηση της συμπεριφοράς των χρηστών σε μεγάλες διαδικτυακές πλατφόρμες μέσω της αξιοποίησης clickstream δεδομένων. Αντιμετωπίζοντας την περιήγηση στον ιστό ως ένα αμιγώς ακολουθιακό φαινόμενο με βαθύτερη ερμηνευτική αξία, η μελέτη απομακρύνεται από την απλή καταγραφή μεμονωμένων ενεργειών και στοχεύει στην αποκάλυψη των λανθανόντων προτύπων που χαρακτηρίζουν διαφορετικές ομάδες χρηστών. Κεντρικός άξονας της έρευνας είναι η σαφής διάκριση μεταξύ φυσιολογικής και μη φυσιολογικής δραστηριότητας, προσφέροντας ένα ολοκληρωμένο πλαίσιο για την ανίχνευση κακόβουλων ή παραπλανητικών λογαριασμών, όπως οι λογαριασμοί τύπου Sybil.

Για την υλοποίηση της ανάλυσης, οι συγγραφείς προτείνουν τρεις διαφορετικές αναπαραστάσεις των ακολουθιών πλοήγησης: την αναπαράσταση click-sequence, τη χρονική αναπαράσταση μέσω ενός time-based model, καθώς και ένα αντίστοιχο υβριδικό μοντέλο. Οι προσεγγίσεις αυτές αποτυπώνουν τόσο τη σειρά των ενεργειών όσο και τη χρονική απόσταση μεταξύ τους, επιτρέποντας την ακριβέστερη κατανόηση της πρόθεσης του χρήστη. Η μέτρηση της ομοιότητας πραγματοποιείται με εξειδικευμένες μετρικές, όπως τα common subsequences, τα subsequences with counts και ο στατιστικός έλεγχος Kolmogorov–Smirnov για τα χρονικά χαρακτηριστικά. Στη συνέχεια, οι χρήστες χαρτογραφούνται σε έναν γράφο ομοιότητας και διαχωρίζονται σε ομάδες με τη χρήση του αλγορίθμου METIS, ενώ ένας παράλληλος μηχανισμός incremental detection επιτρέπει την ταξινόμηση νέων δεδομένων χωρίς την ανάγκη ολικής επανεκπαίδευσης του συστήματος.

Τα συμπεράσματα της έρευνας αναδεικνύουν ότι ακόμη και σχετικά απλές αναπαραστάσεις ακολουθιών, όταν συνδυάζονται με κατάλληλες τεχνικές ομαδοποίησης και ανάλυσης ομοιότητας, επαρκούν για την εξαγωγή ουσιαστικών συμπερασμάτων χωρίς να απαιτείται μεγάλος όγκος επισημασμένων δεδομένων. Η συγκεκριμένη εργασία ενισχύει τον μεθοδολογικό ιστό της αναφοράς, αποδεικνύοντας πώς η σύγκριση ακολουθιακών δομών και οι αλγόριθμοι συσταδοποίησης μπορούν να αποκαλύψουν τα λανθάνοντα χαρακτηριστικά και τις στρατηγικές πλοήγησης των χρηστών.

4.3 Real-time clickstream data analytics and visualization

Η εργασία των Hanamanthrao και Thejaswini [5] επικεντρώνεται στην ανάπτυξη μιας αρχιτεκτονικής για την επεξεργασία, ανάλυση και οπτικοποίηση clickstream δεδομένων σε πραγματικό χρόνο. Αναγνωρίζοντας ότι η επιχειρησιακή αξία των δεδομένων πλοήγησης πολλαπλασιάζεται όταν η διαχείρισή τους γίνεται άμεσα, οι συγγραφείς προτείνουν ένα ολοκληρωμένο λειτουργικό πλαίσιο διαχείρισης συνεχών ροών. Η προσέγγιση αυτή στοχεύει στην υποστήριξη ψηφιακών περιβαλλόντων όπου η χαμηλή καθυστέρηση και η άμεση απόκριση είναι κρίσιμες, όπως οι πλατφόρμες ηλεκτρονικού εμπορίου και τα συστήματα τηλεεκπαίδευσης, επιτρέποντας τη γρήγορη λήψη αποφάσεων και τη δυναμική βελτιστοποίηση των ψηφιακών υπηρεσιών.

Η προτεινόμενη μεθοδολογία υλοποιεί μια end-to-end data pipeline αρχιτεκτονική, η οποία βασίζεται στον συνδυασμό των Apache Kafka, Apache Spark Streaming, Elasticsearch και Kibana. Τα δεδομένα συλλέγονται ζωντανά, διοχετεύονται μέσω του Kafka και υποβάλλονται σε real-time επεξεργασία από το Spark Streaming, προκειμένου να ευρετηριαστούν στο Elasticsearch και να παρουσιαστούν διαδραστικά μέσω του Kibana. Η υποδομή επιτρέπει την παρακολούθηση κρίσιμων δεικτών, όπως ο αριθμός των clicks, ο χρόνος παραμονής και τα συχνότερα μονοπάτια πλοήγησης. Με αυτόν τον τρόπο, η έμφαση μετατοπίζεται από την ανάπτυξη πολύπλοκων προβλεπτικών μοντέλων στην αποδοτική διαχείριση και την άμεση επιχειρησιακή αξιοποίηση της ροής των δεδομένων.

Τα συμπεράσματα της μελέτης αναδεικνύουν τη σημασία της τεχνικής και λειτουργικής πλευράς των web analytics, προσφέροντας ένα ισχυρό τεχνολογικό υπόβαθρο. Η συγκεκριμένη εργασία προσθέτει σημαντική αξία στην παρούσα αναφορά, καθώς εισάγει το απαραίτητο υποστηρικτικό πλαίσιο streaming και visualization που πρέπει να προηγείται της φάσης της μοντελοποίησης. Υπενθυμίζει με σαφήνεια ότι η ποιότητα και η αξιοπιστία των εξαγόμενων προτύπων συμπεριφοράς εξαρτώνται άμεσα από την ορθή συλλογή, επεξεργασία και παρουσίαση των δεδομένων στην είσοδο του συστήματος.

4.4 Intent-Aware Clickstream Analytics with Explainable AI: A Scalable Data Engineering Framework

Η εργασία των Venkatesan et al. [14] επικεντρώνεται στη σχεδίαση ενός ολοκληρωμένου και επεκτάσιμου πλαισίου μηχανικής δεδομένων για την ανάλυση clickstream με επίγνωση πρόθεσης, ενσωματώνοντας τεχνικές Explainable AI. Κεντρικό κίνητρο της έρευνας αποτελεί η διαπίστωση ότι τα υπάρχοντα συστήματα επικεντρώνονται αποκλειστικά στην περιγραφή ή στην πρόβλεψη της συμπεριφοράς των χρηστών, χωρίς να αιτιολογούν τον λόγο που αυτή εκδηλώνεται. Για τον λόγο αυτό, οι συγγραφείς προτείνουν μια αρθρωτή αρχιτεκτονική αγνωστικιστική ως προς το cloud, η οποία συνδυάζει την κανονικοποίηση συμβάντων, την εξαγωγή χαρακτηριστικών συμπεριφοράς και έναν lightweight ταξινομητή με ένα επίπεδο εξήγησης βασισμένο σε LLMs, παράγοντας τελικά αφηγηματικές ερμηνείες αναγνώσιμες από ανθρώπους.

Η μεθοδολογία βασίζεται σε τέσσερα διαδοχικά στάδια επεξεργασίας. Αρχικά, τα ακατέργαστα αρχεία καταγραφής clickstream, τα οποία παράγονται από συνθετικές ή πραγματικές συνεδρίες, εισάγονται σε ένα αγωγό ETL που τα μετασχηματίζει σε δομημένα χαρακτηριστικά, όπως στατιστικά χρόνου παραμονής, βάθος πλοήγησης και συχνότητα μεταβάσεων. Στη συνέχεια, ένας κανονιστικός ταξινομητής βασισμένος σε ευρετικούς κανόνες αναγνωρίζει ανωμαλίες, όπως επαναλαμβανόμενες υποβολές φορμών, βρόχους σύνδεσης ή μαζική τροποποίηση παραμέτρων URL. Κάθε ταξινομημένη συνεδρία περνά, τέλος, σε ένα LLM μέσω ενός σταθερού πρότυπου εντολής, το οποίο παράγει μια συνοπτική, αιτιολογημένη αφήγηση που συνδέει τα χαρακτηριστικά της συμπεριφοράς με την πιθανή πρόθεση του χρήστη. Η πειραματική αξιολόγηση σε 10.000 συνθετικές συνεδρίες έδειξε ότι η υβριδική προσέγγιση κανόνων–LLM πέτυχε ακρίβεια ταξινόμησης 92%, μείωση ψευδώς θετικών αποτελεσμάτων κατά 18% σε σχέση με τη βασική γραμμή κανόνων, και μέση καθυστέρηση εξαγωγής συμπερασμάτων μόλις 580 ms ανά συνεδρία.

Η συγκεκριμένη εργασία εισφέρει σημαντική αξία στη βιβλιογραφία της ανάλυσης clickstream, καθώς αντιμετωπίζει ένα χάσμα που άλλες μελέτες αφήνουν ανοικτό: κανένα από τα υπάρχοντα συστήματα δεν ενοποιεί δομημένη εξαγωγή χαρακτηριστικών, διαφανείς ευρετικούς κανόνες και αφηγήσεις επιπέδου συνεδρίας παραγόμενες από LLM σε ένα ελέγξιμο και χαμηλού κώδικα περιβάλλον. Η μελέτη αυτή συνδέεται άμεσα με τις υπόλοιπες εργασίες της παρούσας αναφοράς, καθώς επεκτείνει τις αρχές ανίχνευσης ανωμαλιών και μοντελοποίησης συμπεριφοράς που αναπτύχθηκαν στις προηγούμενες ενότητες, προσθέτοντας το κρίσιμο στρώμα ερμηνευσιμότητας που καθιστά τα αποτελέσματα κατανοητά και αξιόπιστα από τους αναλυτές.

4.5 Predicting online shopping behaviour from clickstream data using deep learning

Η εργασία των Koehn et al. [7] εξετάζει την πρόβλεψη της αγοραστικής συμπεριφοράς χρηστών από clickstream δεδομένα, χρησιμοποιώντας deep learning και συγκεκριμένα recurrent neural networks. Οι συγγραφείς υποστηρίζουν ότι τα clickstream δεδομένα έχουν εγγενώς σειριακή δομή, την οποία τα κλασικά supervised μοντέλα δεν αξιοποιούν επαρκώς, και προτείνουν τη μοντελοποίηση των sessions ως ακολουθιών page views. Στο πλαίσιο μιας εφαρμογής e-commerce, το μοντέλο χρησιμοποιείται για την πρόβλεψη του αν ένας επισκέπτης θα ολοκληρώσει αγορά, με στόχο τη βελτιστοποίηση στοχευμένων marketing ενεργειών, όπως η αποστολή ψηφιακών κουπονιών.

Η βασική συνεισφορά της εργασίας είναι ότι συγκρίνει διαφορετικές RNN αρχιτεκτονικές, όπως LSTM και GRU, με κλασικά supervised baselines και δείχνει ότι τα sequence models μπορούν να αποτυπώσουν καλύτερα τις χρονικές εξαρτήσεις της πλοήγησης. Παράλληλα, οι συγγραφείς δεν αξιολογούν μόνο την predictive performance, αλλά και το business value του

μοντέλου, δείχνοντας ότι η χρησιμότητα ενός classifier σε τέτοιο περιβάλλον εξαρτάται όχι μόνο από την ακρίβεια αλλά και από το οικονομικό όφελος που προσφέρει. Για τον λόγο αυτό, η εργασία καταλήγει ότι ένας συνδυασμός sequence και conventional classifiers μέσω ensemble μπορεί να δώσει τα πιο σταθερά αποτελέσματα.

4.6 Efficient Long Sequential User Data Modeling for Click-Through Rate Prediction

Η εργασία των Chen et al. [2] εξετάζει την πρόβλεψη click-through rate (CTR) αξιοποιώντας μεγάλες ακολουθίες συμπεριφοράς χρηστών σε recommendation systems. Οι συγγραφείς υποστηρίζουν ότι τα κλασικά sequence-based μοντέλα, όπως τα DIN και DIEN, περιορίζονται κυρίως σε σύντομες ακολουθίες λόγω του αυξανόμενου υπολογιστικού κόστους, με αποτέλεσμα να μη μπορούν να εκμεταλλευτούν πλήρως το μακροχρόνιο ιστορικό του χρήστη. Για τον λόγο αυτό προτείνουν το ETA-Net, ένα end-to-end μοντέλο που σχεδιάστηκε ειδικά για αποδοτική μοντελοποίηση μακρών user behavior sequences.

Η βασική τεχνική συνεισφορά της εργασίας είναι ο μηχανισμός Efficient Target Attention, ο οποίος αντικαθιστά το κλασικό dot-product attention με hashing-based bit-wise operations. Με αυτόν τον τρόπο μειώνεται σημαντικά η υπολογιστική πολυπλοκότητα της διαδικασίας επιλογής των πιο σχετικών συμπεριφορών, ενώ το μοντέλο παραμένει ικανό να μαθαίνει χρήσιμα long-term interest patterns. Παράλληλα, οι συγγραφείς προτείνουν και μια γενική αρχιτεκτονική για την ενσωμάτωση του ETA-Net σε βιομηχανικά recommendation systems μεγάλης κλίμακας.

Τα πειράματα δείχνουν ότι το ETA-Net υπερέχει σε σχέση με state-of-the-art μεθόδους τόσο σε offline αξιολόγηση όσο και σε online A/B testing. Στην πρακτική εφαρμογή του στο Taobao, το μοντέλο οδήγησε σε βελτιώσεις τόσο στο CTR όσο και στο GMV, επιβεβαιώνοντας ότι η αποδοτική χρήση μακρών ακολουθιών μπορεί να προσφέρει ουσιαστικό επιχειρηματικό όφελος. Έτσι, η εργασία αποτελεί ένα πολύ σημαντικό παράδειγμα για το πώς η αποδοτικότητα και η predictive performance μπορούν να συνδυαστούν σε πραγματικά industrial settings.

4.7 ClickstreamGPT: a transformer-based generative AI approach to click-stream prediction for E-commerce platforms

Η εργασία των F. Mancini et al. [9] προτείνει τη χρήση αρχιτεκτονικής τύπου Transformer (και συγκεκριμένα GPT-style μοντέλου) για την πρόβλεψη της επόμενης ενέργειας χρηστών μέσα σε e-banking εφαρμογές, βασιζόμενη σε clickstream δεδομένα. Η βασική ιδέα είναι ότι η πλοήγηση ενός χρήστη μπορεί να αντιμετωπιστεί ως μια ακολουθία, αντίστοιχη με μια πρόταση σε φυσική γλώσσα, όπου κάθε click ή screen της εφαρμογής θεωρείται ως ένα token. Με αυτόν τον τρόπο, το πρόβλημα μετατρέπεται σε task πρόβλεψης επόμενου token, δηλαδή το μοντέλο εκπαιδεύεται να προβλέπει ποια θα είναι η επόμενη ενέργεια του χρήστη με βάση το ιστορικό της αλληλεπίδρασής του.

Η χρήση Transformers σε αυτό το πλαίσιο είναι σημαντική γιατί, σε αντίθεση με τα κλασικά recurrent neural networks (RNNs), δεν επεξεργάζονται τα δεδομένα σειριακά αλλά χρησιμοποιούν το mechanism του self-attention, το οποίο τους επιτρέπει να εξετάζουν ολόκληρη την ακολουθία ταυτόχρονα και να εντοπίζουν πιο εύκολα εξαρτήσεις μεταξύ απομακρυσμένων ενεργειών μέσα στο session. Αυτό είναι ιδιαίτερα χρήσιμο σε e-banking περιβάλλον, όπου η τελική επιλογή ενός χρήστη (π.χ. μια οικονομική συναλλαγή ή αίτηση προϊόντος) μπορεί να επηρεάζεται από ενέργειες που έγιναν αρκετά πιο πριν στο session και όχι μόνο από τις τελευταίες κινήσεις.

Επιπλέον, το self-attention επιτρέπει στο μοντέλο να αποδίδει διαφορετικά βάρη σε προηγούμενα clicks, ανάλογα με τη σημασία τους για την πρόβλεψη της επόμενης ενέργειας, κάτι που βελτιώνει

την ικανότητα κατανόησης σύνθετων patterns συμπεριφοράς. Έτσι, το GPT δεν λειτουργεί απλά ως classifier, αλλά μαθαίνει τη “δομή” των user journeys, αναπαριστώντας ουσιαστικά τη συμπεριφορά του χρήστη ως μια μορφή γλώσσας. Αυτό δίνει τη δυνατότητα για πιο ακριβή prediction και πιο γενικευμένα μοντέλα που μπορούν να εφαρμοστούν σε διαφορετικά είδη clickstream δεδομένων.

Συνολικά, η εργασία των Mancini et al. δείχνει ότι τα Transformer-based μοντέλα μπορούν να επεκταθούν πέρα από τις εφαρμογές φυσικής γλώσσας και να χρησιμοποιηθούν αποτελεσματικά στην ανάλυση συμπεριφοράς χρηστών, προσφέροντας μια πιο ισχυρή και ευέλικτη προσέγγιση σε σχέση με τα παραδοσιακά sequence models.

4.8 Clickstream user behavior clustering using graph time series

Η εργασία [3] προτείνει μια προσέγγιση που συνδυάζει τεχνικές ανάλυσης χρονοσειρών με μεθόδους ανάλυσης δικτύων, με στόχο την καλύτερη κατανόηση της συμπεριφοράς χρηστών μέσα από clickstream δεδομένα. Η βασική ιδέα είναι ότι οι χρονοσειρές που προκύπτουν από τις αλληλεπιδράσεις των χρηστών δεν αντιμετωπίζονται μεμονωμένα, αλλά ως μέρος ενός μεγαλύτερου συστήματος, το οποίο μπορεί να αναπαρασταθεί ως γράφος.

Μέσα από αυτή τη μοντελοποίηση, οι σχέσεις ομοιότητας μεταξύ διαφορετικών μοτίβων συμπεριφοράς αποτυπώνονται μέσω ακμών που βασίζονται σε συναρτήσεις απόστασης, επιτρέποντας έτσι την ομαδοποίηση παρόμοιων συμπεριφορών ακόμη και όταν υπάρχουν χρονικές μετατοπίσεις ή διαφοροποιήσεις στο σχήμα των δεδομένων. Η εφαρμογή αλγορίθμων community detection πάνω σε αυτό το δίκτυο αποτελεί ένα από τα βασικά σημεία της προσέγγισης, καθώς επιτρέπει τον εντοπισμό ομάδων χρονοσειρών που παρουσιάζουν ισχυρή εσωτερική ομοιότητα. Με αυτόν τον τρόπο, η εργασία καταφέρνει να μετατρέψει ένα σύνθετο πρόβλημα ανάλυσης χρονικών δεδομένων σε πρόβλημα εντοπισμού κοινοτήτων σε γράφο, κάτι που είναι πιο εύκολα διαχειρίσιμο και ερμηνεύσιμο. Παράλληλα, η χρήση τοπολογικών χαρακτηριστικών του δικτύου συμβάλλει στην εξαγωγή τόσο τοπικών όσο και καθολικών προτύπων, ενισχύοντας την ικανότητα του μοντέλου να αναγνωρίζει διαφορετικού τύπου συμπεριφορές.

Ένα σημαντικό σημείο της εργασίας είναι ότι αναδεικνύει τη χρησιμότητα του συνδυασμού time series analysis και network science για την ανάλυση clickstream δεδομένων σε μεγάλη κλίμακα. Ωστόσο, τονίζει και την ύπαρξη ερευνητικού κενού, καθώς οι περισσότερες υπάρχουσες προσεγγίσεις αντιμετωπίζουν ξεχωριστά είτε τη χρονική διάσταση είτε τη δομή των δικτύων, χωρίς να τα συνδυάζουν αποτελεσματικά. Η προτεινόμενη μεθοδολογία επιχειρεί να καλύψει αυτό το κενό, προσφέροντας ένα πλαίσιο που μπορεί να εντοπίζει μοτίβα συμπεριφοράς χρηστών μέσα σε συγκεκριμένα χρονικά παράθυρα.

Τέλος, η χρήση ενός πολύ μεγάλου dataset από mobile banking περιβάλλον ενισχύει τη σημασία των αποτελεσμάτων, καθώς δείχνει ότι η μέθοδος μπορεί να εφαρμοστεί σε πραγματικές συνθήκες μεγάλης κλίμακας. Συνολικά, η εργασία καταλήγει ότι ο συνδυασμός χρονοσειρών και ανάλυσης δικτύων αποτελεί μια ιδιαίτερα υποσχόμενη κατεύθυνση για την κατανόηση και πρόβλεψη της συμπεριφοράς χρηστών σε ψηφιακά περιβάλλοντα.

4.9 Understanding consumers' online browsing patterns and influence of marketing stimuli: A two-layer sequence analysis approach

Η εργασία των Ding et al. [4] προτείνει ένα καινοτόμο δύο-επιπέδων (two-layer) framework για την ανάλυση clickstream δεδομένων σε περιβάλλον e-commerce, με στόχο την κατανόηση των online browsing patterns και της επίδρασης που έχουν τα marketing stimuli στη συμπεριφορά των καταναλωτών. Η βασική προσέγγιση βασίζεται στη sequence analysis, μια μεθοδολογία

που προέρχεται από τη βιοπληροφορική και επιτρέπει τη μοντελοποίηση της πλοήγησης των χρηστών ως χρονικές ακολουθίες ενεργειών, λαμβάνοντας υπόψη τόσο τη σειρά όσο και τη δυναμική εξέλιξη των shopping goals.

Στο πρώτο επίπεδο (Layer 1), οι συγγραφείς κατηγοριοποιούν τους καταναλωτές σε διαφορετικά browsing patterns, τα οποία διαφοροποιούνται με βάση τον βαθμό “σαφήνειας” του shopping goal και τον τρόπο με τον οποίο ο χρήστης κινείται προς την ολοκλήρωση μιας αγοράς. Με αυτόν τον τρόπο, προκύπτουν διακριτά behavioral clusters που αποτυπώνουν διαφορετικές στρατηγικές πλοήγησης, από πιο διερευνητική έως πιο στοχευμένη αγοραστική συμπεριφορά.

Στο δεύτερο επίπεδο (Layer 2), η ανάλυση επεκτείνεται ώστε να εξετάσει πώς τα marketing stimuli, όπως personalized recommendations και price promotions, επηρεάζουν αυτές τις συμπεριφορές. Το σημαντικό εύρημα είναι ότι η αποτελεσματικότητα των marketing ενεργειών δεν είναι σταθερή, αλλά εξαρτάται έντονα από το είδος του χρήστη και το στάδιο στο οποίο βρίσκεται μέσα στη διαδικασία αναζήτησης. Για παράδειγμα, οι προσωποποιημένες προτάσεις προϊόντων φαίνεται να είναι πιο αποτελεσματικές όταν ο χρήστης βρίσκεται σε αρχικό στάδιο εξερεύνησης και έχει γενικούς στόχους, ενώ οι προσφορές τιμής λειτουργούν καλύτερα όταν ο χρήστης έχει ήδη πιο συγκεκριμένη πρόθεση αγοράς. Ένα ιδιαίτερα σημαντικό στοιχείο της εργασίας είναι ότι δεν περιορίζεται μόνο στην περιγραφική ανάλυση της συμπεριφοράς, αλλά δείχνει ότι τα αναγνωρισμένα patterns μπορούν να χρησιμοποιηθούν ως επιπλέον επίπεδο πληροφορίας για την ενίσχυση μοντέλων πρόβλεψης αγοράς. Συγκεκριμένα, προτείνεται ότι η pattern-based ανάλυση μπορεί να βελτιώσει την ακρίβεια των clickstream prediction models, μειώνοντας τον θόρυβο από μη σχετικές αλληλεπιδράσεις και επιτρέποντας πιο στοχευμένη βελτιστοποίηση των παραμέτρων των μοντέλων.

Συνολικά, η εργασία καταλήγει ότι η κατανόηση της online συμπεριφοράς δεν μπορεί να βασίζεται μόνο σε απλά clickstream prediction models, αλλά απαιτεί πολυεπίπεδη ανάλυση που συνδυάζει τη δομή των ακολουθιών με τη σημασία των εξωτερικών παραγόντων, όπως τα marketing stimuli. Αυτό καθιστά το προτεινόμενο framework ιδιαίτερα χρήσιμο τόσο σε θεωρητικό επίπεδο, για την κατανόηση της αγοραστικής συμπεριφοράς, όσο και σε πρακτικό επίπεδο, για τη βελτιστοποίηση στρατηγικών marketing σε πραγματικά e-commerce συστήματα.

5 Σύνοψη και συμπεράσματα

5.1 Deep learning & sequential prediction

Η εργασία των Koehn et al. [7] επικεντρώνεται επίσης σε clickstream δεδομένα, αλλά χρησιμοποιεί recurrent neural networks (RNNs), όπως LSTM και GRU, για την πρόβλεψη αγοραστικής συμπεριφοράς σε e-commerce περιβάλλον. Εκεί το βασικό task είναι πιο “binary” και συγκεκριμένο: αν ο χρήστης θα ολοκληρώσει αγορά ή όχι.

Αντίθετα, η προσέγγιση των Mancini et al. [9] είναι πιο γενική και sequence-based, καθώς δεν περιορίζεται μόνο σε τελικό outcome (purchase), αλλά προβλέπει την επόμενη ενέργεια μέσα στο session. Επιπλέον, το GPT-based μοντέλο έχει θεωρητικά μεγαλύτερη ικανότητα να χειριστεί μακροχρόνιες εξαρτήσεις σε σχέση με τα RNNs, τα οποία έχουν πιο περιορισμένη μνήμη παρά την ύπαρξη LSTM/GRU.

Από την άλλη, η εργασία των Koehn et al. [7] έχει πιο ξεκάθαρη business ερμηνεία (conversion prediction και marketing actions), ενώ οι Mancini et al. [9] δίνουν μεγαλύτερη έμφαση στη γενικότητα της μοντελοποίησης clickstream ως language-like sequence.

Συνολικά, μπορούμε να πούμε ότι τα RNN-based μοντέλα είναι πιο “task-specific” και κατάλληλα για classification προβλήματα όπως purchase prediction, ενώ τα GPT-based approaches είναι πιο “universal” και κατάλληλα για γενική πρόβλεψη ακολουθιών συμπεριφοράς

και πιο σύνθετη κατανόηση user journeys.

5.2 MHMM & Sequence modeling

Η συγκριτική εξέταση τριών εργασιών, συγκεκριμένα της προσέγγισης των Urso et al. [13], της μεθοδολογίας των Alamoudi et al. [1] και του μοντέλου συμπεριφοράς των Wang et al. [15], αναδεικνύει τις διαφορετικές μεθοδολογικές αφετηρίες και τη συμπληρωματικότητα των προσεγγίσεων γύρω από τη μοντελοποίηση δεδομένων clickstream. Η διαφοροποίηση εντοπίζεται κυρίως στους εξής άξονες:

- **Θεωρητική έναντι Πρακτικής Στόχευσης:** Η προσέγγιση των Mixture Hidden Markov Models (MHMMs) [13] δίνει έμφαση στη στατιστική θεμελίωση και τη μαθηματική αυστηρότητα της επιλογής του μοντέλου. Αντίθετα, η μεθοδολογία των Alamoudi et al. [1] γύρω από τα θορυβώδη περιβάλλοντα "κλικ" μετατοπίζει το ενδιαφέρον από τη θεωρητική βελτιστοποίηση στην πρακτική διαχείριση των ατελειών των πραγματικών δεδομένων με σκοπό την άμεση επιχειρησιακή αξιοποίηση.
- **Επίπεδο Αφαίρεσης:** Το μοντέλο συμπεριφοράς που προτείνουν οι Wang et al. [15] λειτουργεί ως συνδετικός κρίκος. Γεφυρώνει το χάσμα μεταξύ της βαθιάς στατιστικής ερμηνείας των υποκείμενων καταστάσεων [13] και της ανάγκης για αναγνώριση σταθερών, επαναλαμβανόμενων προτύπων πλοήγησης [1] σε ένα γενικότερο πλαίσιο αναπαράστασης.

Συνολικά, η σύγκριση καταδεικνύει ότι η επεξεργασία δεδομένων clickstream δεν αποτελεί μια μονοδιάστατη διαδικασία. Αντιθέτως, απαιτεί τη συνδυαστική θεώρηση στατιστικών μοντέλων για την κατανόηση της δυναμικής των χρηστών, παράλληλα με ανθεκτικούς αλγορίθμους εξόρυξης, κατάλληλους για τη διαχείριση των ασυνεχειών στα δεδομένα ακολουθιών πλοήγησης.

5.3 Real-Time Streaming & ETL Υποδομές

Η μετάβαση από τη στατική επεξεργασία στην ανάλυση ροής δεδομένων σε πραγματικό χρόνο αναδεικνύει κρίσιμες υποδομικές προκλήσεις, με την υλοποίηση μιας τέτοιας αρχιτεκτονικής να καθίσταται εφικτή μέσω διαφορετικών τεχνολογικών και δομικών προσεγγίσεων. Η συγκριτική εξέταση των σχετικών εργασιών, συγκεκριμένα του συστήματος των Pal et al. [11], της αρχιτεκτονικής των Hanamanthrao και Thejaswini [5], του μοντέλου των Chen et al. [2] και του πλαισίου μηχανικής δεδομένων των Venkatesan et al. [14], φέρνει στην επιφάνεια τους εξής άξονες:

- **Αρχιτεκτονική Ευελιξία και Δομές Επεξεργασίας:** Η επεξεργασία ροής σε πραγματικό χρόνο δεν περιορίζεται σε μία μοναδική τεχνολογική λύση. Η προσέγγιση που βασίζεται στο Apache Storm [11] υλοποιεί ένα live pipeline για την άμεση εκτέλεση μοντέλων μηχανικής μάθησης, ενώ η εργασία με το Apache Spark Streaming [5] προκρίνει τη χρήση Elasticsearch και Kibana, δίνοντας βάση στην ευρετηρίαση και την άμεση οπτικοποίηση των δεδομένων. Διαφορετική προσέγγιση ακολουθεί το πλαίσιο των Venkatesan et al. [14], το οποίο εισάγει μια cloud-agnostic ETL δομή κανονικοποίησης συμβάντων και εξαγωγής χαρακτηριστικών, αποδεικνύοντας ότι ο μετασχηματισμός των ακατέργαστων clickstream logs μπορεί να οργανωθεί με ποικίλα λειτουργικά σχήματα προτού φτάσει στη φάση της μοντελοποίησης.
- **Κλίμακα και Υπολογιστική Αποδοτικότητα:** Η επιλογή της real-time δομής επηρεάζει άμεσα την ικανότητα διαχείρισης του όγκου των δεδομένων. Ενώ τα κλασικά streaming pipelines [11, 5] εστιάζουν στη μείωση της καθυστέρησης σε επίπεδο τρέχουσας

συνεδρίας, βιομηχανικά μοντέλα μεγάλης κλίμακας, όπως το ETA-Net των Chen et al. [2], επεκτείνουν αυτή την αρχιτεκτονική χρησιμοποιώντας bit-wise operations για να ενσωματώσουν αποτελεσματικά το μακροχρόνιο ιστορικό του χρήστη σε πραγματικό χρόνο, χωρίς να επιβαρύνουν υπολογιστικά το σύστημα.

Συνολικά, η σύγκριση καταδεικνύει ότι οι streaming υποδομές και οι ETL ροές αποτελούν τον απαραίτητο ζωντανό μηχανισμό υποστήριξης των δεδομένων clickstream [5, 14]. Επιβεβαιώνεται ότι η αξιοπιστία των εξαγόμενων προτύπων εξαρτάται άμεσα από την ορθή συλλογή, τον μετασχηματισμό και την επεξεργασία τους στην είσοδο του συστήματος, μια διαδικασία που μπορεί να σχεδιαστεί επιτυχώς με περισσότερες από μία μεθοδολογίες.

Συμπεράσματικά για τα 2 papers του De Oliveira et al. (2025) και του Ding et al έχουμε ότι:

Η εργασία αναδεικνύει ότι η συνδυαστική αξιοποίηση της ανάλυσης χρονοσειρών και της ανάλυσης δικτύων μπορεί να προσφέρει βαθύτερη κατανόηση της συμπεριφοράς των χρηστών σε clickstream δεδομένα. Μέσω της αναπαράστασης των χρονοσειρών ως γράφου και της εφαρμογής τεχνικών ανίχνευσης κοινοτήτων, καθίσταται δυνατός ο εντοπισμός ομάδων χρηστών με παρόμοια πρότυπα συμπεριφοράς, ακόμη και όταν υπάρχουν χρονικές μετατοπίσεις ή διαφοροποιήσεις στις ακολουθίες ενεργειών.

Παράλληλα, τα αποτελέσματα δείχνουν ότι η ενσωμάτωση τοπολογικών χαρακτηριστικών των δικτύων βελτιώνει την εξαγωγή συμπεριφορικών προτύπων σε περιβάλλοντα μεγάλης κλίμακας. Η εργασία καταλήγει ότι οι υβριδικές προσεγγίσεις που συνδυάζουν χρονική και δομική πληροφορία αποτελούν μια ιδιαίτερα υποσχόμενη κατεύθυνση για μελλοντικά συστήματα ανάλυσης και πρόβλεψης συμπεριφοράς χρηστών.

Η εργασία του Ding et al. (2025) καταδεικνύει ότι η συμπεριφορά πλοήγησης των καταναλωτών μπορεί να περιγραφεί αποτελεσματικά μέσω διακριτών προτύπων ακολουθιών, τα οποία αποτυπώνουν διαφορετικές στρατηγικές αναζήτησης και λήψης αγοραστικών αποφάσεων. Η προτεινόμενη προσέγγιση δύο επιπέδων επιτρέπει όχι μόνο την αναγνώριση αυτών των προτύπων αλλά και τη μελέτη της επίδρασης εξωτερικών παραγόντων, όπως οι προσωποποιημένες προτάσεις και οι προωθητικές ενέργειες.

, τα ευρήματα δείχνουν ότι η αποτελεσματικότητα των marketing stimuli εξαρτάται από το στάδιο της αγοραστικής διαδικασίας και τα χαρακτηριστικά του χρήστη. Ως αποτέλεσμα, η εργασία υποστηρίζει ότι η αξιοποίηση του behavioral patterns μπορεί να συμβάλλει τόσο στη βελτίωση της ακρίβειας των μοντέλων πρόβλεψης όσο και στη σχεδίαση πιο αποδοτικών και εξατομικευμένων στρατηγικών marketing.

References

- [1] A. Alamoudi, F. Fekri, M. Mohandes, and B. Liu. Mining and predicting users clickstream patterns from noisy interleaving clicks. In *2022 IEEE Global Communications Conference (GLOBECOM)*, pages 3083–3088, 2022.
- [2] Qiwei Chen, Yue Xu, Changhua Pei, Shanshan Lv, Tao Zhuang, and Junfeng Ge. Efficient long sequential user data modeling for click-through rate prediction. In *Proceedings of the 31st ACM International Conference on Information and Knowledge Management Workshop on Deep Learning Practice for High-Dimensional Sparse Data (DLP-KDD)*, 2022.
- [3] Leticia Alves De Oliveira, Victor Augusto Sampaio Precoma, Felipe Mancini, and Fabio Teixeira. Clickstream user behavior clustering using graph time series, 2025. SSRN Preprint, Abstract 5132450.
- [4] Yi Ding, Haifeng Xu, Chee Wei Phang, and Bernard C. Y. Tan. Understanding consumers’ online browsing patterns and influence of marketing stimuli: A two-layer sequence analysis approach. *Journal of the Academy of Marketing Science*, 53:1715–1747, 2025.
- [5] Ramanna Hanamanthrao and Thejaswini S. Real-time clickstream data analytics and visualization. In *2017 2nd IEEE International Conference on Recent Trends in Electronics Information & Communication Technology (RTEICT)*, pages 2139–2144, May 2017.
- [6] Satu Helske and Jouni Helske. Mixture hidden markov models for sequence data: The seqhmm package in r. *Journal of Statistical Software*, 88(3):1–32, 2019.
- [7] Dennis Koehn, Stefan Lessmann, and Markus Schaal. Predicting online shopping behaviour from clickstream data using deep learning. *Expert Systems with Applications*, 150:113342, 2020.
- [8] Z. Liu, Y. Wang, M. Dontcheva, M. Hoffman, S. Walker, and A. Wilson. Patterns and sequences: Interactive exploration of clickstreams to understand common visitor paths. *IEEE Transactions on Visualization and Computer Graphics*, 23(1):321–330, 2017.
- [9] Felipe Mancini, Victor Augusto Sampaio Precoma, Leticia Alves De Oliveira, and Fabio Teixeira. Clickstreamgpt: a transformer-based generative ai approach to clickstream prediction for e-commerce platforms. *Electronic Commerce Research*, 2025.
- [10] Erdi Olmezogullari and Mehmet S. Aktas. Pattern2vec: Representation of clickstream data sequences for learning user navigational behavior. 2022.
- [11] Gautam Pal, Katie Atkinson, and Gangmin Li. Real-time user clickstream behavior analysis based on apache storm streaming. 2023.
- [12] R. Suguna, P. Sathishkumar, and S. Deepa. Exclusive item recommendation to the online shopping customers based on category using clickstream and uid matrix. In *Computer Networks and Inventive Communication Technologies*, pages 177–190. Springer, 2023.
- [13] Furio Urso, Antonino Abbruzzo, Marcello Chiodi, and Maria Francesca Cracolici. Model selection for mixture hidden markov models: an application to clickstream data. 2024.

- [14] Vivek Venkatesan, Balaji Sundareshan, Deepak Barla, and Chakkaravarthy Arunachalam. Intent-aware clickstream analytics with explainable ai: A scalable data engineering framework. In *Proceedings of the 2026 IEEE 16th Annual Computing and Communication Workshop and Conference (CCWC)*, pages 348–355. IEEE, 2026.
- [15] Gang Wang, Xinyi Zhang, Shiliang Tang, Christo Wilson, Haitao Zheng, and Ben Y. Zhao. Clickstream user behavior models. *ACM Transactions on the Web*, 11(4):21:1–21:37, 2017.