



ΠΑΝΕΠΙΣΤΗΜΙΟ
ΠΑΤΡΩΝ
UNIVERSITY OF PATRAS

Πολυτεχνική Σχολή
Τμήμα Μηχανικών Η/Υ & Πληροφορικής

ΕΞΟΥΥΞΗ ΔΕΔΟΜΕΝΩΝ ΚΑΙ ΜΗΧΑΝΙΚΗ ΜΑΘΗΣΗ

Αναφορά βασισμένη στην ανάλυση Clickstream Δεδομένων

Γεωργία Μυλωνά
A.M. 1104783

Δημήτριος Φιλόπουλος
A.M. 1101130

Πάτρα, 2026

Contents

1	Εισαγωγή	2
2	Προηγούμενες σχετικές μελέτες	2
3	Βασική ανάλυση	2
3.1	Model selection for mixture hidden Markov models: an application to click-stream data	2
3.1.1	Σκοπός της Έρευνας	2
3.1.2	Μεθοδολογία	3
3.1.3	Συμπεράσματα	4
3.2	Real-time user clickstream behavior analysis based on apache storm streaming	4
3.2.1	Σκοπός της Έρευνας	4
3.2.2	Μεθοδολογία	4
3.2.3	Συμπεράσματα	5
3.3	Pattern2Vec: Representation of clickstream data sequences for learning user navigational behavior	5
3.3.1	Σκοπός της έρευνας	5
3.3.2	Μεθοδολογία	6
3.3.3	Συμπεράσματα	6
3.4	Exclusive Item Recommendation to the Online Shopping Customers Based on Category Using Clickstream and UID Matrix, 2023 [7]	6
3.4.1	Σκοπός της έρευνας	6
3.4.2	Μεθοδολογία	7
3.4.3	Συμπεράσματα	7
4	Μετέπειτα Εργασίες	8
4.1	Mining and Predicting Users Clickstream Patterns from Noisy Interleaving Clicks [1]	8
4.2	Clickstream user behavior models [9]	8
4.3	Real-time clickstream data analytics and visualization [3]	9
4.4	Χρήση Deep Learning για prediction	9
4.4.1	Predicting online shopping behaviour from clickstream data using deep learning [4]	9
4.5	Incremental clickstream pattern mining	10
4.5.1	Efficient Long Sequential User Data Modeling for Click-Through Rate Prediction [2]	10
5	Σύνοψη και συμπεράσματα	10

1 Εισαγωγή

2 Προηγούμενες σχετικές μελέτες

Η μελέτη της βιβλιογραφίας γύρω από τα clickstream δεδομένα δείχνει ότι το συγκεκριμένο πεδίο έχει αναπτυχθεί σε πολλαπλές κατευθύνσεις, οι οποίες περιλαμβάνουν τη μοντελοποίηση της συμπεριφοράς των χρηστών, την ανάλυση ροών δεδομένων σε πραγματικό χρόνο, την αναγνώριση προτύπων πλοήγησης και την αξιοποίηση των ακολουθιών κλικ για τη λήψη αποφάσεων. Οι προηγούμενες σχετικές εργασίες είναι ιδιαίτερα σημαντικές, διότι προσφέρουν το θεωρητικό και μεθοδολογικό υπόβαθρο πάνω στο οποίο στηρίζεται η παρούσα μελέτη. Μέσα από αυτές καθίσταται σαφές ότι τα clickstream δεδομένα δεν αποτελούν απλώς ένα σύνολο διαδοχικών ενεργειών, αλλά μια πλούσια πηγή πληροφορίας για την ερμηνεία της συμπεριφοράς των χρηστών σε ψηφιακά περιβάλλοντα.

3 Βασική ανάλυση

3.1 Model selection for mixture hidden Markov models: an application to clickstream data

3.1.1 Σκοπός της Έρευνας

Ο κύριος σκοπός αυτού του άρθρου [8] είναι η εις βάθος ανάλυση δεδομένων clickstream μέσω της χρήσης Mixture Hidden Markov Models (MHMMs). Η ανάλυση αυτή αποσκοπεί στο να ξεπεράσει τους περιορισμούς των απλών αλγορίθμων ομαδοποίησης, οι οποίοι συχνά απαιτούν έναν μεγάλο και μη πρακτικό αριθμό συστάδων για να παράγουν ομοιογενείς ομάδες, επειδή εξετάζουν αποκλειστικά τις ορατές αλληλουχίες των σελίδων που επισκέπτονται οι χρήστες.

Τα MHMMs προσφέρουν μια ουσιαστικότερη προσέγγιση στην ομαδοποίηση των ακολουθιών πλοήγησης, καθώς δεν αντιμετωπίζουν τη συμπεριφορά των χρηστών ως μια απλή, τυχαία σειρά από κλικ. Αντιθέτως, βασίζονται στην υπόθεση ότι η πλοήγηση καθοδηγείται από μια μίξη λανθανουσών μαρκοβιανών διαδικασιών, καθεμία από τις οποίες αντιστοιχεί σε έναν διαφορετικό, άγνωστο υποπληθυσμό χρηστών. Αυτές οι διαδικασίες αποτυπώνουν τα λανθάνοντα κίνητρα των χρηστών, τα οποία αναφέρονται στη μελέτη ως «νοητικές» ή «κρυφές καταστάσεις» (mental / hidden states). Οι καταστάσεις αυτές υπαγορεύουν την πορεία του χρήστη μέσα στον ιστότοπο, προσαρμόζοντας τις επιλογές του ανάλογα με τον εκάστοτε στόχο του. Με αυτόν τον τρόπο, το μοντέλο καταφέρνει να αποκαλύψει υποκείμενα προφίλ συμπεριφοράς που δεν θα μπορούσαν να εντοπιστούν αποκλειστικά από την επιφανειακή καταγραφή των σελίδων.

Ωστόσο, η πρακτική εφαρμογή των MHMMs περιπλέκεται σημαντικά από την ανάγκη προσδιορισμού ενός άγνωστου, εκ των προτέρων, αριθμού τόσο των συστάδων όσο και αυτών των κρυφών καταστάσεων. Όταν τα δεδομένα αποτελούνται από σύντομες ακολουθίες, τα παραδοσιακά κριτήρια πληροφοριών αποτυγχάνουν να υποδείξουν τον σωστό αριθμό ομάδων, καθώς αγνοούν τον βαθμό διαχωρισμού μεταξύ των προφίλ των χρηστών.

Για να αντιμετωπίσουν αυτή την πρόκληση και να εντοπίσουν τον βέλτιστο διαχωρισμό των χρηστών, οι συγγραφείς ανέπτυξαν και πρότειναν ένα νέο κριτήριο επιλογής μοντέλου, το BIC_H . Το κριτήριο αυτό σχεδιάστηκε ειδικά για να επιλέγει μοντέλα που δεν προσαρμόζονται απλώς καλά στα παρατηρούμενα δεδομένα, αλλά ταυτόχρονα αξιολογούν την αβεβαιότητα της ταξινόμησης, προσφέροντας τελικά διακριτές και εύκολα ερμηνεύσιμες ομάδες χρηστών.

Όσον αφορά τα **αποτελέσματα**, η αξιολόγηση του προτεινόμενου κριτηρίου χωρίζεται σε δύο σκέλη:

- **Αξιολόγηση μέσω Monte Carlo προσομοιώσεων:** Οι συγγραφείς εξέτασαν την απόδοση του BIC_H έναντι των κλασικών κριτηρίων πληροφοριών (AIC , BIC και $ssBIC$) σε διάφορα σενάρια, μεταβάλλοντας το μήκος των ακολουθιών και τον αριθμό των δεδομένων. Αποδείχθηκε ότι σε ακολουθίες μικρού μήκους, γεγονός που αποτελεί τον κανόνα στα δεδομένα clickstream, το BIC_H έχει σημαντικά καλύτερη απόδοση στην ταυτόχρονη αναγνώριση του σωστού αριθμού συστάδων και καταστάσεων. Αντίθετα, τα κλασικά κριτήρια δυσκολεύονται έντονα και υποτιμούν συστηματικά τον αριθμό των συστάδων.
- **Εφαρμογή σε πραγματικά δεδομένα:** Κατά την ανάλυση των πραγματικών δεδομένων clickstream από τον ιστότοπο της εταιρείας φιλοξενίας "LovePanormus", το κριτήριο BIC_H επέλεξε ένα μοντέλο με 3 συστάδες (clusters) και (3, 2, 4) κρυφές καταστάσεις αντίστοιχα. Η επιλογή αυτή αποκάλυψε τρία διακριτά προφίλ χρηστών:
 1. **«Απλός επισκέπτης / πιθανός συνεργάτης» (Casual explorer / Potential partner):** Αποτελεί το 22% των χρηστών. Το μοντέλο εντόπισε 3 κρυφές καταστάσεις σε αυτό το προφίλ, οι οποίες αντιστοιχούν σε πλοήγηση στην αρχική σελίδα, σε γενική εξερεύνηση, και στην αναζήτηση πληροφοριών για την ίδια την εταιρεία.
 2. **«Αναζητητής πληροφοριών» (Information seeker):** Αποτελεί το 19% των χρηστών. Εδώ εντοπίστηκαν 2 κρυφές καταστάσεις, όπου οι χρήστες εστιάζουν αποκλειστικά σε τουριστικές πληροφορίες (αξιοθέατα) ή ακολουθούν μια μικτή πορεία προς τις τοπικές εκδηλώσεις, χωρίς να δείχνουν άμεση πρόθεση αγοράς υπηρεσιών.
 3. **«Πιθανός τουρίστας» (Potential tourist):** Είναι η μεγαλύτερη ομάδα (59% των χρηστών). Το μοντέλο αποκάλυψε 4 κρυφές καταστάσεις που χαρτογραφούν την πορεία του χρήστη από την αρχική σελίδα προς τα αξιοθέατα, και τελικά προς αγοραστικές ενέργειες, όπως η εύρεση διαμονής (Accommodation) ή τοπικών εμπειριών (Experiences).

3.1.2 Μεθοδολογία

Η μεθοδολογία του άρθρου επικεντρώνεται στο πώς θα επιλεγεί το βέλτιστο MHMM. Όταν δεν υπάρχει εκ των προτέρων γνώση για τα δεδομένα, η επιλογή βασίζεται συνήθως σε παραδοσιακά κριτήρια, όπως το BIC. Ωστόσο, τέτοιου είδους κριτήρια δεν λαμβάνουν υπόψη τον βαθμό διαχωρισμού μεταξύ των λανθανουσών κλάσεων (δηλαδή των διαφορετικών προφίλ που προκύπτουν).

Για την αντιμετώπιση αυτού του προβλήματος, οι συγγραφείς βασίστηκαν στην προσέγγιση της Ολοκληρωμένης Συμπληρωμένης Πιθανοφάνειας (Integrated Completed Likelihood - ICL). Το νέο κριτήριο, BIC_H , λειτουργεί ως μια προσέγγιση του ICL, χρησιμοποιώντας τη βάση του BIC αλλά «ποινικοποιώντας» το μοντέλο με γνώμονα την **εντροπία**.

Ο τύπος του BIC_H συνδυάζει μαθηματικά τρία στοιχεία:

1. **Την παρατηρούμενη λογαριθμική πιθανοφάνεια (log-likelihood):** Αξιολογεί τον βαθμό προσαρμογής του μοντέλου, δηλαδή το πόσο καλά το μοντέλο εξηγεί τα παρατηρούμενα δεδομένα.
2. **Μια συνολική ποινή εντροπίας:** Προστίθεται για να «τιμωρήσει» την αβεβαιότητα στην ταξινόμηση των χρηστών, εξασφαλίζοντας τον βέλτιστο διαχωρισμό τους. Η ποινή αυτή αποτελείται από δύο επίπεδα: την εντροπία που σχετίζεται με τον αριθμό των συστάδων (δηλαδή πόσο αβέβαιο είναι το μοντέλο για το σε ποιο cluster ανήκει ο χρήστης) και την εντροπία που σχετίζεται με τις κρυφές καταστάσεις (αβεβαιότητα για την ακριβή αλληλουχία των προθέσεων του).

3. **Τους βαθμούς ελευθερίας:** Λειτουργεί ως ποινή για την πολυπλοκότητα του μοντέλου, λαμβάνοντας υπόψη τον αριθμό των παρατηρήσεων, τις υπολογιζόμενες παραμέτρους, και τυχόν σταθερές στον χρόνο συμμεταβλητές που επηρεάζουν την πιθανότητα ένταξης σε μια ομάδα, όπως για παράδειγμα η γεωγραφική περιοχή ή η συσκευή πρόσβασης του χρήστη.

Τέλος, η εκτίμηση των παραμέτρων (εκπαίδευση) του μοντέλου πραγματοποιήθηκε μέσω του γνωστού αλγορίθμου Expectation-Maximization (EM).

3.1.3 Συμπεράσματα

Το άρθρο συμπεραίνει ότι η χρήση κριτηρίων που βασίζονται στην εντροπία, όπως το BIC_H , είναι πολύ πιο αποτελεσματική από τα παραδοσιακά κριτήρια όταν αναλύονται σύντομες ακολουθίες, οι οποίες αποτελούν τον κανόνα στα δεδομένα clickstream.

Η ενσωμάτωση της εντροπίας επιτρέπει στο μοντέλο να επιλέγει διαμορφώσεις με τον καλύτερο δυνατό διαχωρισμό τόσο μεταξύ των διαφορετικών προφίλ χρηστών όσο και μεταξύ των κρυφών προθέσεων κάθε χρήστη. Πρακτικά, η εφαρμογή αυτών των μοντέλων μπορεί να προσφέρει σε επιχειρήσεις ηλεκτρονικού εμπορίου πολύτιμες γνώσεις για τη στρατηγική τους. Αυτό συμβαίνει διότι τα MHMMs αποκαλύπτουν όχι μόνο το τι κάνουν οι χρήστες (δηλαδή τις παρατηρούμενες καταστάσεις), αλλά και τους πιθανούς λόγους για τους οποίους πλοηγούνται με έναν συγκεκριμένο τρόπο (δηλαδή τις κρυφές καταστάσεις).

3.2 Real-time user clickstream behavior analysis based on apache storm streaming

3.2.1 Σκοπός της Έρευνας

Ο κύριος σκοπός αυτού του άρθρου [6], είναι η ανάπτυξη ενός ολοκληρωμένου συστήματος για την ανάλυση της συμπεριφοράς και των προθέσεων των καταναλωτών σε πλατφόρμες ηλεκτρονικού εμπορίου σε πραγματικό χρόνο. Η έρευνα αυτή υποκινείται από τους περιορισμούς των παραδοσιακών συστημάτων προτάσεων, τα οποία βασίζονται κυρίως σε στατική, εκτός-σύνδεσης ανάλυση ιστορικών δεδομένων, αποτυγχάνοντας έτσι να προσαρμοστούν στις άμεσες μεταβολές του ενδιαφέροντος του χρήστη κατά τη διάρκεια μιας ενεργής συνεδρίας.

Εστιάζοντας στα δεδομένα clickstream που δημιουργούνται κατά τη πλοήγηση, οι συγγραφείς επιδιώκουν να χαρτογραφήσουν τα μοτίβα συμπεριφοράς και την τρέχουσα πρόθεση αναζήτησης του καταναλωτή. Απώτερος στόχος είναι η άμεση πρόβλεψη των επόμενων κινήσεων του χρήστη, η εξατομίκευση των προτάσεων προϊόντων την ακριβή στιγμή της περιήγησης και η δυναμική συσταδοποίηση των πελατών, επιτυγχάνοντας τη βέλτιστη δυνατή απόδοση της υποδομής με ελάχιστη καθυστέρηση κατά την επεξεργασία.

3.2.2 Μεθοδολογία

Η μεθοδολογία αξιοποιεί την αρχιτεκτονική Lambda για να γεφυρώσει την ανάλυση ιστορικών παρτίδων δεδομένων (batch processing μέσω Apache Hadoop) με τη ζωντανή επεξεργασία ροών. Για την επίτευξη χαμηλής καθυστέρησης, τα δεδομένα Apache Kafka, την επεξεργασία τους από το Apache Storm, και τελικά την αποθήκευσή τους στη βάση δεδομένων Cassandra, επιτρέποντας την άμεση ανταπόκριση του συστήματος.

Η αναλυτική διαδικασία βασίζεται σε τρεις κεντρικούς άξονες:

1. **Εξόρυξη Μοτίβων:** Αρχικά, εξάγονται αλληλουχίες N-grams (μήκους 2 έως 7 κλικ) για να ανακαλυφθούν τα πιο συχνά μονοπάτια πλοήγησης μέσα στο site. Στη συνέχεια, εφαρμόζεται η μέθοδος Collocation μέσω του στατιστικού ελέγχου T-Test. Αυτό επιτρέπει στο σύστημα να συγκρίνει διαφορετικούς πληθυσμούς (π.χ. χρήστες που εξετάζουν ακριβά έναντι φθηνών προϊόντων) και να διαπιστώσει εάν οι διαδρομές που ακολουθούν διαφέρουν στατιστικά σημαντικά.
2. **Συσταδοποίηση:** Η τμηματοποίηση των χρηστών πραγματοποιείται με τη βοήθεια του αλγορίθμου EM σε συνδυασμό με Gaussian Mixture Models (GMM). Μέσω αυτής της προσέγγισης, ο κάθε χρήστης κατατάσσεται στοχαστικά σε συστάδες, αναγνωρίζοντας ότι δεν ανήκει απόλυτα σε μία μόνο κατηγορία, αλλά μπορεί να εμπίπτει σε πολλαπλά αγοραστικά προφίλ ταυτόχρονα, με διαφορετικό βαθμό πιθανότητας στο καθένα.
3. **Πρόβλεψη επόμενου κλικ:** Χρησιμοποιούνται Μαρκοβιανές Αλυσίδες υψηλότερης τάξης (higher-order Markov Chains). Το σύστημα δημιουργεί πίνακες πιθανοτήτων μετάβασης που εξετάζουν το δυναμικό ιστορικό των k πιο πρόσφατων καταστάσεων του χρήστη (π.χ. «Προβολή Προϊόντος» → «Προσθήκη στο Καλάθι»), ώστε να υπολογίσουν μαθηματικά ποια θα είναι η πιο πιθανή επόμενη κίνησή του.

3.2.3 Συμπεράσματα

Συνοψίζοντας, η συγκεκριμένη μελέτη καταδεικνύει ότι η ανάλυση του clickstream των πελατών σε σχεδόν πραγματικό χρόνο μπορεί να προσφέρει σημαντικό ανταγωνιστικό πλεονέκτημα, εφόσον υποστηρίζεται από την κατάλληλη υποδομή Big Data. Οι συγγραφείς απέδειξαν ότι η εφαρμογή της αρχιτεκτονικής Λάμδα, η οποία συνδυάζει το Apache Kafka για τη σύλληψη δεδομένων και το Apache Storm για την επεξεργασία τους, επιτρέπει την αποτελεσματική εξαγωγή πληροφορίας, όπως συχνά μοτίβα πλοήγησης (n-grams) και πίνακες συν-εμφάνισης.

Επιπροσθέτως, η έρευνα ανέδειξε την πρακτική αξία του συνδυασμού προηγμένων αλγορίθμων μηχανικής μάθησης. Συγκεκριμένα, η δυναμική τμηματοποίηση των χρηστών (μέσω K-Means και Expectation-Maximization) και η πρόβλεψη των μελλοντικών τους κινήσεων (αξιοποιώντας Μαρκοβιανές Αλυσίδες Υψηλής Τάξης) καθιστούν εφικτή την παροχή εξαιρετικά στοχευμένων προτάσεων. Όσον αφορά την αποδοτικότητα της υποδομής, η χρήση της βάσης δεδομένων Cassandra, σε συνδυασμό με τεχνικές βελτιστοποίησης για εγκαταστάσεις σε πολλαπλά κέντρα δεδομένων, εξασφάλισε απαντήσεις με ελάχιστη καθυστέρηση. Η απόδοση αυτή επιβεβαιώθηκε πειραματικά μέσω μετρικών στο Microsoft Azure HDInsight cluster.

3.3 Pattern2Vec: Representation of clickstream data sequences for learning user navigational behavior

3.3.1 Σκοπός της έρευνας

Σκοπός της εργασίας [5] ήταν η ανάπτυξη μιας νέας μεθόδου αναπαράστασης δεδομένων πλοήγησης χρηστών (clickstream), με την ονομασία Pattern2Vec, με στόχο την αποτελεσματικότερη κατανόηση της συμπεριφοράς των χρηστών κατά την πλοήγησή τους σε ιστοσελίδες. Το βασικό πρόβλημα που αντιμετωπίζεται είναι ότι οι ακολουθίες URLs αποτελούν μη αριθμητικά και μη δομημένα δεδομένα, τα οποία δεν μπορούν να αξιοποιηθούν άμεσα από αλγορίθμους μηχανικής μάθησης. Για τον λόγο αυτό, προτείνεται η μετατροπή των ακολουθιών πλοήγησης σε διανυσματικές αναπαραστάσεις (embeddings), οι οποίες αποτυπώνουν το σημασιολογικό περιεχόμενο και το πλαίσιο εμφάνισης των URLs. Με τον τρόπο αυτό καθίσταται δυνατή η εφαρμογή τεχνικών μη επιβλεπόμενης

μάθησης, όπως η ομαδοποίηση (clustering), για την αναγνώριση προτύπων συμπεριφοράς. Τα αποτελέσματα έδειξαν ότι η προτεινόμενη μέθοδος υπερτερεί έναντι υπαρχουσών προσεγγίσεων, όπως οι Word2Vec, DeepWalk και Node2Vec. Συγκεκριμένα, παρουσίασε υψηλότερες επιδόσεις σε μετρικές αξιολόγησης ομαδοποίησης, όπως το v-score, η ομοιογένεια (homogeneity) και η πληρότητα (completeness), επιτυγχάνοντας ποσοστά που προσεγγίζουν το 95 τοις εκατό. Επιπλέον, τα παραγόμενα clusters εμφανίζουν μεγαλύτερη συνοχή και καλύτερο διαχωρισμό.

3.3.2 Μεθοδολογία

Αρχικά, συλλέχθηκαν δεδομένα clickstream από πραγματική ιστοσελίδα του ηλεκτρονικού εμπορίου. Στη συνέχεια πραγματοποιήθηκε η προεπεξεργασία δεδομένων, η οποία περιλάμβανε καθαρισμό (data cleansing), απομάκρυνση ελλιπών εγγραφών, καθώς και κανονικοποίηση των URLs μέσω κανονικών εκφράσεων, ώστε να αντιστοιχιστούν σε γενικότερες κατηγορίες. Έπειτα, τα δεδομένα οργανώθηκαν σε συνεδρίες πλοήγησης (sessions), λαμβάνοντας υπόψη χρονικούς περιορισμούς, όπως το μέγιστο χρονικό διάστημα μεταξύ διαδοχικών ενεργειών. Με αυτόν τον τρόπο εξασφαλίστηκε ότι οι ακολουθίες αντανakλούν την ρεαλιστική συμπεριφορά χρηστών. Στη συνέχεια, εφαρμόστηκε η εξόρυξη προτύπων (pattern mining) με αλγορίθμους όπως ο PrefixSpan και ο FPGrowth, με στόχο την αναγνώριση συχνών και λανθανόντων (hidden) προτύπων πλοήγησης. Παράλληλα, πραγματοποιήθηκε φιλτράρισμα για την απομάκρυνση πλεοναζόντων ή επικαλυπτόμενων προτύπων. Το κύριο στάδιο της μεθοδολογίας είναι η εφαρμογή της Pattern2Vec. Η μέθοδος βασίζεται σε διανυσματικές αναπαραστάσεις τύπου Word2Vec, αλλά διαφοροποιείται στο ότι εισάγει μηχανισμό στάθμισης των χαρακτηριστικών. Συγκεκριμένα, αξιοποιεί τον νόμο του Zipf, ώστε κάθε URL να συνεισφέρει διαφορετικά στο τελικό διάνυσμα, ανάλογα με τη συχνότητα εμφάνισης και τη θέση του μέσα στο πρότυπο. Με αυτόν τον τρόπο αποδίδεται μεγαλύτερη σημασία στα πιο αντιπροσωπευτικά στοιχεία της ακολουθίας. Τέλος, εφαρμόστηκαν τεχνικές μη επιβλεπόμενης μάθησης, όπως ο αλγόριθμος K-Means και η ιεραρχική ομαδοποίηση (Agglomerative Clustering), για την αξιολόγηση της ποιότητας των παραγόμενων αναπαραστάσεων. Η αξιολόγηση βασίστηκε σε μετρικές ομαδοποίησης, καθώς και σε τεχνικές οπτικοποίησης, όπως το t-SNE.

3.3.3 Συμπεράσματα

Συνοψίζοντας, η εργασία καταδεικνύει ότι η Pattern2Vec αποτελεί μια πιο αποδοτική μέθοδο αναπαράστασης δεδομένων clickstream σε σύγκριση με τις υπάρχουσες προσεγγίσεις. Η βασική καινοτομία της έγκειται στην ενσωμάτωση της σχετικής σημασίας και της θέσης των URLs στη διαδικασία δημιουργίας των embeddings. Η προσέγγιση αυτή οδηγεί σε μία βελτιωμένη ποιότητα ομαδοποίησης, με πιο διακριτά και ερμηνεύσιμα σύνολα δεδομένων. Επιπλέον, η μέθοδος μπορεί να εφαρμοστεί σε πρακτικά σενάρια, όπως η ανάλυση διοχέτευσης χρηστών (funnel analysis) και η αυτοματοποίηση δοκιμής διεπαφής λογισμικού. Τέλος, προτείνονται κατευθύνσεις για μελλοντική έρευνα, όπως η ανάπτυξη μηχανισμών κατάταξης προτύπων και η εφαρμογή της μεθόδου σε άλλα είδη ακολουθιακών δεδομένων, γεγονός που υποδεικνύει τη δυναμική επέκτασης αυτής της προσέγγισης.

3.4 Exclusive Item Recommendation to the Online Shopping Customers Based on Category Using Clickstream and UID Matrix, 2023 [7]

3.4.1 Σκοπός της έρευνας

Ο βασικός στόχος της συγκεκριμένης έρευνας είναι η ανάπτυξη ενός πιο ακριβούς και εξατομικευμένου συστήματος συστάσεων προϊόντων για online αγορές, αξιοποιώντας clickstream δεδομένα και

το ιστορικό αγορών των χρηστών. Σε αντίθεση με πολλές υπάρχουσες προσεγγίσεις που βασίζονται κυρίως σε ratings ή απλά clicks, η συγκεκριμένη εργασία δίνει έμφαση στη πραγματική αγοραστική συμπεριφορά του χρήστη. Οι βασικοί σκοποί της μελέτης είναι η εξής: η ανάλυση της συμπεριφοράς των χρηστών μέσα από clickstream δεδομένα, η ταξινόμηση των χρηστών σε τρεις διαφορετικές κατηγορίες που είναι Regular, Special και Exceptional, η δημιουργία ενός πιο πλούσιου User-Item-Detail matrix που ενσωματώνει πολλαπλά χαρακτηριστικά συμπεριφοράς και η παροχή εξατομικευμένων και αποκλειστικών προτάσεων προϊόντων για κάθε κατηγορία χρηστών με στόχο τη βελτίωση της εμπειρίας αγορών και την αύξηση των πωλήσεων.

3.4.2 Μεθοδολογία

Η προτεινόμενη μεθοδολογία UID-KNN αποτελείται από τέσσερα βασικά στάδια που συνδυάζουν τεχνικές επεξεργασίας δεδομένων, μηχανικής μάθησης και συστημάτων συστάσεων. Αρχικά πραγματοποιείται η προεπεξεργασία των clickstream δεδομένων. Σε αυτό το στάδιο γίνεται καθαρισμός των δεδομένων, η αναγνώριση μοναδικών χρηστών μέσω user ID ή IP διεύθυνσης, καθώς και ο διαχωρισμός των sessions με βάση τη χρονική δραστηριότητα του χρήστη. Επιπλέον γίνεται path completion ώστε να ανακατασκευαστούν ελλιπείς διαδρομές πλοήγησης και να αποτυπωθεί πιο σωστά η συμπεριφορά του χρήστη. Στη συνέχεια εφαρμόζεται ο αλγόριθμος K-Nearest Neighbors για την ταξινόμηση των χρηστών. Η ταξινόμηση δεν βασίζεται απλά στο browsing behavior αλλά κυρίως στο ιστορικό αγορών. Οι χρήστες χωρίζονται σε τρεις κατηγορίες που είναι Regular, Special και Exceptional, με βάση χαρακτηριστικά όπως χρόνος παραμονής σε προϊόντα, αριθμός clicks, προσθήκη στο καλάθι, wishlist και ολοκλήρωση αγοράς. Η ομοιότητα μεταξύ χρηστών υπολογίζεται με Ευκλείδεια απόσταση. Έπειτα κατασκευάζεται το User-Item-Detail matrix, το οποίο αποτελεί μια πιο αναλυτική μορφή αναπαράστασης δεδομένων σε σχέση με το κλασικό user-item matrix. Ο πίνακας αυτός περιλαμβάνει χαρακτηριστικά όπως την βαθμολογία προϊόντος, τον χρόνο θέασης, τον αριθμό επισκέψεων στη σελίδα προϊόντος, την προσθήκη στο καλάθι, την προσθήκη στη wishlist και την τελική αγορά. Με βάση αυτά τα δεδομένα δημιουργούνται τρεις ξεχωριστοί πίνακες UID για κάθε κατηγορία χρηστών, ώστε να υπάρχει πιο στοχευμένη ανάλυση και καλύτερη εξατομίκευση. Τέλος εφαρμόζεται ο μηχανισμός συστάσεων που προτείνει τα top-N προϊόντα σε κάθε κατηγορία χρηστών. Οι προτάσεις βασίζονται τόσο στη συμπεριφορά του χρήστη όσο και στη συσχέτιση μεταξύ χρηστών και προϊόντων μέσα από το collaborative filtering approach. Για την αξιολόγηση της μεθόδου χρησιμοποιούνται τα metrics MAE και RMSE για την ακρίβεια των προβλέψεων, καθώς και το Precision, Recall και F-measure για την ποιότητα των προτάσεων.

3.4.3 Συμπεράσματα

Τα αποτελέσματα της έρευνας δείχνουν ότι η προτεινόμενη μέθοδος UID-KNN παρουσιάζει καλύτερη απόδοση σε σχέση με υπάρχουσες προσεγγίσεις που βασίζονται μόνο σε item ratings ή απλό user-item matrix. Συγκεκριμένα, επιτυγχάνει χαμηλότερες τιμές MAE και RMSE, κάτι που δείχνει πιο ακριβείς προβλέψεις και μικρότερο σφάλμα στο σύστημα συστάσεων. Επιπλέον, η ταξινόμηση των χρηστών σε τρεις διαφορετικές κατηγορίες συμβάλλει σημαντικά στη βελτίωση της ποιότητας των προτάσεων, καθώς επιτρέπει την πιο στοχευμένη και εξατομικευμένη παροχή προϊόντων. Το σύστημα καταφέρνει να προσαρμόζει τις προτάσεις με βάση το προφίλ και τη συμπεριφορά κάθε χρήστη, κάτι που βελτιώνει συνολικά την εμπειρία του online shopping. Συνολικά, η μελέτη αποδεικνύει ότι η χρήση clickstream δεδομένων σε συνδυασμό με την ταξινόμηση των χρηστών και το εμπλουτισμένο UID matrix μπορεί να βελτιώσει σημαντικά την απόδοση των recommender systems. Ως μελλοντική εργασία προτείνεται η ενσωμάτωση τεχνικών deep learning για ακόμη πιο ακριβή και δυναμικά συστήματα προτάσεων.

4 Μετέπειτα Εργασίες

4.1 Mining and Predicting Users Clickstream Patterns from Noisy Interleaving Clicks

Η εργασία των Alamoudi et al. [1] επικεντρώνεται στην εξόρυξη και την πρόβλεψη clickstream patterns σε ρεαλιστικά ψηφιακά περιβάλλοντα, όπου οι ακολουθίες των χρηστών επιβαρύνονται από θόρυβο και παρεμβαλλόμενες, άσχετες ενέργειες. Με δεδομένο ότι η ανθρώπινη συμπεριφορά στον ιστό σπάνια ακολουθεί γραμμικές ή ιδανικές διαδρομές, οι συγγραφείς προσεγγίζουν το clickstream ως ένα στοχαστικό ακολουθιακό πρόβλημα και εισάγουν μια μεθοδολογία βασισμένη σε ένα τροποποιημένο suffix tree σε συνδυασμό με κινούμενο χρονικό παράθυρο. Η προσέγγιση αυτή επιτρέπει την απομόνωση και την εξόρυξη συχνών, μη επικαλυπτόμενων προτύπων συμπεριφοράς, διασφαλίζοντας παράλληλα την υπολογιστική αποδοτικότητα της αναζήτησης μέσω της ιδιότητας της αντι-μονοτονικότητας, ακόμη και όταν η κύρια δραστηριότητα διακόπτεται προσωρινά.

Για το στάδιο της μοντελοποίησης και της πρόβλεψης των μελλοντικών κινήσεων του χρήστη, η έρευνα αξιοποιεί ένα τροποποιημένο Hidden Markov Model. Η επιλογή αυτή βασίζεται στην ικανότητα των Μαρκοβιανών δομών να αποτυπώνουν τις χρονικές και στατιστικές εξαρτήσεις μεταξύ διαδοχικών ενεργειών, συνδέοντας τα παρατηρούμενα, θορυβώδη μοτίβα με τις λανθάνουσες καταστάσεις και τις υποκείμενες προθέσεις πλοήγησης. Η εκτίμηση των παραμέτρων και η βελτιστοποίηση των πιθανοτήτων μετάβασης πραγματοποιούνται μέσω του αλγορίθμου EM, με τα πειραματικά αποτελέσματα να επιβεβαιώνουν την υψηλή ακρίβεια πρόβλεψης του μοντέλου ακόμη και σε συνθήκες υψηλού θορύβου.

Συνολικά, η συγκεκριμένη μελέτη προσφέρει ένα συνεκτικό πλαίσιο που γεφυρώνει με επιτυχία τις sequential mining τεχνικές με την πιθανοτική στατιστική μοντελοποίηση. Η ικανότητά της να απομονώνει την ουσιαστική πληροφορία από τις τυχαίες ενέργειες αναδεικνύει την εξελιγμένη χρήση των Μαρκοβιανών αλυσίδων και των κρυφών καταστάσεων, καθιστώντας την προσέγγιση αυτή εξαιρετικά ανθεκτική και πολύτιμη για την κατανόηση της σύνθετης ανθρώπινης συμπεριφοράς σε μη ιδανικά ψηφιακά περιβάλλοντα.

4.2 Clickstream user behavior models

Η εργασία των Wang et al. [9] εστιάζει στη συστηματική μοντελοποίηση της συμπεριφοράς των χρηστών σε μεγάλες διαδικτυακές πλατφόρμες μέσω της αξιοποίησης clickstream δεδομένων. Αντιμετωπίζοντας την περιήγηση στον ιστό ως ένα αμιγώς ακολουθιακό φαινόμενο με βαθύτερη ερμηνευτική αξία, η μελέτη απομακρύνεται από την απλή καταγραφή μεμονωμένων ενεργειών και στοχεύει στην αποκάλυψη των λανθανόντων προτύπων που χαρακτηρίζουν διαφορετικές ομάδες χρηστών. Κεντρικός άξονας της έρευνας είναι η σαφής διάκριση μεταξύ φυσιολογικής και μη φυσιολογικής δραστηριότητας, προσφέροντας ένα ολοκληρωμένο πλαίσιο για την ανίχνευση κακόβουλων ή παραπλανητικών λογαριασμών, όπως οι λογαριασμοί τύπου Sybil.

Για την υλοποίηση της ανάλυσης, οι συγγραφείς προτείνουν τρεις διαφορετικές αναπαραστάσεις των ακολουθιών πλοήγησης: την αναπαράσταση click-sequence, τη χρονική αναπαράσταση μέσω ενός time-based model, καθώς και ένα αντίστοιχο υβριδικό μοντέλο. Οι προσεγγίσεις αυτές αποτυπώνουν τόσο τη σειρά των ενεργειών όσο και τη χρονική απόσταση μεταξύ τους, επιτρέποντας την ακριβέστερη κατανόηση της πρόθεσης του χρήστη. Η μέτρηση της ομοιότητας πραγματοποιείται με εξειδικευμένες μετρικές, όπως τα common subsequences, τα subsequences with counts και ο στατιστικός έλεγχος Kolmogorov–Smirnov για τα χρονικά χαρακτηριστικά. Στη συνέχεια, οι χρήστες χαρτογραφούνται σε έναν γράφο ομοιότητας και διαχωρίζονται σε ομάδες με τη χρήση του αλγορίθμου METIS, ενώ ένας παράλληλος μηχανισμός incremental de-

tection επιτρέπει την ταξινόμηση νέων δεδομένων χωρίς την ανάγκη ολικής επανεκπαίδευσης του συστήματος.

Τα συμπεράσματα της έρευνας αναδεικνύουν ότι ακόμη και σχετικά απλές αναπαραστάσεις ακολουθιών, όταν συνδυάζονται με κατάλληλες τεχνικές ομαδοποίησης και ανάλυσης ομοιότητας, επαρκούν για την εξαγωγή ουσιαστικών συμπερασμάτων χωρίς να απαιτείται μεγάλος όγκος επισημασμένων δεδομένων. Η συγκεκριμένη εργασία ενισχύει τον μεθοδολογικό ιστό της αναφοράς, αποδεικνύοντας πώς η σύγκριση ακολουθιακών δομών και οι αλγόριθμοι συσταδοποίησης μπορούν να αποκαλύψουν τα λανθάνοντα χαρακτηριστικά και τις στρατηγικές πλοήγησης των χρηστών.

4.3 Real-time clickstream data analytics and visualization

Η εργασία των Hanamanthrao και Thejaswini [3] επικεντρώνεται στην ανάπτυξη μιας αρχιτεκτονικής για την επεξεργασία, ανάλυση και οπτικοποίηση clickstream δεδομένων σε πραγματικό χρόνο. Αναγνωρίζοντας ότι η επιχειρησιακή αξία των δεδομένων πλοήγησης πολλαπλασιάζεται όταν η διαχείρισή τους γίνεται άμεσα, οι συγγραφείς προτείνουν ένα ολοκληρωμένο λειτουργικό πλαίσιο διαχείρισης συνεχών ροών. Η προσέγγιση αυτή στοχεύει στην υποστήριξη ψηφιακών περιβαλλόντων όπου η χαμηλή καθυστέρηση και η άμεση απόκριση είναι κρίσιμες, όπως οι πλατφόρμες ηλεκτρονικού εμπορίου και τα συστήματα τηλεεκπαίδευσης, επιτρέποντας τη γρήγορη λήψη αποφάσεων και τη δυναμική βελτιστοποίηση των ψηφιακών υπηρεσιών.

Η προτεινόμενη μεθοδολογία υλοποιεί μια end-to-end data pipeline αρχιτεκτονική, η οποία βασίζεται στον συνδυασμό των Apache Kafka, Apache Spark Streaming, Elasticsearch και Kibana. Τα δεδομένα συλλέγονται ζωντανά, διοχετεύονται μέσω του Kafka και υποβάλλονται σε real-time επεξεργασία από το Spark Streaming, προκειμένου να ευρετηριαστούν στο Elasticsearch και να παρουσιαστούν διαδραστικά μέσω του Kibana. Η υποδομή επιτρέπει την παρακολούθηση κρίσιμων δεικτών, όπως ο αριθμός των clicks, ο χρόνος παραμονής και τα συχνότερα μονοπάτια πλοήγησης. Με αυτόν τον τρόπο, η έμφαση μετατοπίζεται από την ανάπτυξη πολύπλοκων προβλεπτικών μοντέλων στην αποδοτική διαχείριση και την άμεση επιχειρησιακή αξιοποίηση της ροής των δεδομένων.

Τα συμπεράσματα της μελέτης αναδεικνύουν τη σημασία της τεχνικής και λειτουργικής πλευράς των web analytics, προσφέροντας ένα ισχυρό τεχνολογικό υπόβαθρο. Η συγκεκριμένη εργασία προσθέτει σημαντική αξία στην παρούσα αναφορά, καθώς εισάγει το απαραίτητο υποστηρικτικό πλαίσιο streaming και visualization που πρέπει να προηγείται της φάσης της μοντελοποίησης. Υπενθυμίζει με σαφήνεια ότι η ποιότητα και η αξιοπιστία των εξαγόμενων προτύπων συμπεριφοράς εξαρτώνται άμεσα από την ορθή συλλογή, επεξεργασία και παρουσίαση των δεδομένων στην είσοδο του συστήματος.

4.4 Χρήση Deep Learning για prediction

4.4.1 Predicting online shopping behaviour from clickstream data using deep learning

Η εργασία των Koehn et al. [4] εξετάζει την πρόβλεψη της αγοραστικής συμπεριφοράς χρηστών από clickstream δεδομένα, χρησιμοποιώντας deep learning και συγκεκριμένα recurrent neural networks. Οι συγγραφείς υποστηρίζουν ότι τα clickstream δεδομένα έχουν εγγενώς σειριακή δομή, την οποία τα κλασικά supervised μοντέλα δεν αξιοποιούν επαρκώς, και προτείνουν τη μοντελοποίηση των sessions ως ακολουθιών page views. Στο πλαίσιο μιας εφαρμογής e-commerce, το μοντέλο χρησιμοποιείται για την πρόβλεψη του αν ένας επισκέπτης θα ολοκληρώσει αγορά, με στόχο τη βελτιστοποίηση στοχευμένων marketing ενεργειών, όπως η αποστολή ψηφιακών κουπονιών.

Η βασική συνεισφορά της εργασίας είναι ότι συγκρίνει διαφορετικές RNN αρχιτεκτονικές, όπως LSTM και GRU, με κλασικά supervised baselines και δείχνει ότι τα sequence models μπορούν να αποτυπώσουν καλύτερα τις χρονικές εξαρτήσεις της πλοήγησης. Παράλληλα, οι συγγραφείς δεν αξιολογούν μόνο την predictive performance, αλλά και το business value του μοντέλου, δείχνοντας ότι η χρησιμότητα ενός classifier σε τέτοιο περιβάλλον εξαρτάται όχι μόνο από την ακρίβεια αλλά και από το οικονομικό όφελος που προσφέρει. Για τον λόγο αυτό, η εργασία καταλήγει ότι ένας συνδυασμός sequence και conventional classifiers μέσω ensemble μπορεί να δώσει τα πιο σταθερά αποτελέσματα.

4.5 Incremental clickstream pattern mining

4.5.1 Efficient Long Sequential User Data Modeling for Click-Through Rate Prediction

Η εργασία των Chen et al. [2] εξετάζει την πρόβλεψη click-through rate (CTR) αξιοποιώντας μεγάλες ακολουθίες συμπεριφοράς χρηστών σε recommendation systems. Οι συγγραφείς υποστηρίζουν ότι τα κλασικά sequence-based μοντέλα, όπως τα DIN και DIEN, περιορίζονται κυρίως σε σύντομες ακολουθίες λόγω του αυξανόμενου υπολογιστικού κόστους, με αποτέλεσμα να μη μπορούν να εκμεταλλευτούν πλήρως το μακροχρόνιο ιστορικό του χρήστη. Για τον λόγο αυτό προτείνουν το ETA-Net, ένα end-to-end μοντέλο που σχεδιάστηκε ειδικά για αποδοτική μοντελοποίηση μακρών user behavior sequences.

Η βασική τεχνική συνεισφορά της εργασίας είναι ο μηχανισμός Efficient Target Attention, ο οποίος αντικαθιστά το κλασικό dot-product attention με hashing-based bit-wise operations. Με αυτόν τον τρόπο μειώνεται σημαντικά η υπολογιστική πολυπλοκότητα της διαδικασίας επιλογής των πιο σχετικών συμπεριφορών, ενώ το μοντέλο παραμένει ικανό να μαθαίνει χρήσιμα long-term interest patterns. Παράλληλα, οι συγγραφείς προτείνουν και μια γενική αρχιτεκτονική για την ενσωμάτωση του ETA-Net σε βιομηχανικά recommendation systems μεγάλης κλίμακας.

Τα πειράματα δείχνουν ότι το ETA-Net υπερέχει σε σχέση με state-of-the-art μεθόδους τόσο σε offline αξιολόγηση όσο και σε online A/B testing. Στην πρακτική εφαρμογή του στο Taobao, το μοντέλο οδήγησε σε βελτιώσεις τόσο στο CTR όσο και στο GMV, επιβεβαιώνοντας ότι η αποδοτική χρήση μακρών ακολουθιών μπορεί να προσφέρει ουσιαστικό επιχειρηματικό όφελος. Έτσι, η εργασία αποτελεί ένα πολύ σημαντικό παράδειγμα για το πώς η αποδοτικότητα και η predictive performance μπορούν να συνδυαστούν σε πραγματικά industrial settings.

5 Σύνοψη και συμπεράσματα

References

- [1] A. Alamoudi, F. Fekri, M. Mohandes, and B. Liu. Mining and predicting users clickstream patterns from noisy interleaving clicks. In *2022 IEEE Global Communications Conference (GLOBECOM)*, pages 3083–3088, 2022.
- [2] Qiwei Chen, Yue Xu, Changhua Pei, Shanshan Lv, Tao Zhuang, and Junfeng Ge. Efficient long sequential user data modeling for click-through rate prediction. In *Proceedings of the 31st ACM International Conference on Information and Knowledge Management Workshop on Deep Learning Practice for High-Dimensional Sparse Data (DLP-KDD)*, 2022.
- [3] Ramanna Hanamanthrao and Thejaswini S. Real-time clickstream data analytics and visualization. In *2017 2nd IEEE International Conference on Recent Trends in Electronics Information & Communication Technology (RTEICT)*, pages 2139–2144, May 2017.
- [4] Dennis Koehn, Stefan Lessmann, and Markus Schaal. Predicting online shopping behaviour from clickstream data using deep learning. *Expert Systems with Applications*, 150:113342, 2020.
- [5] Erdi Olmezogullari and Mehmet S. Aktas. Pattern2vec: Representation of clickstream data sequences for learning user navigational behavior. 2022.
- [6] Gautam Pal, Katie Atkinson, and Gangmin Li. Real-time user clickstream behavior analysis based on apache storm streaming. 2023.
- [7] R. Suguna, P. Sathishkumar, and S. Deepa. Exclusive item recommendation to the online shopping customers based on category using clickstream and uid matrix. In *Computer Networks and Inventive Communication Technologies*, pages 177–190. Springer, 2023.
- [8] Furio Urso, Antonino Abbruzzo, Marcello Chiodi, and Maria Francesca Cracolici. Model selection for mixture hidden markov models: an application to clickstream data. 2024.
- [9] Gang Wang, Xinyi Zhang, Shiliang Tang, Christo Wilson, Haitao Zheng, and Ben Y. Zhao. Clickstream user behavior models. *ACM Transactions on the Web*, 11(4):21:1–21:37, 2017.