



ΠΑΝΕΠΙΣΤΗΜΙΟ
ΠΑΤΡΩΝ
UNIVERSITY OF PATRAS

Πολυτεχνική Σχολή

Τμήμα Μηχανικών Η/Υ & Πληροφορικής

ΕΞΟΥΣΗ ΔΕΔΟΜΕΝΩΝ ΚΑΙ ΑΛΓΟΡΙΘΜΟΙ ΜΑΘΗΣΗΣ

βατραχοπόδαρα

Γεωργία Μυλωνά

A.M. 1104783

Δημήτριος Φιλόπουλος

A.M. 1101130

Πάτρα, 2026

Contents

1	Εισαγωγή	2
1.1	Σαμπ-εισαγωγή	2
1.1.1	Σαμπ-σαμπ-εισαγωγή	2
2	Προηγούμενες σχετικές μελέτες	2
2.1	Model selection for mixture hidden Markov models: an application to click-stream data [1]	2
2.1.1	Σκοπός της Έρευνας	2
2.1.2	Μεθοδολογία	3
2.1.3	Συμπεράσματα	4
2.2	Pattern2Vec: Representation of clickstream data sequences for learning user navigational behavior [2]	4
2.2.1	Σκοπός της Έρευνας	4
2.2.2	Μεθοδολογία	4
2.2.3	Συμπεράσματα	5
3	Προτεινόμενες τεχνικές	5
3.1	Θεωρητική περιγραφή	5
3.2	Υλοποίηση - Πειράματα	5
4	Μετέπειτα Εργασίες	5
5	Σύνοψη και συμπεράσματα	5

1 Εισαγωγή

Εδώ γράφετε την εισαγωγή σας...

1.1 Σαμπ-εισαγωγή

1.1.1 Σαμπ-σαμπ-εισαγωγή

2 Προηγούμενες σχετικές μελέτες

Εδώ γίνεται η ανασκόπηση της βιβλιογραφίας...

2.1 Model selection for mixture hidden Markov models: an application to clickstream data [1]

2.1.1 Σκοπός της Έρευνας

Ο κύριος σκοπός αυτού του άρθρου είναι η εις βάθος ανάλυση δεδομένων clickstream μέσω της χρήσης Mixture Hidden Markov Models (MHMMs). Η ανάλυση αυτή αποσκοπεί στο να ξεπεράσει τους περιορισμούς των απλών αλγορίθμων ομαδοποίησης, οι οποίοι συχνά απαιτούν έναν μεγάλο και μη πρακτικό αριθμό συστάδων για να παράγουν ομοιογενείς ομάδες, επειδή εξετάζουν αποκλειστικά τις ορατές αλληλουχίες των σελίδων που επισκέπτονται οι χρήστες.

Τα MHMMs προσφέρουν μια ουσιαστικότερη προσέγγιση στην ομαδοποίηση των ακολουθιών πλοήγησης, καθώς δεν αντιμετωπίζουν τη συμπεριφορά των χρηστών ως μια απλή, τυχαία σειρά από κλικ. Αντιθέτως, βασίζονται στην υπόθεση ότι η πλοήγηση καθοδηγείται από μια μίξη λανθάνουσών μαρκοβιανών διαδικασιών, καθεμία από τις οποίες αντιστοιχεί σε έναν διαφορετικό, άγνωστο υποπληθυσμό χρηστών. Αυτές οι διαδικασίες αποτυπώνουν τα λανθάνοντα κίνητρα των χρηστών, τα οποία αναφέρονται στη μελέτη ως «νοητικές» ή «κρυφές καταστάσεις» (mental / hidden states). Οι καταστάσεις αυτές υπαγορεύουν την πορεία του χρήστη μέσα στον ιστότοπο, προσαρμόζοντας τις επιλογές του ανάλογα με τον εκάστοτε στόχο του. Με αυτόν τον τρόπο, το μοντέλο καταφέρνει να αποκαλύψει υποκείμενα προφίλ συμπεριφοράς που δεν θα μπορούσαν να εντοπιστούν αποκλειστικά από την επιφανειακή καταγραφή των σελίδων.

Ωστόσο, η πρακτική εφαρμογή των MHMMs περιπλέκεται σημαντικά από την ανάγκη προσδιορισμού ενός άγνωστου, εκ των προτέρων, αριθμού τόσο των συστάδων όσο και αυτών των κρυφών καταστάσεων. Όταν τα δεδομένα αποτελούνται από σύντομες ακολουθίες, τα παραδοσιακά κριτήρια πληροφοριών αποτυγχάνουν να υποδείξουν τον σωστό αριθμό ομάδων, καθώς αγνοούν τον βαθμό διαχωρισμού μεταξύ των προφίλ των χρηστών.

Για να αντιμετωπίσουν αυτή την πρόκληση και να εντοπίσουν τον βέλτιστο διαχωρισμό των χρηστών, οι συγγραφείς ανέπτυξαν και πρότειναν ένα νέο κριτήριο επιλογής μοντέλου, το BIC_H . Το κριτήριο αυτό σχεδιάστηκε ειδικά για να επιλέγει μοντέλα που δεν προσαρμόζονται απλώς καλά στα παρατηρούμενα δεδομένα, αλλά ταυτόχρονα αξιολογούν την αβεβαιότητα της ταξινόμησης, προσφέροντας τελικά διακριτές και εύκολα ερμηνεύσιμες ομάδες χρηστών.

Όσον αφορά τα **αποτελέσματα**, η αξιολόγηση του προτεινόμενου κριτηρίου χωρίζεται σε δύο σκέλη:

- **Αξιολόγηση μέσω Monte Carlo προσομοιώσεων:** Οι συγγραφείς εξέτασαν την απόδοση του BIC_H έναντι των κλασικών κριτηρίων πληροφοριών (AIC , BIC και $ssBIC$) σε διάφορα σενάρια, μεταβάλλοντας το μήκος των ακολουθιών και τον αριθμό των δεδομένων. Αποδείχθηκε ότι σε ακολουθίες μικρού μήκους, γεγονός που αποτελεί τον κανόνα στα

δεδομένα clickstream, το BIC_H έχει σημαντικά καλύτερη απόδοση στην ταυτόχρονη αναγνώριση του σωστού αριθμού συστάδων και καταστάσεων. Αντίθετα, τα κλασικά κριτήρια δυσκολεύονται έντονα και υποτιμούν συστηματικά τον αριθμό των συστάδων.

- **Εφαρμογή σε πραγματικά δεδομένα:** Κατά την ανάλυση των πραγματικών δεδομένων clickstream από τον ιστότοπο της εταιρείας φιλοξενίας "LovePanormus", το κριτήριο BIC_H επέλεξε ένα μοντέλο με 3 συστάδες (clusters) και (3, 2, 4) κρυφές καταστάσεις αντίστοιχα. Η επιλογή αυτή αποκάλυψε τρία διακριτά προφίλ χρηστών:
 1. **«Απλός επισκέπτης / πιθανός συνεργάτης» (Casual explorer / Potential partner):** Αποτελεί το 22% των χρηστών. Το μοντέλο εντόπισε 3 κρυφές καταστάσεις σε αυτό το προφίλ, οι οποίες αντιστοιχούν σε πλοήγηση στην αρχική σελίδα, σε γενική εξερεύνηση, και στην αναζήτηση πληροφοριών για την ίδια την εταιρεία.
 2. **«Αναζητητής πληροφοριών» (Information seeker):** Αποτελεί το 19% των χρηστών. Εδώ εντοπίστηκαν 2 κρυφές καταστάσεις, όπου οι χρήστες εστιάζουν αποκλειστικά σε τουριστικές πληροφορίες (αξιοθέατα) ή ακολουθούν μια μικτή πορεία προς τις τοπικές εκδηλώσεις, χωρίς να δείχνουν άμεση πρόθεση αγοράς υπηρεσιών.
 3. **«Πιθανός τουρίστας» (Potential tourist):** Είναι η μεγαλύτερη ομάδα (59% των χρηστών). Το μοντέλο αποκάλυψε 4 κρυφές καταστάσεις που χαρτογραφούν την πορεία του χρήστη από την αρχική σελίδα προς τα αξιοθέατα, και τελικά προς αγοραστικές ενέργειες, όπως η εύρεση διαμονής (Accommodation) ή τοπικών εμπειριών (Experiences).

2.1.2 Μεθοδολογία

Η μεθοδολογία του άρθρου επικεντρώνεται στο πώς θα επιλεγεί το βέλτιστο MHMM. Όταν δεν υπάρχει εκ των προτέρων γνώση για τα δεδομένα, η επιλογή βασίζεται συνήθως σε παραδοσιακά κριτήρια, όπως το BIC. Ωστόσο, τέτοιου είδους κριτήρια δεν λαμβάνουν υπόψη τον βαθμό διαχωρισμού μεταξύ των λανθανουσών κλάσεων (δηλαδή των διαφορετικών προφίλ που προκύπτουν).

Για την αντιμετώπιση αυτού του προβλήματος, οι συγγραφείς βασίστηκαν στην προσέγγιση της Ολοκληρωμένης Συμπληρωμένης Πιθανοφάνειας (Integrated Completed Likelihood - ICL). Το νέο κριτήριο, BIC_H , λειτουργεί ως μια προσέγγιση του ICL, χρησιμοποιώντας τη βάση του BIC αλλά «ποινικοποιώντας» το μοντέλο με γνώμονα την **εντροπία**.

Ο τύπος του BIC_H συνδυάζει μαθηματικά τρία στοιχεία:

1. **Την παρατηρούμενη λογαριθμική πιθανοφάνεια (log-likelihood):** Αξιολογεί τον βαθμό προσαρμογής του μοντέλου, δηλαδή το πόσο καλά το μοντέλο εξηγεί τα παρατηρούμενα δεδομένα.
2. **Μια συνολική ποινή εντροπίας:** Προστίθεται για να «τιμωρήσει» την αβεβαιότητα στην ταξινόμηση των χρηστών, εξασφαλίζοντας τον βέλτιστο διαχωρισμό τους. Η ποινή αυτή αποτελείται από δύο επίπεδα: την εντροπία που σχετίζεται με τον αριθμό των συστάδων (δηλαδή πόσο αβέβαιο είναι το μοντέλο για το σε ποιο cluster ανήκει ο χρήστης) και την εντροπία που σχετίζεται με τις κρυφές καταστάσεις (αβεβαιότητα για την ακριβή αλληλουχία των προθέσεων του).
3. **Τους βαθμούς ελευθερίας:** Λειτουργεί ως ποινή για την πολυπλοκότητα του μοντέλου, λαμβάνοντας υπόψη τον αριθμό των παρατηρήσεων, τις υπολογιζόμενες παραμέτρους, και τυχόν σταθερές στον χρόνο συμμεταβλητές που επηρεάζουν την πιθανότητα ένταξης

σε μια ομάδα, όπως για παράδειγμα η γεωγραφική περιοχή ή η συσκευή πρόσβασης του χρήστη.

Τέλος, η εκτίμηση των παραμέτρων (εκπαίδευση) του μοντέλου πραγματοποιήθηκε μέσω του γνωστού αλγορίθμου Expectation-Maximization (EM).

2.1.3 Συμπεράσματα

Το άρθρο συμπεραίνει ότι η χρήση κριτηρίων που βασίζονται στην εντροπία, όπως το BIC_H , είναι πολύ πιο αποτελεσματική από τα παραδοσιακά κριτήρια όταν αναλύονται σύντομες ακολουθίες, οι οποίες αποτελούν τον κανόνα στα δεδομένα clickstream.

Η ενσωμάτωση της εντροπίας επιτρέπει στο μοντέλο να επιλέγει διαμορφώσεις με τον καλύτερο δυνατό διαχωρισμό τόσο μεταξύ των διαφορετικών προφίλ χρηστών όσο και μεταξύ των κρυφών προθέσεων κάθε χρήστη. Πρακτικά, η εφαρμογή αυτών των μοντέλων μπορεί να προσφέρει σε επιχειρήσεις ηλεκτρονικού εμπορίου πολύτιμες γνώσεις για τη στρατηγική τους. Αυτό συμβαίνει διότι τα MHMMs αποκαλύπτουν όχι μόνο το τι κάνουν οι χρήστες (δηλαδή τις παρατηρούμενες καταστάσεις), αλλά και τους πιθανούς λόγους για τους οποίους πλοηγούνται με έναν συγκεκριμένο τρόπο (δηλαδή τις κρυφές καταστάσεις).

2.2 Pattern2Vec: Representation of clickstream data sequences for learning user navigational behavior [2]

2.2.1 Σκοπός της Έρευνας

Σκοπός της εργασίας ήταν η ανάπτυξη μιας νέας μεθόδου αναπαράστασης δεδομένων πλοήγησης χρηστών (clickstream), με την ονομασία Pattern2Vec, με στόχο την αποτελεσματικότερη κατανόηση της συμπεριφοράς των χρηστών κατά την πλοήγησή τους σε ιστοσελίδες. Το βασικό πρόβλημα που αντιμετωπίζεται είναι ότι οι ακολουθίες URLs αποτελούν μη αριθμητικά και μη δομημένα δεδομένα, τα οποία δεν μπορούν να αξιοποιηθούν άμεσα από αλγορίθμους μηχανικής μάθησης. Για τον λόγο αυτό, προτείνεται η μετατροπή των ακολουθιών πλοήγησης σε διανυσματικές αναπαραστάσεις (embeddings), οι οποίες αποτυπώνουν το σημασιολογικό περιεχόμενο και το πλαίσιο εμφάνισης των URLs. Με τον τρόπο αυτό καθίσταται δυνατή η εφαρμογή τεχνικών μη επιβλεπόμενης μάθησης, όπως η ομαδοποίηση (clustering), για την αναγνώριση προτύπων συμπεριφοράς. Τα αποτελέσματα έδειξαν ότι η προτεινόμενη μέθοδος υπερτερεί έναντι υπαρχουσών προσεγγίσεων, όπως οι Word2Vec, DeepWalk και Node2Vec. Συγκεκριμένα, παρουσίασε υψηλότερες επιδόσεις σε μετρικές αξιολόγησης ομαδοποίησης, όπως το v -score, η ομοιογένεια (homogeneity) και η πληρότητα (completeness), επιτυγχάνοντας ποσοστά που προσεγγίζουν το 95 τοις εκατό. Επιπλέον, τα παραγόμενα clusters εμφανίζουν μεγαλύτερη συνοχή και καλύτερο διαχωρισμό.

2.2.2 Μεθοδολογία

Αρχικά, συλλέχθηκαν δεδομένα clickstream από πραγματική ιστοσελίδα του ηλεκτρονικού εμπορίου. Στη συνέχεια πραγματοποιήθηκε η προεπεξεργασία δεδομένων, η οποία περιλάμβανε καθαρισμό (data cleansing), απομάκρυνση ελλιπών εγγραφών, καθώς και κανονικοποίηση των URLs μέσω κανονικών εκφράσεων, ώστε να αντιστοιχιστούν σε γενικότερες κατηγορίες. Έπειτα, τα δεδομένα οργανώθηκαν σε συνεδρίες πλοήγησης (sessions), λαμβάνοντας υπόψη χρονικούς περιορισμούς, όπως το μέγιστο χρονικό διάστημα μεταξύ διαδοχικών ενεργειών. Με αυτόν τον τρόπο εξασφαλίστηκε ότι οι ακολουθίες αντανakλούν την ρεαλιστική συμπεριφορά χρηστών. Στη συνέχεια, εφαρμόστηκε η εξόρυξη προτύπων (pattern mining) με αλγορίθμους όπως ο PrefixSpan και ο FPGrowth, με

στόχο την αναγνώριση συχνών και λανθανόντων (hidden) προτύπων πλοήγησης. Παράλληλα, πραγματοποιήθηκε φιλτράρισμα για την απομάκρυνση πλεοναζόντων ή επικαλυπτόμενων προτύπων. Το κύριο στάδιο της μεθοδολογίας είναι η εφαρμογή της Pattern2Vec. Η μέθοδος βασίζεται σε διανυσματικές αναπαραστάσεις τύπου Word2Vec, αλλά διαφοροποιείται στο ότι εισάγει μηχανισμό στάθμισης των χαρακτηριστικών. Συγκεκριμένα, αξιοποιεί τον νόμο του Zipf, ώστε κάθε URL να συνεισφέρει διαφορετικά στο τελικό διάνυσμα, ανάλογα με τη συχνότητα εμφάνισης και τη θέση του μέσα στο πρότυπο. Με αυτόν τον τρόπο αποδίδεται μεγαλύτερη σημασία στα πιο αντιπροσωπευτικά στοιχεία της ακολουθίας. Τέλος, εφαρμόστηκαν τεχνικές μη επιβλεπόμενης μάθησης, όπως ο αλγόριθμος K-Means και η ιεραρχική ομαδοποίηση (Agglomerative Clustering), για την αξιολόγηση της ποιότητας των παραγόμενων αναπαραστάσεων. Η αξιολόγηση βασίστηκε σε μετρικές ομαδοποίησης, καθώς και σε τεχνικές οπτικοποίησης, όπως το t-SNE.

2.2.3 Συμπεράσματα

Συνοψίζοντας, η εργασία καταδεικνύει ότι η Pattern2Vec αποτελεί μια πιο αποδοτική μέθοδο αναπαράστασης δεδομένων clickstream σε σύγκριση με τις υπάρχουσες προσεγγίσεις. Η βασική καινοτομία της έγκειται στην ενσωμάτωση της σχετικής σημασίας και της θέσης των URLs στη διαδικασία δημιουργίας των embeddings. Η προσέγγιση αυτή οδηγεί σε μία βελτιωμένη ποιότητα ομαδοποίησης, με πιο διακριτά και ερμηνεύσιμα σύνολα δεδομένων. Επιπλέον, η μέθοδος μπορεί να εφαρμοστεί σε πρακτικά σενάρια, όπως η ανάλυση διοχέτευσης χρηστών (funnel analysis) και η αυτοματοποίηση δοκιμής διεπαφής λογισμικού. Τέλος, προτείνονται κατευθύνσεις για μελλοντική έρευνα, όπως η ανάπτυξη μηχανισμών κατάταξης προτύπων και η εφαρμογή της μεθόδου σε άλλα είδη ακολουθιακών δεδομένων, γεγονός που υποδεικνύει τη δυναμική επέκτασης αυτής της προσέγγισης.

3 Προτεινόμενες τεχνικές

3.1 Θεωρητική περιγραφή

Η θεωρία πίσω από την υλοποίηση...

3.2 Υλοποίηση - Πειράματα

Ανάλυση του κώδικα, μεθοδολογία και πειραματικά αποτελέσματα...

4 Μετέπειτα Εργασίες

Ιδέες για μελλοντική επέκταση της εργασίας (Future Work)...

5 Σύνοψη και συμπεράσματα

Τελικά συμπεράσματα και σύνοψη της μελέτης...

References

- [1] Furio Urso, Antonino Abbruzzo, Marcello Chiodi, Maria Francesca Cracolici (2024) Model selection for mixture hidden Markov models: an application to clickstream data <https://doi.org/10.1007/s00362-024-01608-3>
- [2] Erdi Olmezogullari, Mehmet S. Aktas (2022) Pattern2Vec: Representation of clickstream data sequences for learning user navigational behavior <https://doi.org/10.1002/cpe.6546>
- [3] Gautam Pal, Katie Atkinson, Gangmin Li (2023) Real-time user clickstream behavior analysis based on apache storm streaming <https://doi.org/10.1007/s10660-021-09518-4>