



ΠΑΝΕΠΙΣΤΗΜΙΟ
ΠΑΤΡΩΝ
UNIVERSITY OF PATRAS

Πολυτεχνική Σχολή

Τμήμα Μηχανικών Η/Υ & Πληροφορικής

ΕΞΟΡΥΞΗ ΔΕΔΟΜΕΝΩΝ ΚΑΙ ΜΗΧΑΝΙΚΗ ΜΑΘΗΣΗ

**ΑΝΑΦΟΡΑ ΒΑΣΙΣΜΕΝΗ ΣΤΗΝ ΑΝΑΛΥΣΗ
ΤΟΥ CLICKSTREAM**

Γεωργία Μυλωνά

A.M. 1104783

Δημήτριος Φιλόπουλος

A.M. 1101130

Πάτρα, 2026

Contents

1	Εισαγωγή	2
2	Προηγούμενες σχετικές μελέτες	2
3	Βασική ανάλυση	2
3.1	Model selection for mixture hidden Markov models: an application to click-stream data [1]	2
3.1.1	Σκοπός της Έρευνας	2
3.1.2	Μεθοδολογία	3
3.1.3	Συμπεράσματα	4
3.2	Real-time user clickstream behavior analysis based on apache storm streaming	4
3.2.1	Σκοπός της Έρευνας	4
3.2.2	Μεθοδολογία	4
3.2.3	Συμπεράσματα	5
3.3	Pattern2Vec: Representation of clickstream data sequences for learning user navigational behavior [2]	5
3.3.1	Σκοπός της έρευνας	5
3.3.2	Μεθοδολογία	5
3.3.3	Συμπεράσματα	6
3.4	Exclusive Item Recommendation to the Online Shopping Customers Based on Category Using Clickstream and UID Matrix, 2023 [4]	6
3.4.1	Σκοπός της έρευνας	6
3.4.2	Μεθοδολογία	6
3.4.3	Συμπεράσματα	7
4	Μετέπειτα Εργασίες	7
5	Σύνοψη και συμπεράσματα	7

1 Εισαγωγή

2 Προηγούμενες σχετικές μελέτες

3 Βασική ανάλυση

3.1 Model selection for mixture hidden Markov models: an application to clickstream data [1]

3.1.1 Σκοπός της Έρευνας

Ο κύριος σκοπός αυτού του άρθρου είναι η εις βάθος ανάλυση δεδομένων clickstream μέσω της χρήσης Mixture Hidden Markov Models (MHMMs). Η ανάλυση αυτή αποσκοπεί στο να ξεπεράσει τους περιορισμούς των απλών αλγορίθμων ομαδοποίησης, οι οποίοι συχνά απαιτούν έναν μεγάλο και μη πρακτικό αριθμό συστάδων για να παράγουν ομοιογενείς ομάδες, επειδή εξετάζουν αποκλειστικά τις ορατές αλληλουχίες των σελίδων που επισκέπτονται οι χρήστες.

Τα MHMMs προσφέρουν μια ουσιαστικότερη προσέγγιση στην ομαδοποίηση των ακολουθιών πλοήγησης, καθώς δεν αντιμετωπίζουν τη συμπεριφορά των χρηστών ως μια απλή, τυχαία σειρά από κλικ. Αντιθέτως, βασίζονται στην υπόθεση ότι η πλοήγηση καθοδηγείται από μια μίξη λανθανουσών μαρκοβιανών διαδικασιών, καθεμία από τις οποίες αντιστοιχεί σε έναν διαφορετικό, άγνωστο υποπληθυσμό χρηστών. Αυτές οι διαδικασίες αποτυπώνουν τα λανθάνοντα κίνητρα των χρηστών, τα οποία αναφέρονται στη μελέτη ως «νοητικές» ή «κρυφές καταστάσεις» (mental / hidden states). Οι καταστάσεις αυτές υπαγορεύουν την πορεία του χρήστη μέσα στον ιστότοπο, προσαρμόζοντας τις επιλογές του ανάλογα με τον εκάστοτε στόχο του. Με αυτόν τον τρόπο, το μοντέλο καταφέρνει να αποκαλύψει υποκείμενα προφίλ συμπεριφοράς που δεν θα μπορούσαν να εντοπιστούν αποκλειστικά από την επιφανειακή καταγραφή των σελίδων.

Ωστόσο, η πρακτική εφαρμογή των MHMMs περιπλέκεται σημαντικά από την ανάγκη προσδιορισμού ενός άγνωστου, εκ των προτέρων, αριθμού τόσο των συστάδων όσο και αυτών των κρυφών καταστάσεων. Όταν τα δεδομένα αποτελούνται από σύντομες ακολουθίες, τα παραδοσιακά κριτήρια πληροφοριών αποτυγχάνουν να υποδείξουν τον σωστό αριθμό ομάδων, καθώς αγνοούν τον βαθμό διαχωρισμού μεταξύ των προφίλ των χρηστών.

Για να αντιμετωπίσουν αυτή την πρόκληση και να εντοπίσουν τον βέλτιστο διαχωρισμό των χρηστών, οι συγγραφείς ανέπτυξαν και πρότειναν ένα νέο κριτήριο επιλογής μοντέλου, το BIC_H . Το κριτήριο αυτό σχεδιάστηκε ειδικά για να επιλέγει μοντέλα που δεν προσαρμόζονται απλώς καλά στα παρατηρούμενα δεδομένα, αλλά ταυτόχρονα αξιολογούν την αβεβαιότητα της ταξινόμησης, προσφέροντας τελικά διακριτές και εύκολα ερμηνεύσιμες ομάδες χρηστών.

Όσον αφορά τα **αποτελέσματα**, η αξιολόγηση του προτεινόμενου κριτηρίου χωρίζεται σε δύο σκέλη:

- **Αξιολόγηση μέσω Monte Carlo προσομοιώσεων:** Οι συγγραφείς εξέτασαν την απόδοση του BIC_H έναντι των κλασικών κριτηρίων πληροφοριών (AIC , BIC και $ssBIC$) σε διάφορα σενάρια, μεταβάλλοντας το μήκος των ακολουθιών και τον αριθμό των δεδομένων. Αποδείχθηκε ότι σε ακολουθίες μικρού μήκους, γεγονός που αποτελεί τον κανόνα στα δεδομένα clickstream, το BIC_H έχει σημαντικά καλύτερη απόδοση στην ταυτόχρονη αναγνώριση του σωστού αριθμού συστάδων και καταστάσεων. Αντίθετα, τα κλασικά κριτήρια δυσκολεύονται έντονα και υποτιμούν συστηματικά τον αριθμό των συστάδων.
- **Εφαρμογή σε πραγματικά δεδομένα:** Κατά την ανάλυση των πραγματικών δεδομένων clickstream από τον ιστότοπο της εταιρείας φιλοξενίας "LovePanormus", το κριτήριο

BIC_H επέλεξε ένα μοντέλο με 3 συστάδες (clusters) και (3, 2, 4) κρυφές καταστάσεις αντίστοιχα. Η επιλογή αυτή αποκάλυψε τρία διακριτά προφίλ χρηστών:

1. **«Απλός επισκέπτης / πιθανός συνεργάτης» (Casual explorer / Potential partner):** Αποτελεί το 22% των χρηστών. Το μοντέλο εντόπισε 3 κρυφές καταστάσεις σε αυτό το προφίλ, οι οποίες αντιστοιχούν σε πλοήγηση στην αρχική σελίδα, σε γενική εξερεύνηση, και στην αναζήτηση πληροφοριών για την ίδια την εταιρεία.
2. **«Αναζητητής πληροφοριών» (Information seeker):** Αποτελεί το 19% των χρηστών. Εδώ εντοπίστηκαν 2 κρυφές καταστάσεις, όπου οι χρήστες εστιάζουν αποκλειστικά σε τουριστικές πληροφορίες (αξιοθέατα) ή ακολουθούν μια μικτή πορεία προς τις τοπικές εκδηλώσεις, χωρίς να δείχνουν άμεση πρόθεση αγοράς υπηρεσιών.
3. **«Πιθανός τουρίστας» (Potential tourist):** Είναι η μεγαλύτερη ομάδα (59% των χρηστών). Το μοντέλο αποκάλυψε 4 κρυφές καταστάσεις που χαρτογραφούν την πορεία του χρήστη από την αρχική σελίδα προς τα αξιοθέατα, και τελικά προς αγοραστικές ενέργειες, όπως η εύρεση διαμονής (Accommodation) ή τοπικών εμπειριών (Experiences).

3.1.2 Μεθοδολογία

Η μεθοδολογία του άρθρου επικεντρώνεται στο πώς θα επιλεγεί το βέλτιστο MHMM. Όταν δεν υπάρχει εκ των προτέρων γνώση για τα δεδομένα, η επιλογή βασίζεται συνήθως σε παραδοσιακά κριτήρια, όπως το BIC. Ωστόσο, τέτοιου είδους κριτήρια δεν λαμβάνουν υπόψη τον βαθμό διαχωρισμού μεταξύ των λανθανουσών κλάσεων (δηλαδή των διαφορετικών προφίλ που προκύπτουν).

Για την αντιμετώπιση αυτού του προβλήματος, οι συγγραφείς βασίστηκαν στην προσέγγιση της Ολοκληρωμένης Συμπληρωμένης Πιθανοφάνειας (Integrated Completed Likelihood - ICL). Το νέο κριτήριο, BIC_H , λειτουργεί ως μια προσέγγιση του ICL, χρησιμοποιώντας τη βάση του BIC αλλά «ποινικοποιώντας» το μοντέλο με γνώμονα την **εντροπία**.

Ο τύπος του BIC_H συνδυάζει μαθηματικά τρία στοιχεία:

1. **Την παρατηρούμενη λογαριθμική πιθανοφάνεια (log-likelihood):** Αξιολογεί τον βαθμό προσαρμογής του μοντέλου, δηλαδή το πόσο καλά το μοντέλο εξηγεί τα παρατηρούμενα δεδομένα.
2. **Μια συνολική ποινή εντροπίας:** Προστίθεται για να «τιμωρήσει» την αβεβαιότητα στην ταξινόμηση των χρηστών, εξασφαλίζοντας τον βέλτιστο διαχωρισμό τους. Η ποινή αυτή αποτελείται από δύο επίπεδα: την εντροπία που σχετίζεται με τον αριθμό των συστάδων (δηλαδή πόσο αβέβαιο είναι το μοντέλο για το σε ποιο cluster ανήκει ο χρήστης) και την εντροπία που σχετίζεται με τις κρυφές καταστάσεις (αβεβαιότητα για την ακριβή αλληλουχία των προθέσεων του).
3. **Τους βαθμούς ελευθερίας:** Λειτουργεί ως ποινή για την πολυπλοκότητα του μοντέλου, λαμβάνοντας υπόψη τον αριθμό των παρατηρήσεων, τις υπολογιζόμενες παραμέτρους, και τυχόν σταθερές στον χρόνο συμμεταβλητές που επηρεάζουν την πιθανότητα ένταξης σε μια ομάδα, όπως για παράδειγμα η γεωγραφική περιοχή ή η συσκευή πρόσβασης του χρήστη.

Τέλος, η εκτίμηση των παραμέτρων (εκπαίδευση) του μοντέλου πραγματοποιήθηκε μέσω του γνωστού αλγορίθμου Expectation-Maximization (EM).

3.1.3 Συμπεράσματα

Το άρθρο συμπεραίνει ότι η χρήση κριτηρίων που βασίζονται στην εντροπία, όπως το BIC_H , είναι πολύ πιο αποτελεσματική από τα παραδοσιακά κριτήρια όταν αναλύονται σύντομες ακολουθίες, οι οποίες αποτελούν τον κανόνα στα δεδομένα clickstream.

Η ενσωμάτωση της εντροπίας επιτρέπει στο μοντέλο να επιλέγει διαμορφώσεις με τον καλύτερο δυνατό διαχωρισμό τόσο μεταξύ των διαφορετικών προφίλ χρηστών όσο και μεταξύ των κρυφών προθέσεων κάθε χρήστη. Πρακτικά, η εφαρμογή αυτών των μοντέλων μπορεί να προσφέρει σε επιχειρήσεις ηλεκτρονικού εμπορίου πολύτιμες γνώσεις για τη στρατηγική τους. Αυτό συμβαίνει διότι τα MHMMs αποκαλύπτουν όχι μόνο το τι κάνουν οι χρήστες (δηλαδή τις παρατηρούμενες καταστάσεις), αλλά και τους πιθανούς λόγους για τους οποίους πλοηγούνται με έναν συγκεκριμένο τρόπο (δηλαδή τις κρυφές καταστάσεις).

3.2 Real-time user clickstream behavior analysis based on apache storm streaming

[3]

3.2.1 Σκοπός της Έρευνας

Ο κύριος σκοπός αυτού του άρθρου είναι η ανάπτυξη ενός συστήματος για την ανάλυση της συμπεριφοράς και των προθέσεων των καταναλωτών σε πλατφόρμες ηλεκτρονικού εμπορίου σε πραγματικό χρόνο. Εστιάζοντας στα δεδομένα clickstream που δημιουργούνται κατά την πλοήγηση των χρηστών, οι συγγραφείς επιδιώκουν να κατανοήσουν τα μοτίβα συμπεριφοράς (browsing motifs) και την πρόθεση αναζήτησης. Στόχος είναι η άμεση πρόβλεψη των επόμενων κινήσεων του χρήστη, η εξατομίκευση των προτάσεων (όπως τα «πρόσφατα προβαλλόμενα προϊόντα») και η δυναμική τμηματοποίηση των πελατών, με ελάχιστη δυνατή καθυστέρηση (low latency).

3.2.2 Μεθοδολογία

Η μεθοδολογία του άρθρου βασίζεται στην αρχιτεκτονική Λάμδα (Lambda Architecture) για Big Data, η οποία συνδυάζει την ανάλυση ιστορικών δεδομένων σε παρτίδες (batch processing μέσω Hadoop) με την επεξεργασία ροών δεδομένων σε πραγματικό χρόνο. Για το κομμάτι του πραγματικού χρόνου, το σύστημα αντλεί τα δεδομένα από τον browser του πελάτη χρησιμοποιώντας εργαλεία όπως το Apache Kafka, τα επεξεργάζεται μέσω του Apache Storm και τα αποθηκεύει στη βάση δεδομένων Cassandra.

Η αναλυτική διαδικασία βασίζεται σε τρεις άξονες:

1. **Εξόρυξη Μοτίβων (Pattern Mining):** Γίνεται χρήση αλληλουχιών N-grams και της μεθόδου Collocation (μέσω του στατιστικού ελέγχου T-Test) για να εντοπιστούν οι πιο σημαντικές και συχνές διαδρομές πλοήγησης.
2. **Ομαδοποίηση (Clustering):** Η τμηματοποίηση των χρηστών πραγματοποιείται με τη βοήθεια του αλγορίθμου Expectation-Maximization (EM) σε συνδυασμό με Μοντέλα Γκαουσιανής Μίξης (Gaussian Mixture Models - GMM). Αυτό επιτρέπει τη «μαλακή» κατανομή (soft allocation), αναγνωρίζοντας ότι ένας χρήστης μπορεί να ανήκει σε πολλαπλά αγοραστικά προφίλ ταυτόχρονα.

3. **Πρόβλεψη επόμενου κλικ:** Χρησιμοποιούνται Μαρκοβιανές Αλυσίδες υψηλότερης τάξης (higher-order Markov Chains), οι οποίες εξετάζουν το ιστορικό των k προηγούμενων καταστάσεων του χρήστη για να προβλέψουν με ακρίβεια την επόμενη κίνησή του.

3.2.3 Συμπεράσματα

Το άρθρο καταλήγει στο συμπέρασμα ότι ο συνδυασμός τεχνολογιών Big Data με προηγμένους αλγορίθμους μηχανικής μάθησης μπορεί να προσφέρει τεράστιο ανταγωνιστικό πλεονέκτημα στο ηλεκτρονικό εμπόριο. Η προτεινόμενη τοπολογία μέσω του Apache Storm καταφέρνει να επεξεργάζεται τεράστιο όγκο δεδομένων (high-velocity stream) διατηρώντας την καθυστέρηση σε επίπεδα χιλιοστών του δευτερολέπτου.

Αυτό σημαίνει πρακτικά ότι οι επιχειρήσεις δεν χρειάζεται να περιμένουν την επόμενη μέρα για να αναλύσουν τη συμπεριφορά των πελατών τους, αλλά μπορούν να αντιδρούν, να τμηματοποιούν το κοινό και να προτείνουν προϊόντα την ακριβή στιγμή που ο πελάτης πλοηγείται στο κατάστημα, αυξάνοντας έτσι σημαντικά τις πιθανότητες πώλησης.

3.3 Pattern2Vec: Representation of clickstream data sequences for learning user navigational behavior [2]

3.3.1 Σκοπός της έρευνας

Σκοπός της εργασίας ήταν η ανάπτυξη μιας νέας μεθόδου αναπαράστασης δεδομένων πλοήγησης χρηστών (clickstream), με την ονομασία Pattern2Vec, με στόχο την αποτελεσματικότερη κατανόηση της συμπεριφοράς των χρηστών κατά την πλοήγησή τους σε ιστοσελίδες. Το βασικό πρόβλημα που αντιμετωπίζεται είναι ότι οι ακολουθίες URLs αποτελούν μη αριθμητικά και μη δομημένα δεδομένα, τα οποία δεν μπορούν να αξιοποιηθούν άμεσα από αλγορίθμους μηχανικής μάθησης. Για τον λόγο αυτό, προτείνεται η μετατροπή των ακολουθιών πλοήγησης σε διανυσματικές αναπαραστάσεις (embeddings), οι οποίες αποτυπώνουν το σημασιολογικό περιεχόμενο και το πλαίσιο εμφάνισης των URLs. Με τον τρόπο αυτό καθίσταται δυνατή η εφαρμογή τεχνικών μη επιβλεπόμενης μάθησης, όπως η ομαδοποίηση (clustering), για την αναγνώριση προτύπων συμπεριφοράς. Τα αποτελέσματα έδειξαν ότι η προτεινόμενη μέθοδος υπερτερεί έναντι υπαρχουσών προσεγγίσεων, όπως οι Word2Vec, DeepWalk και Node2Vec. Συγκεκριμένα, παρουσίασε υψηλότερες επιδόσεις σε μετρικές αξιολόγησης ομαδοποίησης, όπως το v -score, η ομοιογένεια (homogeneity) και η πληρότητα (completeness), επιτυγχάνοντας ποσοστά που προσεγγίζουν το 95 τοις εκατό. Επιπλέον, τα παραγόμενα clusters εμφανίζουν μεγαλύτερη συνοχή και καλύτερο διαχωρισμό.

3.3.2 Μεθοδολογία

Αρχικά, συλλέχθηκαν δεδομένα clickstream από πραγματική ιστοσελίδα του ηλεκτρονικού εμπορίου. Στη συνέχεια πραγματοποιήθηκε η προεπεξεργασία δεδομένων, η οποία περιλάμβανε καθαρισμό (data cleansing), απομάκρυνση ελλιπών εγγραφών, καθώς και κανονικοποίηση των URLs μέσω κανονικών εκφράσεων, ώστε να αντιστοιχιστούν σε γενικότερες κατηγορίες. Έπειτα, τα δεδομένα οργανώθηκαν σε συνεδρίες πλοήγησης (sessions), λαμβάνοντας υπόψη χρονικούς περιορισμούς, όπως το μέγιστο χρονικό διάστημα μεταξύ διαδοχικών ενεργειών. Με αυτόν τον τρόπο εξασφαλίστηκε ότι οι ακολουθίες αντανακλούν την ρεαλιστική συμπεριφορά χρηστών. Στη συνέχεια, εφαρμόστηκε η εξόρυξη προτύπων (pattern mining) με αλγορίθμους όπως ο PrefixSpan και ο FPGrowth, με στόχο την αναγνώριση συχνών και λανθανόντων (hidden) προτύπων πλοήγησης. Παράλληλα, πραγματοποιήθηκε φιλτράρισμα για την απομάκρυνση πλεοναζόντων ή επικαλυπτόμενων προτύπων. Το κύριο στάδιο της μεθοδολογίας είναι η εφαρμογή της Pattern2Vec. Η μέθοδος βασίζεται σε

διανυσματικές αναπαραστάσεις τύπου Word2Vec, αλλά διαφοροποιείται στο ότι εισάγει μηχανισμό στάθμισης των χαρακτηριστικών. Συγκεκριμένα, αξιοποιεί τον νόμο του Zipf, ώστε κάθε URL να συνεισφέρει διαφορετικά στο τελικό διάνυσμα, ανάλογα με τη συχνότητα εμφάνισης και τη θέση του μέσα στο πρότυπο. Με αυτόν τον τρόπο αποδίδεται μεγαλύτερη σημασία στα πιο αντιπροσωπευτικά στοιχεία της ακολουθίας. Τέλος, εφαρμόστηκαν τεχνικές μη επιβλεπόμενης μάθησης, όπως ο αλγόριθμος K-Means και η ιεραρχική ομαδοποίηση (Agglomerative Clustering), για την αξιολόγηση της ποιότητας των παραγόμενων αναπαραστάσεων. Η αξιολόγηση βασίστηκε σε μετρικές ομαδοποίησης, καθώς και σε τεχνικές οπτικοποίησης, όπως το t-SNE.

3.3.3 Συμπεράσματα

Συνοψίζοντας, η εργασία καταδεικνύει ότι η Pattern2Vec αποτελεί μια πιο αποδοτική μέθοδο αναπαράστασης δεδομένων clickstream σε σύγκριση με τις υπάρχουσες προσεγγίσεις. Η βασική καινοτομία της έγκειται στην ενσωμάτωση της σχετικής σημασίας και της θέσης των URLs στη διαδικασία δημιουργίας των embeddings. Η προσέγγιση αυτή οδηγεί σε μία βελτιωμένη ποιότητα ομαδοποίησης, με πιο διακριτά και ερμηνεύσιμα σύνολα δεδομένων. Επιπλέον, η μέθοδος μπορεί να εφαρμοστεί σε πρακτικά σενάρια, όπως η ανάλυση διοχέτευσης χρηστών (funnel analysis) και η αυτοματοποίηση δοκιμής διεπαφής λογισμικού. Τέλος, προτείνονται κατευθύνσεις για μελλοντική έρευνα, όπως η ανάπτυξη μηχανισμών κατάταξης προτύπων και η εφαρμογή της μεθόδου σε άλλα είδη ακολουθιακών δεδομένων, γεγονός που υποδεικνύει τη δυναμική επέκτασης αυτής της προσέγγισης.

3.4 Exclusive Item Recommendation to the Online Shopping Customers Based on Category Using Clickstream and UID Matrix, 2023 [4]

3.4.1 Σκοπός της έρευνας

Ο βασικός στόχος της συγκεκριμένης έρευνας είναι η ανάπτυξη ενός πιο ακριβούς και εξατομικευμένου συστήματος συστάσεων προϊόντων για online αγορές, αξιοποιώντας clickstream δεδομένα και το ιστορικό αγορών των χρηστών. Σε αντίθεση με πολλές υπάρχουσες προσεγγίσεις που βασίζονται κυρίως σε ratings ή απλά clicks, η συγκεκριμένη εργασία δίνει έμφαση στη πραγματική αγοραστική συμπεριφορά του χρήστη. Οι βασικοί σκοποί της μελέτης είναι η εξής: η ανάλυση της συμπεριφοράς των χρηστών μέσα από clickstream δεδομένα, η ταξινόμηση των χρηστών σε τρεις διαφορετικές κατηγορίες που είναι Regular, Special και Exceptional, η δημιουργία ενός πιο πλούσιου User-Item-Detail matrix που ενσωματώνει πολλαπλά χαρακτηριστικά συμπεριφοράς και η παροχή εξατομικευμένων και αποκλειστικών προτάσεων προϊόντων για κάθε κατηγορία χρηστών με στόχο τη βελτίωση της εμπειρίας αγορών και την αύξηση των πωλήσεων.

3.4.2 Μεθοδολογία

Η προτεινόμενη μεθοδολογία UID-KNN αποτελείται από τέσσερα βασικά στάδια που συνδυάζουν τεχνικές επεξεργασίας δεδομένων, μηχανικής μάθησης και συστημάτων συστάσεων. Αρχικά πραγματοποιείται η προεπεξεργασία των clickstream δεδομένων. Σε αυτό το στάδιο γίνεται καθαρισμός των δεδομένων, η αναγνώριση μοναδικών χρηστών μέσω user ID ή IP διεύθυνσης, καθώς και ο διαχωρισμός των sessions με βάση τη χρονική δραστηριότητα του χρήστη. Επιπλέον γίνεται path completion ώστε να ανακατασκευαστούν ελλιπείς διαδρομές πλοήγησης και να αποτυπωθεί πιο σωστά η συμπεριφορά του χρήστη. Στη συνέχεια εφαρμόζεται ο αλγόριθμος K-Nearest Neighbors για την ταξινόμηση των χρηστών. Η ταξινόμηση δεν βασίζεται απλά στο browsing behavior αλλά κυρίως στο ιστορικό αγορών. Οι χρήστες χωρίζονται σε τρεις

κατηγορίες που είναι Regular, Special και Exceptional, με βάση χαρακτηριστικά όπως χρόνος παραμονής σε προϊόντα, αριθμός clicks, προσθήκη στο καλάθι, wishlist και ολοκλήρωση αγοράς. Η ομοιότητα μεταξύ χρηστών υπολογίζεται με Ευκλείδεια απόσταση. Έπειτα κατασκευάζεται το User-Item-Detail matrix, το οποίο αποτελεί μια πιο αναλυτική μορφή αναπαράστασης δεδομένων σε σχέση με το κλασικό user-item matrix. Ο πίνακας αυτός περιλαμβάνει χαρακτηριστικά όπως την βαθμολογία προϊόντος, τον χρόνο θέασης, τον αριθμό επισκέψεων στη σελίδα προϊόντος, την προσθήκη στο καλάθι, την προσθήκη στη wishlist και την τελική αγορά. Με βάση αυτά τα δεδομένα δημιουργούνται τρεις ξεχωριστοί πίνακες UID για κάθε κατηγορία χρηστών, ώστε να υπάρχει πιο στοχευμένη ανάλυση και καλύτερη εξατομίκευση. Τέλος εφαρμόζεται ο μηχανισμός συστάσεων που προτείνει τα top-N προϊόντα σε κάθε κατηγορία χρηστών. Οι προτάσεις βασίζονται τόσο στη συμπεριφορά του χρήστη όσο και στη συσχέτιση μεταξύ χρηστών και προϊόντων μέσα από το collaborative filtering approach. Για την αξιολόγηση της μεθόδου χρησιμοποιούνται τα metrics MAE και RMSE για την ακρίβεια των προβλέψεων, καθώς και το Precision, Recall και F-measure για την ποιότητα των προτάσεων.

3.4.3 Συμπεράσματα

Τα αποτελέσματα της έρευνας δείχνουν ότι η προτεινόμενη μέθοδος UID-KNN παρουσιάζει καλύτερη απόδοση σε σχέση με υπάρχουσες προσεγγίσεις που βασίζονται μόνο σε item ratings ή απλό user-item matrix. Συγκεκριμένα, επιτυγχάνει χαμηλότερες τιμές MAE και RMSE, κάτι που δείχνει πιο ακριβείς προβλέψεις και μικρότερο σφάλμα στο σύστημα συστάσεων. Επιπλέον, η ταξινόμηση των χρηστών σε τρεις διαφορετικές κατηγορίες συμβάλλει σημαντικά στη βελτίωση της ποιότητας των προτάσεων, καθώς επιτρέπει την πιο στοχευμένη και εξατομικευμένη παροχή προϊόντων. Το σύστημα καταφέρνει να προσαρμόζει τις προτάσεις με βάση το προφίλ και τη συμπεριφορά κάθε χρήστη, κάτι που βελτιώνει συνολικά την εμπειρία του online shopping. Συνολικά, η μελέτη αποδεικνύει ότι η χρήση clickstream δεδομένων σε συνδυασμό με την ταξινόμηση των χρηστών και το εμπλουτισμένο UID matrix μπορεί να βελτιώσει σημαντικά την απόδοση των recommender systems. Ως μελλοντική εργασία προτείνεται η ενσωμάτωση τεχνικών deep learning για ακόμη πιο ακριβή και δυναμικά συστήματα προτάσεων.

4 Μετέπειτα Εργασίες

5 Σύνοψη και συμπεράσματα

References

- [1] Furio Urso, Antonino Abbruzzo, Marcello Chiodi, Maria Francesca Cracolici (2024) Model selection for mixture hidden Markov models: an application to clickstream data <https://doi.org/10.1007/s00362-024-01608-3>
- [2] Erdi Olmezogullari, Mehmet S. Aktas (2022) Pattern2Vec: Representation of clickstream data sequences for learning user navigational behavior <https://doi.org/10.1002/cpe.6546>
- [3] Gautam Pal, Katie Atkinson, Gangmin Li (2023) Real-time user clickstream behavior analysis based on apache storm streaming <https://doi.org/10.1007/s10660-021-09518-4>
- [4] R. Suguna, P. Sathishkumar, S. Deepa, Exclusive Item Recommendation to the Online Shopping Customers Based on Category Using Clickstream and UID Matrix, 2023 https://link.springer.com/chapter/10.1007/978-981-19-3035-5_14